COMPARAÇÃO ENTRE TÉCNICAS DE MACHINE LEARNING: IDENTIFICAÇÃO DA TÉCNICA MAIS EFICAZ PARA PREDIÇÃO DE VENDAS NUMA EMPRESA VAREJISTA

Caio Aleixo Alves Pereira (caioaleixo61@gmail.com)

Leonardo Carvalho Mascarenhas Meira (leomeira150@gmail.com)

Lucas Parreiras de Sousa (lucasparreirasds@gmail.com)

Renato Moreira Hadad (rhadad@pucminas.br)

1. INTRODUÇÃO

O avanço da tecnologia e em especial da computação é notável ao longo dos anos e acontece de forma cada vez mais acelerada. Graças a essa evolução, novas ferramentas são desenvolvidas e com elas se tornam capazes de produzir mais, com gastos cada vez menores (Mariano Enguita, 1988) e de resolver problemas complexos. A geração de dados a nível mundial, por exemplo, dobra a cada quatro anos segundo estimativa do *International Data Corporation* (IDC) e, por isso, métodos e técnicas para extraí-los, analisá-los e obter informações úteis são importantes na tomada de decisão (Bose e Mahapatra, 2001). Afinal a análise de tantos dados se torna impossível de ser realizada sem o auxílio da tecnologia.

Como citam Bose e Mahapatra (2001), com o desenvolvimento da Inteligência Computacional, surgiram diversas técnicas de *Machine Learning* (cujo significado literal é Aprendizado de Máquina) que permitiram a automação de atividades cruciais para a descoberta de padrões em bancos de dados. Ou seja, o avanço da tecnologia na área não apenas permitiu que empresas organizassem e armazenassem grandes volumes de dados empresariais, mas que estes também pudessem ser analisados (Bose e Mahapatra, 2001).

O *Machine Learning* procura solucionar um problema real, mas, para isso, são necessárias bases de dados com informações que possibilitem chegar à solução (ROZA et. al, 2016). Existem várias técnicas que podem ser utilizadas para realizar

a predição, mas nenhum algoritmo de predição é superior aos demais (WOLPERT e MACREADY, 1997). Sendo assim, umas das tendências nessa área é testar diferentes técnicas e selecionar a melhor para resolver um problema em particular (KOTTHOFF, 2012).

Para fins de investigação, este trabalho utiliza uma base de dados real com histórico de vendas mensais da *BigMart Retail*, marca internacional de lojas de supermercados que foi incorporada na Índia em 2007 e que hoje está presente em vários países do mundo. A empresa investe bastante em serviços gratuitos de entrega à domicílio e possui em seu catálogo mais de 22.000 produtos, entre eles produtos de mercearia e alimentos. A base de dados foi retirada do site *kaggle.com*, que é uma plataforma subsidiária da Google LLC, que reúne profissionais da área de *Machine Learning* e permite que os usuários participem de competições, explorem e publiquem bases de dados e códigos e, por isso, o site é considerado valioso para aprender e resolver na prática problemas envolvendo *Machine Learning.*

Conhecer e estudar técnicas de *Machine Learning* será um diferencial para organizações num futuro próximo, o que motivou a realização deste trabalho. Com a acelerada evolução da tecnologia, torna-se inevitável, para qualquer sociedade e ou empresa em particular, a adoção de inovações tecnológicas (Mariano Enguita, 1988) e, considerando a facilidade cada vez maior para empresas produzir, organizar e armazenar grandes volumes de dados, o *Machine Learning* é um método eficaz de processar tais dados e, a partir deles, gerar valor para a empresa que o utiliza.

O *Machine Learning* começa a se impor no mundo corporativo, em consequência do acesso a grandes volumes de dados, e acreditamos que a quantidade de materiais disponíveis sobre o assunto na rede é proporcional à velocidade que a tecnologia se desenvolverá e se tornará acessível. Sendo assim, este trabalho ajudará na transformação digital do mercado e que cada vez mais empresas conheçam e utilizem o *Machine Learning*. Afinal, a tecnologia tem potencial para beneficiar um negócio em diversas atividades, como por exemplo, a recomendação de produtos personalizada para cada cliente, previsão de demanda, logística e manutenções preditivas.

O objetivo geral deste trabalho é investigar algumas técnicas de *Machine Learning* existentes e identificar qual delas é a mais eficaz quando aplicada para predição de vendas no setor varejista. Os objetivos específicos são: selecionar e pré-processar os dados disponíveis; criar modelos de classificação (por meio de técnicas de aprendizagem de máquina); testar os modelos criados utilizando a base de dados selecionada e comparar a eficácia de cada um dos testes.

2. FUNDAMENTAÇÃO TEÓRICA

2.1 MACHINE LEARNING

O *Machine Learning* é parte da ciência conhecida como Inteligência Artificial (IA), o qual é um ramo da ciência da computação e estuda como as máquinas podem aprender, ou seja, o *Machine Learning* tem o intuito de solucionar problemas do cotidiano das mais diversas áreas de atuação, cuja relevância e necessidade está intrinsicamente ligada ao desenvolvimento de tal conteúdo, mas para que isso aconteça é necessário que haja uma base de dados consistentes que suportem tal solução (SMOLA; VISHWANATHAN, 2008).

Diante disso para que a solução desses problemas seja encontrada em meio aos dados fornecidos é preciso que primeiro sejam compreendidos os processos envolvidos, para que depois modelos possam ser construídos e possam ser validados de acordo com a região com a qual se deseja trabalhar. Tais modelos são baseados e compilados a partir de entradas e saídas possíveis e aplicáveis a tal situação – considera-se uma área de possibilidades infinitas.

Para que um modelo possa ser construído se faz necessário o conhecimento aprofundado e holístico dos processos e problemas envolvidos de forma a se obter uma modelagem fidedigna além de conhecer a qualidade dos dados que estão disponíveis para então ser possível propor algumas soluções. Cada modelo pode ser construído baseado em um ou mais algoritmos os quais e alguma forma se relacionam com os dados e com o mundo exterior, conforme Figura 1.

Figura 1 - Modelagem de fenômenos externos (mundo real)

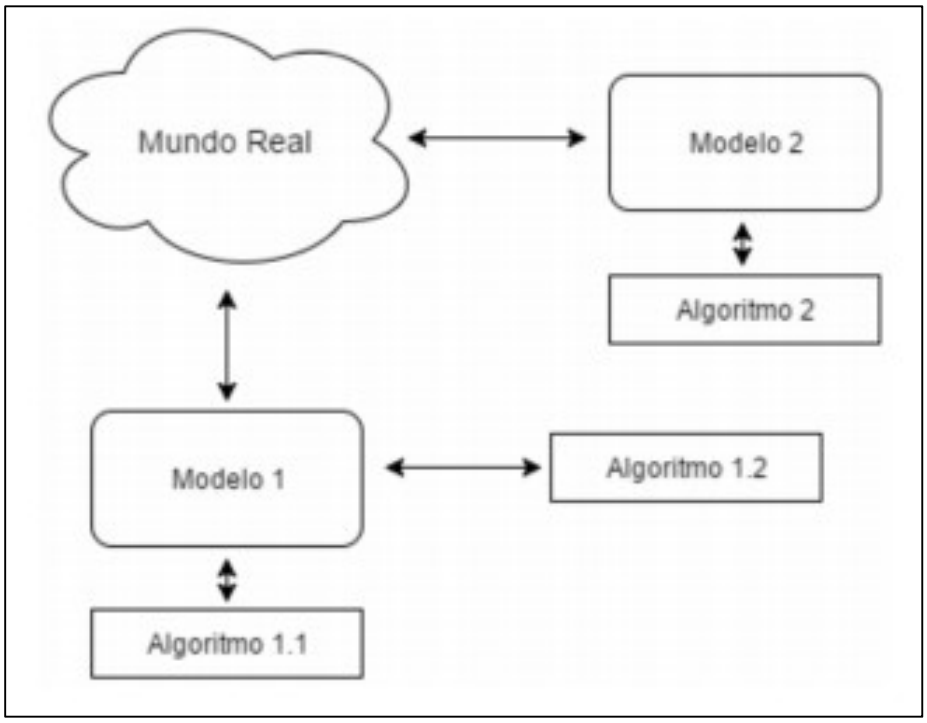

Fonte: SMOLA, 2008.

De forma a assegurar a precisão e a fidelidade dos modelos em relação aos fenômenos estudados, é imperativo que todos eles sejam analisados e avaliados para serem validados, sendo que tal tarefa se dá de acordo com cada critério relativo ao próprio cenário do problema e deve-se atentar ao objetivo final para que tal solução possa ser atingida.

2.1.1 PYTHON

As linguagens de programação são divididas em níveis, o Python é uma linguagem de programação de alto nível (HLL - *High Level Language*) que tem por

objetivo otimizar a velocidade de desenvolvimento. Trata-se de um software simples, flexível e de uso fácil por ser de código aberto, o que torna a compreensão e modificação algo simples. O Python é muito bem equipado, fornecendo ao usuário ferramentas que se adequam às metodologias de softwares modernos e permite que um único código seja utilizado várias vezes. (LUTZ, MARK, 2006).

2.1.1.1 BIBLIOTECAS

O termo *Data Science* vem sendo muito utilizado no ramo da programação, e relacionado a ele é encontrado o uso de pacotes para análise dos dados que estão sendo estudados. A biblioteca Pandas é um desses pacotes que de maneira interativa realiza a análise de dados e posteriormente manipula os mesmos, por meio da combinação da matemática da matriz utilizada, com o banco de dados fornecido e o processamento de planilhas. (LUBANOVIC, BILL, 2014).

Existem diversas bibliotecas disponíveis para uso dentro da linguagem Python, e suas funções geralmente são voltadas para a minimização do uso de códigos complexos. Uma biblioteca importante voltada para o *Machine Learning* é a *SciKit Learn*, que consiste em um grupo de pacotes científicos que visam o armazenamento, a modelagem e a classificação de algoritmos. (GÉRON, AURÉLIEN, 2019).

2.2 PARADIGMAS DE APRENDIZADO

É sabido que no processo de aprendizagem a Indução é uma forma de inferir de maneira lógica a respeito de exemplos em particular. O processo indutivo é caracterizado pelo raciocínio que generaliza um conceito específico conforme é possível observar na descrição abaixo:

> Na indução um conceito é aprendido e efetuando-se a inferência indutiva sobre os exemplos apresentados. Portanto, as hipóteses geradas através de inferência indutiva podem não preservar a verdade, mas mesmo assim a inferência indutiva é um dos principais métodos utilizados para derivar conhecimento novo e predizer eventos futuros [...] Apesar de a indução ser o recurso mais utilizado pelo cérebro humano para derivar conhecimento novo, ela deve ser utilizada com cautela, pois se

> o número de exemplos for insuficiente ou inadequado os resultados obtidos podem ser de pouco valor. (MONARD; BARANAUSKAS, 2003 p. 32).

Segundo Monard e Baranauskas (2003) esse tipo de aprendizado acontece após a utilização de exemplos que não fazem parte do processo em si, ou seja, as informações vêm de um ambiente externo ao sistema de aprendizado. O processo de aprendizado indutivo pode ser dividido em duas categorias: não supervisionado e supervisionado.

2.2.1 Aprendizado Indutivo Supervisionado e Não Supervisionado

No aprendizado não supervisionado, o algoritmo precisa quantizar cada atributo sem possuir conhecimento de sua classe na base de dados de treino (WITTEN, I; FRANK, E, 2005), ou seja, o algoritmo verifica e compara os exemplos dados e, a partir de tentativas e erros, agrupa, em classes, os registros que se relacionam.

Já no aprendizado supervisionado, as classes são conhecidas e levadas em conta na discretização dos atributos (WITTEN, I; FRANK, E, 2005). Sendo assim, os exemplos são determinados por dados e características, os quais são fornecidos previamente e o algoritmo tem função de criar uma forma de classificação que possa auxiliar na determinação de novas classes de exemplos ainda não tratados. Na Figura 2 é possível observar a hierarquia do aprendizado mencionado.

Figura 2 - Hierarquia do Aprendizado

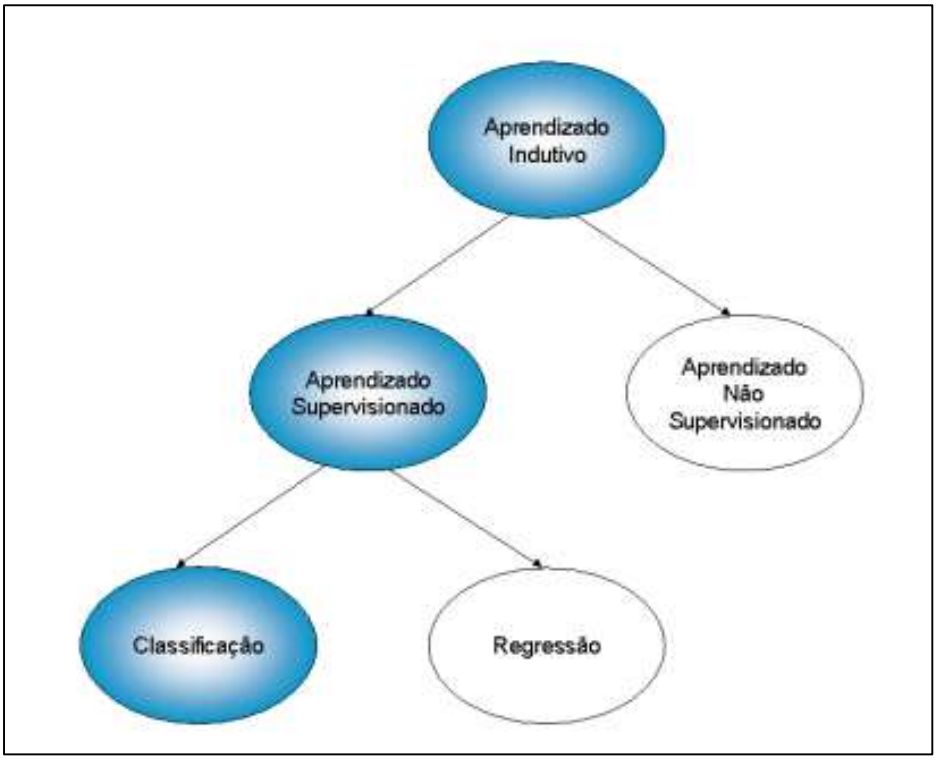

Fonte: Monard e Baranauskas (2003)

Os paradigmas de aprendizagem são vários segundo, Aha, Kibler e Albert (1991), dentre os quais se relacionam: Estatístico, Genético, Baseado em Exemplos, Conexionista, Simbólico dentre outros. E para um melhor entendimento serão conceituados em seguida.

- **Paradigma Estatístico** – São métodos baseados em parâmetros, modelados os quais têm como saída valores relacionados aos parâmetros previamente estabelecidos por modelos iniciais dos dados disponíveis. De uma forma geral, utiliza a estatística para encontrar alguma proximidade dos conceitos do algoritmo;
- **Paradigma Genético** – Nesse caso o paradigma se baseia em uma população de exemplares já classificados que são utilizados para predizerem as respostas, e os exemplares muito diferentes são

descartados enquanto os que mais se aproximam do modelo são utilizados e acabam produzindo variações de si mesmos;

- **Paradigma Baseado em Exemplos** – A técnica utilizada nesse caso é a da similaridade, onde um exemplar conhecido e já classificado serve como base para novas classificações em que a semelhança é a principal ferramenta utilizada. Também conhecido como *Lazy,* para que esse tipo funcione é preciso que os exemplos, a serem utilizados como modelo de comparação, sejam mantidos na memória de forma a serem buscados sempre que uma nova classificação se faça necessária;
- **Paradigma Conexionista** – O modelo biológico do sistema nervoso encontrado nos seres humanos é formado por redes neurais que se explicam por meio de construções matemáticas profundamente conectadas, daí o nome Conexionismo e resumidamente é a capacidade conjunta disponível para resolver problemas;
- **Paradigma Simbólico** – O modelo Simbólico se estrutura no princípio da construção de símbolos para análise de exemplos e seus pares. Para que isso aconteça geralmente são postuladas expressões lógicas, semântica, regras ou árvore de decisões que auxiliam a soluções dos problemas propostos.

2.3 ALGORÍTMO

Os Algoritmos são uma sequência de raciocínio lógico, operações e instruções parametrizadas de forma lógica e finita cujo objetivo principal é solucionar um problema eminente. Estes podem se apresentar na forma matemática, textual e até mesmo visual, sendo obrigatório conter uma entrada de dados, o processamento destes e uma saída de informação.

As técnicas de *Machine Learning* utilizam-se dos algoritmos para realizarem suas tarefas e suas aplicações são um ativo valioso para todas as áreas. No entanto, os algoritmos utilizados ainda não são capazes de apresentar universalidade em seu

desempenho sendo necessária a criação/desenvolvimento de algoritmos específicos para cada situação ou problema sendo necessário, em muitas situações, que uma avaliação seja feita. (SANTOS, 1994).

2.3.1 Técnicas de aprendizagem

Segundo Weiss e Indurkya (1998) ao se comparar algoritmos não se podem levar em consideração apenas valores e saídas numéricas, pois dessa forma não fica evidente a eficácia de um algoritmo em relação a outro. É preciso cruzar todas as informações disponíveis de ambos para que se possa chegar a um resultado satisfatório que auxilie na tomada de decisão.

2.3.1.1 Regressão Linear

O modelo de regressão linear conforme citado por Almeida (2014), é o estudo de uma variável dependente utilizada para conhecer seu comportamento em relação a uma ou mais variáveis independentes, tendo como objetivo estimar e prever possíveis valores para a variável resposta. A regressão linear procura encontrar a explicação para um certo fenômeno estudado a partir de dadas premissas identificadas a partir de um contexto específico.

Existem dois tipos de regressão linear: simples e múltipla. Na regressão linear simples, a relação entre duas variáveis pode ser representada por uma linha reta para estabelecer uma relação causal direta. Por outro lado, a regressão linear múltipla é uma coleção de técnicas estatísticas usadas na construção de modelos para descrever a relação entre as várias variáveis explicativas em um determinado processo.

Compreendido por Angrist e Pischke (2009), os modelos de regressão conseguem ser vistos como um dispositivo computacional para o apreço das divergências entre um grupo de tratados e um de controle, com ou sem covariadas. Conforme citado

por Charnet (2008) existem características comuns entre elas, como a busca pelas relações de causa e efeito das variáveis e determinar uma explicação sobre uma população a partir da amostra. Essas características têm como objetivo estimar os parâmetros, realizar a seleção das variáveis, e a eliminação de variáveis.

2.3.1.2 Árvore de Decisão

Outra técnica muito utilizada na área do *Machine Learning* é a árvore de decisão. Como cita Baranauskas e Monard (2003), essa técnica consiste em uma estrutura de dados definida em “nó folha” e “nó de decisão”. O primeiro corresponde à uma classe e o outro possui um teste sobre algum parâmetro e, para cada resultado deste teste, segue-se para outra ramificação da árvore, seguindo a estrutura e seu nível seguinte, até alcançar os nós finais. (BARANAUSKAS; MONARD, 2003). A Figura 3 representa um exemplo prático de árvore de decisão, feito para avaliar se um paciente está saudável ou doente:

Figura 3 -Exemplo de Árvore de Decisão

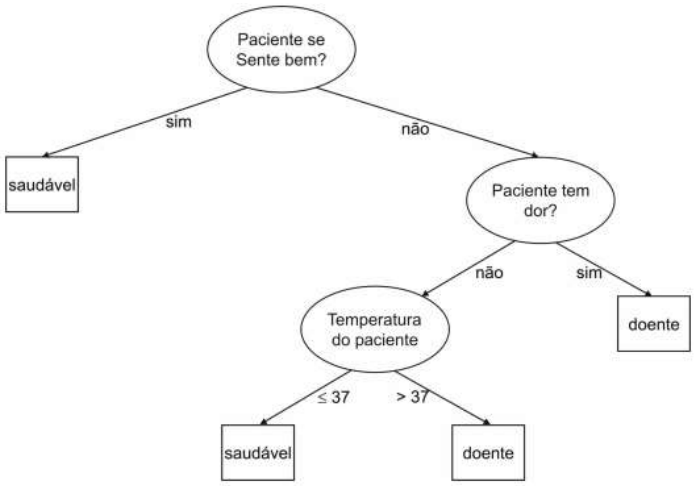

Fonte: Baranauskas; Monard (2003)

Além da facilidade de compreensão, existe uma outra característica incitante em relação à essa técnica. Como citado por (BARANAUSKAS; MONARD, 2003),

para cada ramificação da árvore é formada uma nova regra de decisão, que pode não estar conectada às outras, impossibilitando uma sobreposição de certa regra sobre o espaço das demais.

2.3.1.2.1 *Random Forest* (RF)

O *Random Forest* traduzido para o português como Floresta Randômica, recebe este nome por levar em consideração em sua análise a combinação de diversas arvores de decisão, o algoritmo é definido como “combinação de preditores de árvore, de modo que cada árvore depende dos valores de um vetor aleatório amostrado de forma independente e com a mesma distribuição para todas as árvores na floresta.” (Breiman, 2001, p.5).

No *Random Forest* as amostras são divididas em diversas amostras menores, e a partir de cada sub amostra são selecionados através de formas específicos. Mediante desta seleção o algoritmo é capaz de gerar distintas árvores de decisão. Este algoritmo, conforme citado pelos autores (ROKACH; MAIMON, 2005) tem como objetivo aumentar a acurácia da classificação e contribuir na construção de uma árvore que represente expressamente a estrutura do conjunto de dados.

2.3.1.3 *Support Vector Machines* (SVM)

O SVM, Máquina de Vetores de Suporte em português, é um método com base na teoria de aprendizagem estatística e na otimização matemática (VAPNIK, 1995). Seu algoritmo transforma os dados de treino em dados com alta dimensionalidade e procura um hiperplano de separação (SANTANA, 2015), ou seja, ele traça uma fronteira que separa uma classe da outra em um espaço métrico. O SVM encontra este hiperplano por meio de vetores de suporte e margens, que são definidas pelos vetores (HAN; KAMBER; PEI, 2011). Sendo assim, o SVM classifica os dados em dois grupos ao criar fronteiras separando os dados por meio de um hiperplano (caso os dados sejam linearmente separáveis) e trabalha com a

maximização da margem, onde a fronteira mais distante dos dados iniciais é a melhor. A Figura 4 mostra um hiperplano largo e um estreito, e como eles separa as duas classes do problema.

Figura 4 - Hiperplano com margem estreita e larga

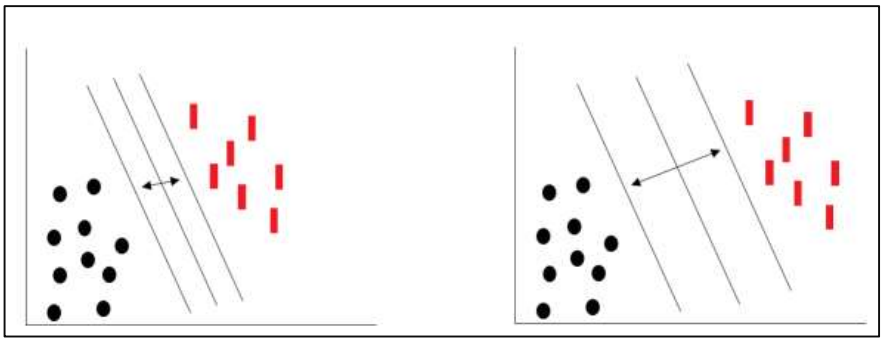

Fonte: Han; Kamber; Pei (2011)

2.3.1.4 *Redes Neurais*

Uma rede neural tem o objetivo de moldar a forma pela qual o cérebro executa uma tarefa. Este modelo é constituído por nós, denominados como neurônios que são interconectados entre si e seus resultados dependem das características destes neurônios e pela forma que eles estão dispostos.

O modelo foi criado por McCulloch e Pitts (1943) com o intuito de criar um modelo computacional que pareça com o funcionamento das células de um cérebro humano. Conforme citado pelos autores Braga, Carvalho, Ludermir (2000) as Redes Neurais pretendem representar as funções das redes biológicas, implementando seu comportamento básico e sua dinâmica.

As redes neurais dispõem de um algoritmo de aprendizado que executa a tarefa de ajustar os pesos de suas conexões (BRAGA; CARVALHO; LUDEMIR, 2000, cap. 2), sendo assim o modelo busca melhorar gradativamente o seu desempenho através da sua capacidade de aprender através de exemplos.

2.3.2 Validação cruzada *k-fold*

A validação cruzada é um método estatístico de avaliação de desempenho mais completo do que uma simples divisão entre base de treino e base de teste, pois os dados são divididos repetidamente e vários modelos são treinados (MULLER; GUIDO, 2017). No método da validação cruzada *k-fold, k* é o número, definido pelo usuário, que definirá em quantas partes a base de dados será repartida, cada parte é chamada de dobra (tradução para *fold).*

Como explicam Muller e Guido (2017), após dividir a base em *k folds,* uma sequência de modelos são treinados, sendo que o primeiro modelo utilizará o *fold* de número 1 para teste e todos os restantes para treino (do 2 até o *k*), o segundo modelo utilizará o *fold* 2 para teste e todos os restantes para treino (1 e todos do 3 até o *k),* e assim se repete para todos os *folds*. A precisão é calculada para cada um deles e, no final, calcula-se a média de todos os *k folds,* e esta é considerada como a precisão do modelo – chamado de *score*. A Figura 5 é uma representação visual da validação cruzada *k-fold.*

Figura 5 – Exemplo de validação cruzada 5-*fold*

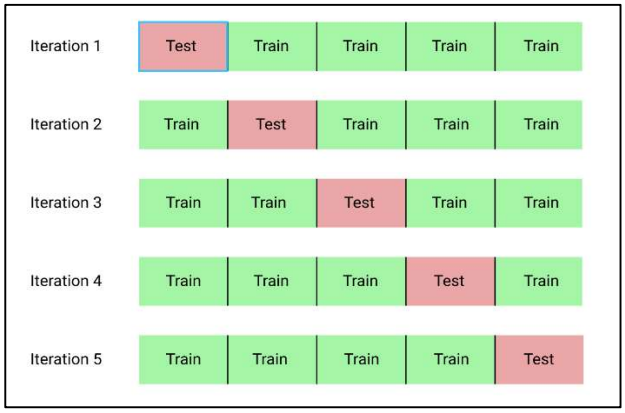

Fonte: Autor desconhecido

2.4 TRATAMENTO DE DADOS

Para que se possa trabalhar na ciência da computação, como o *Machine Learning*, antes de aplicar as técnicas, é preciso reorganizar os dados brutos (ZHANG, 2003), pois é necessário considerar o fator erro que torna indispensável a tratativa dessas informações. Ou seja, para que haja uma concreta probabilidade de utilização desses dados para a aprendizagem de máquina é necessário um pré-processamento das entradas de dados, também conhecido como limpeza de dados. (MULLER; FREYTAG, 2005).

2.4.1 Variáveis *Dummy*

Os dados de uma base nem sempre são numéricos, as vezes eles podem ser categóricos, por exemplo, numa variável “cor de olho” as respostas seriam textos como “preto” e “verde”, então é necessário a utilização de algum método para transformar esse dado não-numérico em número, mas apenas rotulá-los de 1 até *n* implica em uma relação ordinária (não existente para variáveis categóricas) (ZHENG. A; CASARI, A, 2018). Uma das técnicas que pode ser usada para isso é chamada de *Dummy Encoding*, que faz uso das variáveis *dummy.*

Como explicam Zheng e Casari (2018), as variáveis *dummy* utilizam de apenas 0 e 1 para dar informações sobre um dado e seu valor categórico, sendo que o 0 é usado para “falso” e 1 para “verdadeiro”. A variável a ser transformada é desmembrada no mesmo número de valores únicos que possuir e a coluna representada pelo valor correto será preenchida com 1 e as demais com 0. Para melhor visualização, a Figura 6 ilustra a transformação de dados de cor para variáveis *dummy.*

Figura 6 – Transformação de variáveis categóricas em variáveis *dummy*

Original	
ID	Cor
1	Branco
2	Azul
3	Rosa
4	Roxo
5	Verde

Variáveis *Dummy*					
ID	Branco	Azul	Rosa	Roxo	Verde
1	**1**	0	0	0	0
2	0	**1**	0	0	0
3	0	0	**1**	0	0
4	0	0	0	**1**	0
5	0	0	0	**0**	**1**

Fonte: Elaborado pelos autores

2.5 VAREJO

Segundo Santos e Costa (1997) é praticamente impossível validar um conceito que englobe o Varejo em si, pois este possui “características próprias e diferenciadas do ponto de vista acadêmico e analítico” absorvendo diversos ramos de atividades que não podem ser comparadas entre si. Dentre essas atividades é possível citar: lojas de eletrodomésticos; lojas de departamentos; lojas de vestuário (roupas, calçados, cama, mesa, banho, copa e cozinha); lojas de conveniência; supermercados e hipermercados; dentre outros.

As autoras afirmam que o setor de Varejo é um setor enorme que adiciona vida à economia global sendo que nacionalmente também se faz uma atividade muito importante economicamente avaliando. De acordo com o Instituto Brasileiro de Geografia e Estatística (IBGE, 1997 apud SANTOS; COSTA, 1997), o setor varejista é responsável por quase 20% dos empregos nacionais (permeando 9 milhões de empregos, aproximadamente) sendo que 39% de tais empresas são do ramo de comercio – é incontestável a contribuição do setor para a economia brasileira.

Sendo um setor diversificado onde sua atuação depende não só da pluralidade de produtos, clientes e de fornecedores, mas também da qualidade e variedade de seus serviços conforme exposto no trecho:

Embora tenha sido levantado exemplos voltados ao dia a dia das lojas é sabido também que tal setor tem em sua operação uma gama de informações a

serem trabalhadas, verificadas e guardadas e, dessa forma, o *Machine Learning* se faz uma ferramenta perfeita cuja aplicação se torna atual e indispensável para o setor do varejo.

> No varejo [...] a operação demanda ações praticamente em tempo real a fim de compreender e atingir resultados tangíveis para a organização. A evolução recente nos últimos anos e grande disseminação de técnicas de Data Science e *Machine Learning* permitiram novas aplicações em diversas áreas, e com o varejo não está sendo diferente. Dado o volume e velocidade na geração de informações pela interação constante com os consumidores através de interfaces digitais, o varejo [...] torna-se um campo rico para pesquisas e aplicações de modernas técnicas de análise de dados. (JUSTO, 2020, p. 1)

Para Justo (2020), em pesquisa realizada por ele com o intuito de verificar a previsão de erro, foi possível realizar o levantamento dos dados utilizados como amostra referente a dois anos de operação da empresa onde estavam representadas as vendas diretas e as vendas realizadas por meio de terceiros e parceiros nos quais é possível observar na Figura 7:

Figura 7 - Série de dados levantados

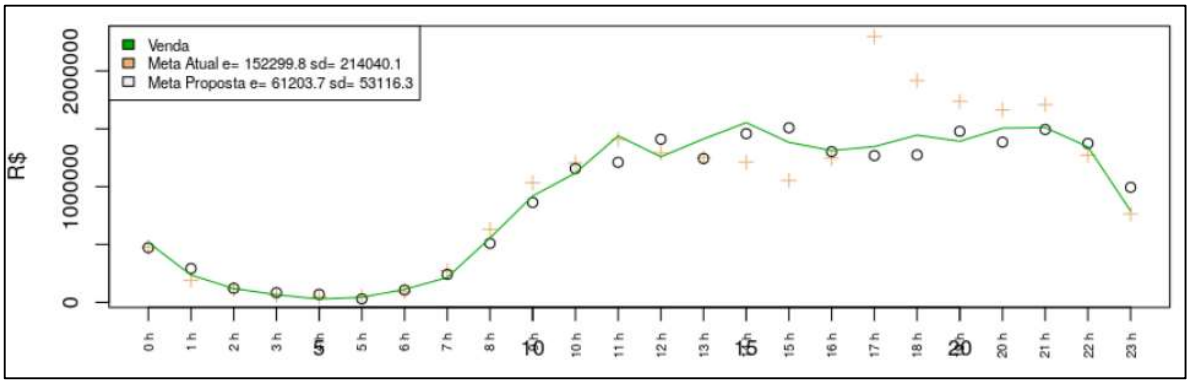

Fonte: Justo, 2020.

Segundo o autor, a linha sólida demonstra a venda em um determinado dia; A meta projetada (atualmente através de planilhas) é representada por um marcador "+" e a meta proposta, neste caso utilizando o algoritmo SVM, através do marcador "o". Por meio da aplicação de *Machine Learning*, procurou-se levantar uma métrica

com o objetivo de comparar os modelos existentes e os modelos propostos, as quais foram:

> 1. Erro de previsão: diz respeito à média das diferenças entre valor real e valor previsto, representado no gráfico acima como e.
> 2. Desvio padrão das diferenças: a operação do negócio diz respeito a tomar ações quando ocorrem variações não esperadas ocorrem. Sendo assim, busca-se na meta uma maior linearidade nas diferenças. Por isto, utilizou-se inicialmente o cálculo do desvio padrão, demonstrando que quanto menor, melhor será a previsão. (JUSTO, 2020, p. 2).

Os resultados obtidos por ele por meio do modelo auto regressivo apresentaram uma melhoria de cerca de 24% em respeito à previsão de erro; e ao utilizar uma outra técnica, chamada de *Suport Vector Machine* (SVM), foi atingido redução de 41% no erro de previsão. Os desvios padrão também apresentaram redução equivalente em ambos os casos.

Em outro estudo de caso realizado por Roza (2016) cujo objetivo era buscar o perfil do cliente mais propenso a comprar um produto em específico:

> O primeiro problema, apresentado na Seção 2.1.1, consiste em buscar o perfil de cliente mais propenso a comprar um determinado produto. A solução desse problema se resume em treinar um classificador utilizando o histórico de vendas das lojas. Para tanto se decidiu utilizar os atributos Região, Sexo e Faixa etária como variáveis de saída. Analisando o conjunto de exemplos disponíveis se percebeu que o campo Faixa etária possuía muitas classes, sendo que algumas apresentavam representatividade muito baixa. (ROZA, FELIPE, 2016, p. 36)

Primeiro foram levantados os dados de acordo com a faixa etária, conforme Figura 8:

Figura 8 - Distribuição por faixa etária

Classe	Quantidade de exemplos
25 a 34	45120
35 a 44	28061
15 a 24	27600
45 a 55	17846
55 a 65	9610
65+	1856

Fonte: Roza, 2016.

Depois para facilitar a saída de dados foi realizado um reagrupamento de classes, conforme Figura 9:

Figura 9 - Reagrupamento por faixa etária

Classe	Quantidade de exemplos
35+	57373
25 a 34	45120
24-	27600

Fonte: Roza, 2016

Após o reagrupamento foram parametrizadas variáveis de saída e de entrada com os respectivos números de classes, conforme Figura 10 e 11:

Figura 10 - Variáveis de saída

Atributo	Número de classes
Sexo	2
Faixa Etária	3
Região	5

Fonte: Roza, 2016

Figura 11 - Variáveis de entrada

Atributo	Número de classes
Fabricante Produto	21
Grupo Produto	35
Subgrupo Produto	106

Fonte: Roza, 2016

Segundo Roza (2016) os modelos de aprendizagem aplicados foram "Árvore de Decisão" e "*k-Nearest Neighbors".*

> "Se optou por treinar um modelo para cada um dos atributos de saída, já que a necessidade da empresa é de realizar as análises separadamente, de modo que se obteve 3 modelos para cada algoritmo utilizado. O conjunto de exemplos foi então dividido em dois subconjuntos, um para treinamento e um para teste, sendo que a proporção utilizada foi de 80/20, respectivamente, totalizando 104.074 exemplos para treinamento e 26.019 exemplos para teste. " (ROZA, FELIPE, 2016, p 37-38).

Segundo o autor os resultados obtidos para tal experimento estão relacionados na Figura 12:

Figura 12 - Taxas de acerto para técnica *k-Nearest Neighbors*

Atributo	$k = 10$	$k = 50$	$k = 100$	$k = 200$
Sexo	0.816941	0.824464	0.835966	0.836465
Região	0.638995	0.680149	0.681579	0.681298
Faixa Etária	0.423998	0.451401	0.458088	0.456666

Fonte: Roza, 2016

Os resultados obtidos para *k-Nearest Neighbors,* segundo o autor, são os para K=100, sendo que estes foram escolhidos para comparação com os resultados obtidos por meio da técnica "árvore de decisão" representado pela Figura 13.

Figura 13 - Taxas de acerto para técnica árvore de decisão

Atributo	Acerto DT	Acerto KNN
Sexo	0.835889	0.835966
Região	0.681733	0.681579
Faixa Etária	0.458011	0.458088

Fonte: Roza, 2016

Diante das técnicas apresentadas e em função dos algoritmos utilizados, os quais possibilitaram a modelagem dos processos bem como por meio de treinamentos prévios realizados visando solucionar os problemas de forma automatizada por meio de *Machine Learning,* foi possível exemplificar a metodologia utilizada para a aplicação do *Machine Learning* no setor de varejo.

2.6 DICIONÁRIO DE DADOS DA *BIGMART RETAIL*

A base de dados usada – dos registros de vendas da *BigMart Retail* - contém 8523 registros e cada um deles possui 12 atributos, que são os seguintes:

- *Item_Identifier* – Número de identificação único do produto;

- *Item_Weight* – Peso do produto;
- *Item_Fat_Content* – Classificação do produto relacionada a sua concentração de gordura;
- *Item_Visibility* – A porcentagem da área de visibilidade de todos produtos semelhantes em uma loja;
- *Item_Type* – Categoria do produto;
- *Item_MRP* – Preço máximo, definido pelo fabricante, que um produto pode ser vendido na Índia;
- *Outlet_Indentifier* – Número de identificação da loja;
- *Outlet_Establishment_Year* – Ano de fundação da loja;
- *Outlet_Size* – Classificação da loja quanto ao seu tamanho (área); *Outlet_Location_Type* – Relacionado ao tamanho da cidade que a loja se encontra;
- *Outlet_Type* – Supermercado ou loja de conveniência;
- *Item_Outlet_Sales* – Número de vendas do produto em uma loja.

3. METODOLOGIA

Neste trabalho, será feita uma comparação entre técnicas de *Machine Learning,* que serão utilizadas na previsão de vendas em uma empresa de varejo, com objetivo de descobrir qual é mais eficaz. Para realização da pesquisa, as seguintes tarefas serão executadas:

1) Foi selecionada no site *kaggle.com* uma base de dados sobre vendas de produtos da empresa *BigMart Retail*, grande rede de supermercados da Índia. A base foi então baixada e será utilizada para criar o modelo de predição;
2) Foi escolhido um *software* que nos permita criar algoritmos na linguagem *Python*;
3) Os dados serão carregados e analisados antes de criar e treinar o modelo. Caso sejam encontrados exemplos com dados inconsistentes ou faltantes, será considerada a média de todos os exemplos - do parâmetro em questão – existentes na base utilizada;
4) Criar um algoritmo em que serão aplicadas todas as técnicas escolhidas: Regressão Linear, *Random Forest,* Redes Neurais e SVM;

5) As funções das técnicas – já existentes na biblioteca *scikit-learn* - serão usadas e a base será treinada em uma validação cruzada com 10 *folds*;
6) A técnicas serão avaliadas e comparadas pela média de pontuação (para os 10 *folds*) que a própria função da validação cruzada fornece, chamado de *score.*

4. ANÁLISE DOS RESULTADOS

Foi realizado o *download* da base de dados históricos de vendas da *BigMart Retail*, no site *Kaggle*. A base foi carregada para o *Spyder* (https://www.spyder-ide.org/), um ambiente de desenvolvimento integrado (IDE) para programação na linguagem *Python.* Criou-se, a partir dos dados carregados, um *dataframe* com doze variáveis para cada um dos registros, sendo onze deles variáveis previsores e um alvo - número de vendas. Foi decidido que se aplicariam os estudos em toda a base de dados, ou seja, nenhuma linha seria retirada do *dataframe*.

A Figura 14 mostra as seis primeiras linhas do *dataframe* e suas colunas:

Figura 14 - Cabeçalho do *dataframe* criado

Index	Item_Identifier	Item_Weight	Item_Fat_Content	Item_Visibility	Item_Type	Item_MRP	Outlet_Identifier	tlet_Establishment_Y	Outlet_Size	itlet_Location_Ty	Outlet_Type	Item_Outlet_Sales
0	FDA15	9.3	Low Fat	0.0160473	Dairy	249.809	OUT049	1999	Medium	Tier 1	Supermarket Type1	3735.14
1	DRC01	5.92	Regular	0.0192782	Soft Drinks	48.2692	OUT018	2009	Medium	Tier 3	Supermarket Type2	443.423
2	FDN15	17.5	Low Fat	0.0167601	Meat	141.618	OUT049	1999	Medium	Tier 1	Supermarket Type1	2097.27
3	FDX07	19.2	Regular	0	Fruits and Vegetables	182.095	OUT010	1998	nan	Tier 3	Grocery Store	732.38
4	NCD19	8.93	Low Fat	0	Household	53.8614	OUT013	1987	High	Tier 3	Supermarket Type1	994.705
5	FDP36	10.395	Regular	0	Baking Goods	51.4008	OUT018	2009	Medium	Tier 3	Supermarket Type2	556.609

Fonte: Elaborado pelos autores

Para melhor conhecimento da base e identificação de variáveis que mais se correlacionam com o nosso alvo – número de vendas -, foi feita uma análise exploratória nos dados, antes que o pré-processamento fosse feito. Foi possível descobrir que a base possui 8523 registros, sendo 1559 diferentes produtos e 3873 dados vazios – 1463 registros sem peso do item e 2410 sem o tamanho da loja que vendeu -, como mostra a Figura 15.

Figura 15 - Algoritmo para verificar dados faltantes e ID's duplicados

```
In [11]: train.isnull().sum()
Out[11]:
Item_Identifier                 0
Item_Weight                  1463
Item_Fat_Content                0
Item_Visibility                 0
Item_Type                       0
Item_MRP                        0
Outlet_Identifier               0
Outlet_Establishment_Year       0
Outlet_Size                  2410
Outlet_Location_Type            0
Outlet_Type                     0
Item_Outlet_Sales               0
dtype: int64

In [12]: idsUnicos = len(set(train.Item_Identifier))
    ...: idsTotal = train.shape[0]
    ...: idsDupli = idsTotal - idsUnicos
    ...: print("Existem " + str(idsDupli) + " IDs duplicados de " + str(idsTotal) + " do total de entradas")
    ...: print('Existem {} produtos diferentes na base.'.format(idsUnicos) )
Existem 6964 IDs duplicados de 8523 do total de entradas
Existem 1559 produtos diferentes na base.
```

Fonte: Elaborado pelos autores

Foi feita uma análise exploratória dos dados e alguns gráficos foram plotados para que os resultados da análise fossem visualizados mais facilmente, como é mostrado nos exemplos abaixo. Na Figura 16, foi feito um gráfico para medir a correlação entre os atributos numéricos, e foi possível notar que a coluna *Item_MRP* tem forte correlação com a coluna *Item_Outlet_Sales:*

Figura 16 - Gráfico de correlação entre variáveis numéricas

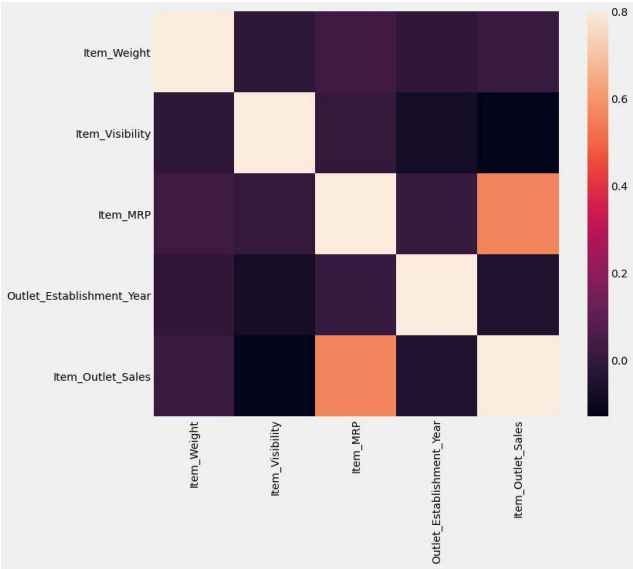

Fonte: Elaborado pelos autores

Então, no gráfico da Figura 17 foi feita uma análise entre os registros destas duas colunas e, pode-se observar, que há um padrão: produtos com maior Item_MRP conseguem atingir um maior número de vendas.

Figura 17 - Gráfico de comparação Item_MRP x vendas

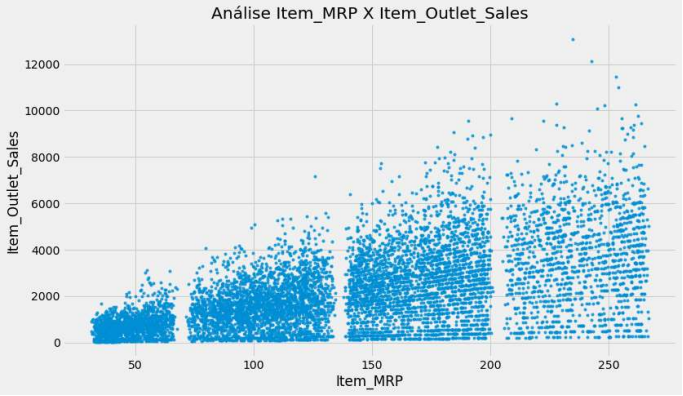

Fonte: Elaborado pelos autores

O gráfico da Figura 18 evidencia que a coluna *Item_Visibility* também pode ter influência nas vendas, pois itens com muita exposição estão com poucas vendas nos registros.

Figura 18 - Gráfico de comparação visibilidade x vendas

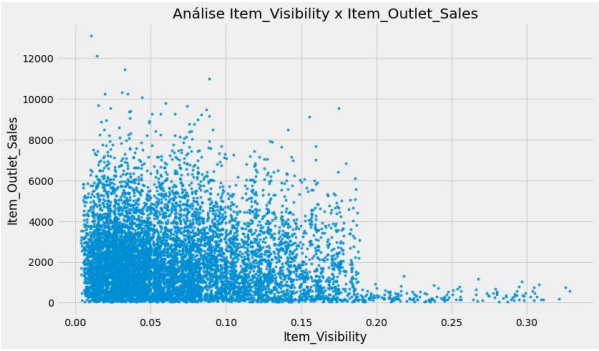

Fonte: Elaborado pelos autores

Com a análise exploratória feita e os gráficos analisados, é dado início ao pré-processamento dos dados. Os 1463 registros sem dado de peso foram completados com a média dos produtos de mesmo ID, pois, como se trata do mesmo produto, o

peso se repete e a média resulta no valor real. Os 2.410 registros de lojas sem tamanho especificado também foram completados com base nos registros de outras lojas do mesmo tipo. Para melhor visualização, a Figura 19 ilustra o antes e depois dessa substituição no caso dos registros que estavam sem peso dos produtos.

Figura 19 – Antes e depois de substituir dados de peso faltante

ANTES

Item_Identifier	Item_Weight
DRA24	19.35
DRA24	nan
DRA24	19.35
DRA24	nan
DRA24	19.35
DRA24	19.35
DRA24	19.35
DRA59	8.27
DRA59	8.27
DRA59	8.27
DRA59	8.27
DRA59	nan
DRA59	nan
DRA59	8.27
DRA59	8.27

DEPOIS

Item_Identifier	Item_Weight
DRA24	19.35
DRA24	19.35
DRA24	19.35
DRA24	19.35
DRA24	19.35
DRA24	19.35
DRA24	19.35
DRA59	8.27
DRA59	8.27
DRA59	8.27
DRA59	8.27
DRA59	8.27
DRA59	8.27
DRA59	8.27
DRA59	8.27

Fonte: Elaborado pelos autores

Na análise exploratória, também foi descoberto que algumas variáveis possuíam o mesmo valor, porém estavam escritos de forma diferente, como é o caso da quantidade de gordura no produto. Além de "*Low Fat*", alguns registros possuíam valor "*low fat*" (a diferença entre maiúsculas e minúsculas os tornam diferentes) e outros "LF", já os produtos de valor "*Regular*" também estavam duplicados com o valor "reg". Os valores foram então padronizados para "*Low Fat*" e "*Regular*". Além disso, alguns produtos não eram comestíveis, mas ainda assim estavam classificados como "*Low fat*", então foi preciso identificar os produtos não comestíveis e alterar o seu valor de *Item_Fat_Content* para um novo valor criado ("*Non-Consumable"* que é "não consumível" em inglês). A Figura 20 mostra como essas alterações foram feitas no *Spyder* e o resultado final após as mudanças.

Figura 20 - Código para padronizar valores e identificar produtos não comestíveis

```
In [17]:
   ...: train['Item_Type_Combined'] = train['Item_Identifier'].apply(lambda x: x[0:2])
   ...: train['Item_Type_Combined'] = train['Item_Type_Combined'].map({'FD' : 'Food',
   ...:                                                                'DR' : 'Drinks',
   ...:                                                                'NC' : 'Non-Consumable'})
   ...:
   ...: # unificando as categorias de gordura no alimento
   ...: train['Item_Fat_Content'] = train['Item_Fat_Content'].replace({'LF':'Low Fat',
   ...:                                                               'reg':'Regular',
   ...:                                                               'low fat':'Low Fat'})
   ...:
   ...: print(train['Item_Fat_Content'].value_counts())
   ...:
   ...: # substituindo a categoria de gordura nos produtos que não são alimentícios
   ...: train.loc[train['Item_Type_Combined']=='Non-Consumable', 'Item_Fat_Content'] = 'Non-Consumable'
   ...: train['Item_Fat_Content'].value_counts()
Low Fat    5517
Regular    3006
Name: Item_Fat_Content, dtype: int64
Out[17]:
Low Fat           3918
Regular           3006
Non-Consumable    1599
Name: Item_Fat_Content, dtype: int64
```

Fonte: Elaborado pelos autores

Para finalizar o pré-processamento, são excluídas as colunas que não fazem diferença para números de vendas finais do produto, como seu ID e o ID da loja que vendeu. As variáveis categóricas – de valores não numéricos - recebem um valor numérico de referência e são transformadas em variáveis *Dummy.*

Para que seja possível analisar como o modelo se sai melhor, a base de dados vai ser treinada em duas condições diferentes: com todos os registros padronizados numa mesma escala e não-padronizados (da mesma maneira que foram baixados). Para que o SVM funcione os dados devem estar padronizados, por isso não serão apresentados os resultados para dados não padronizados.

Então, as funções de cada técnica são importadas e a aplicamos na base de dados, como mostra a Figura 21

Figura 21 - Código para aplicação das técnicas de aprendizado

```
# importando para validação cruzada
from sklearn.model_selection import cross_val_score

# REGRESSÃO LINEAR
from sklearn.linear_model import LinearRegression
lr = LinearRegression()

resultado1 = cross_val_score(lr, train, target, cv=10)
resultado_lr = resultado1.mean()
desvio_lr = resultado1.std()


# RANDOM FOREST
from sklearn.ensemble import RandomForestRegressor
rf = RandomForestRegressor(n_estimators=100)

resultado2 = cross_val_score(rf, train, target, cv=10)
resultado_rf = resultado2.mean()
desvio_rf = resultado2.std()


# REDES NEURAIS
from sklearn.neural_network import MLPRegressor
nn = MLPRegressor(hidden_layer_sizes=(18,18))

resultado3 = cross_val_score(nn, train, target, cv=10)
resultado_nn = resultado3.mean()
desvio_nn = resultado3.std()


# SVM
from sklearn.svm import SVR
svr = SVR(kernel='rbf')

resultado4 = cross_val_score(svr, train, target, cv=10)
resultado_svm = resultado4.mean()
desvio_svm = resultado4.std()
```

Fonte: Elaborado pelos autores

O programa então retorna, armazenado na variável correspondente, o valor da média dos 10 *folds*. A tabela da Figura 22 foi montada com o valor de cada *fold* e a média das técnicas está na última linha.

Figura 22 - Resultado de cada um dos *folds* usados na pesquisa

ESCALA PADRONIZADA				
	Regressão Linear	Random Forest	Redes Neurais	SVM
Fold 1	0,560550	0,552100	0,607025	0,592075
Fold 2	0,582245	0,586412	0,624589	0,613217
Fold 3	0,542665	0,518636	0,570620	0,574643
Fold 4	0,567182	0,580859	0,605797	0,609383
Fold 5	0,509734	0,491353	0,537319	0,550427
Fold 6	0,577654	0,570237	0,611420	0,594144
Fold 7	0,578871	0,570572	0,622949	0,616076
Fold 8	0,556788	0,543405	0,594918	0,582122
Fold 9	0,580847	0,605719	0,626958	0,623620
Fold 10	0,549070	0,536983	0,584879	0,573598
Média	0,5605606	0,5556276	0,598647	0,592931

ESCALA NÃO-PADRONIZADA			
	Regressão Linear	Random Forest	Redes Neurais
Fold 1	0,560515	0,550310	0,597406
Fold 2	0,582572	0,593218	0,623047
Fold 3	0,543018	0,515138	0,566635
Fold 4	0,567838	0,582229	0,586533
Fold 5	0,509912	0,494828	0,539894
Fold 6	0,576976	0,576141	0,613907
Fold 7	0,578940	0,562658	0,603224
Fold 8	0,556263	0,550971	0,560616
Fold 9	0,580718	0,595936	0,612313
Fold 10	0,548766	0,537574	0,581518
Média	0,5605518	0,5559003	0,5885093

Fonte: Elaborado pelos autores

Então, os resultados obtidos para cada uma das técnicas foram:

Com os dados padronizados:

- **Regressão Linear** – *score* de 0,5605
- ***Random Forest*** – *score* de 0,5556
- **Redes Neurais** – *score* de 0,5986
- **SVM** – *score* de 0,5929

Com os dados não padronizados:

- **Regressão Linear** – *score* de 0,5605
- ***Random Forest*** – *score* de 0,5559
- **Redes Neurais** – *score* de 0,5885

Após analisar os resultados, pode-se verificar que os dados padronizados tiveram melhores resultados – comparando as médias – e a técnica de redes neurais foi a com maior *score*, mostrando ser a melhor técnica para predição das vendas da varejista escolhida. O SVM teve o segundo melhor resultado e ficou pouco pior que o primeiro, também apresentando um bom resultado.

5. CONCLUSÃO

Após todo o estudo realizado neste artigo e a implementação do *Machine Learning*, foi concluído que a técnica de redes neurais é a mais eficaz para se usar na predição de vendas da *BigMart Retail*. Não se deve tomar como verdade que esta técnica é a melhor para qualquer empresa varejista, é preciso que estudos sejam feitos e aplicados na base de cada empresa em particular, para que se chegue ao melhor resultado sempre.

É de extrema importância que empresas produzam e organizem seus dados, pois quanto mais informações uma base oferecer, maior a chance de um modelo atingir assertividades mais altas. Vale ressaltar que o estudo apresentado foi feito em uma base de dados relativamente pequena e com um número não tão grande de variáveis, mas mesmo assim foi possível alcançar um resultado de quase 60% de acerto. Além disso, a previsão de vendas pode ser um número difícil de prever, pois seria impossível definir todas as variáveis que a influenciam, algumas até aleatórias e impossíveis de serem listadas.

Assim, com este trabalho espera-se ajudar na transformação digital do mercado e na adoção do *Machine Learning,* apresentando mais um material de estudo para a rede e tornando-o mais acessível, já que seu uso pode ajudar tanto empresas grandes quanto pequenas e resolver demandas de diversas áreas. O objetivo da pesquisa foi cumprido, pois foi possível prever as vendas e definir qual técnica entregou o melhor resultado.

REFERÊNCIAS

AHA, David W.; KIBLER, Dennis; ALBERT, Marc K. Instance-based learning algorithms. **Machine learning**, v. 6, n. 1, p. 37-66, 1991.

BOSE, I. and MAHAPATRA, R. K. (2001). **Business data mining - a machine learning perspective**. Information & management, 39(3):211–225.

BRAGA, Antonio de Pádua; LUDERMIR, Teresa Bernarda; CARVALHO, André Carlos Ponce de Leon Ferreira. **Redes neurais artificiais: teoria e aplicações**. [S.l: s.n.], 2000.

BREIMAN, L. **Random Forests. Machine Learning** 45, 5–32 (2001).

CHARNET, R. **Análise de Modelos de Regressão Linear - Com Aplicações.** Unicamp 2008

DOMINGOS, P. **A few useful things to know about machine learning. Communications of the ACM, ACM**, v. 55, n. 10, p. 78–87, 2012.

ENGUITA, M. **Tecnologia e sociedade: A ideologia da racionalidade técnica, a organização do trabalho e a educação.** Educação & Realidade, Vol. 13, p.39-52, jan/jun 1988.

FERRERO, C. **Algoritmo kNN para previsão de dados temporais: funções de previsão e critérios de seleção de vizinhos próximos aplicados a variáveis ambientais em limnologia.** Tese (Mestrado em Ciência da Computação e Matemática Computacional). Universidade de São Paulo. São Paulo, 2009

GUTIERREZ, Gustavo Luis. **Gestão comunicativa: maximizando criatividade e racionalidade; uma política de recursos humanos a partir da teoria de Habermas**. Qualitymark Editora Ltda. 1999.

HAN, J.; KAMBER, M.; PEI, J. **Data Mining: Concept and Techniques.** 3rd ed. San Francisco , CA, USA. Morgan Kaufmann Publishers Inc. 2011

HESSEN, Johannes. **Teoria do Conhecimento**. São Paulo: Martins Fontes, 2000.

JUSTO, Diógenes. "**MODELOS QUANTITATIVOS APLICADOS A PREVISÃO DE DEMANDA DE VAREJO ON-LINE UTILIZANDO ABORDAGENS DE MACHINE LEARNING**" *13º Congresso Latino-Americano de Varejo e Consumo: "After COVID-19: Building Purpose through Stakeholders in Retailing".* 2020.

KOTTHOFF, L. **Algorithm Selection for Combinatorial Search Problems: A Survey.** CoRR, abs/1210.7959.

MALHOTRA, Yogesh. **Knowledge management for the new world of business**. 1998.

MONARD, Maria Carolina; BARANAUSKAS, José Augusto. Conceitos sobre aprendizado de máquina. **Sistemas inteligentes-Fundamentos e aplicações**, v. 1, n. 1, p. 32, 2003.

MÜLLER, Heiko; FREYTAG, Johann-Christph. **Problems, methods, and challenges in comprehensive data cleansing**. Professoren des Inst. Für Informatik, 2005.

MULLER, Andrea; GUIDO, Sarah. **An Introduction to Machine Learning with Python**. Copyright 2017 Sarah Guido and Andreas Müller, 978-1-449-36941-5.

OLIVEIRA, Maria Lúcia Magalhães de; AQUINO, José Aury de. **Amostragem**. 2012.

PALAZZO, P. **Computação, Tecnologia e Humanismo: Dados, informação e conhecimento**. 2020. Disponível em: https://www.palazzo.pro.br/Wordpress/dados-informacao-e-conhecimento/ Acesso em: 26 out. 2020.

ROKACH, L.; MAIMON, **O. Top-down induction of decision trees classifiers - A survey. IEEE Transactions on Systems, Man and Cybernetics Part C: Applications and Reviews**, v. 35, n. 4, p. 476–487, 2005.

ROZA; Felipe. S. **Aprendizagem de máquina para apoio à tomada de decisão em vendas do varejo utilizando registros de vendas**. Trabalho de conclusão de Curso. Universidade Federal de Santa Catarina. 2016.

SANTANA, M. **Um estudo comparativo das técnicas de predição na identificação de insucesso acadêmico dos estudantes durante cursos de programação introdutória.** Dissertação (Mestrado em Informática) - Instituto de Computação, Programa de Pós-Graduação em Informática, Universidade Federal de Alagoas, Maceió, 2015.

SANTOS, Angela Maria Medeiros Martins; COSTA, Cláudia Soares. **Características gerais do varejo no Brasil**. IBGE. 1997.

SANTOS, Eduardo Toledo. **Avaliação do algoritmo de Ray Tracing em Multicomputadores.** 181p. Dissertação (Mestrado)–Escola Politécnica da Universidade de São Paulo, Departamento de Engenharia de Computação e Sistemas II, São Paulo, 1994.

SCMOELLER, R. Felipe; **Aprendizagem de máquina para apoio à tomada de decisão em vendas do varejo utilizando registros de vendas**. Universidade Federal de Santa Catarina. Trabalho de Conclusão de Curso. 2016.

SMOLA, A.; VISHWANATHAN, S**. Introduction to machine learning**. Cambridge University, UK, v. 32, p. 34, 2008.

WITTEN, I; FRANK, E. **Data mining: practical machine learning tools and techniques.** v.2. San Francisco: Elsevier Inc, 2005.

WEISS, S. M.; INDURKYA, N. **Predictive Data Mining**: A Practical Guide, Morgan K. 1998.

WOLPERT, D. H. e MACREADY, W.G. **No free lunch theorems for optimization.** Evolutionary Computation, IEEE Transactions on, 1(1):67-82, 1997

ZHANG, S.; ZHANG, C.; YANG, Q. **Data Preparation for data mining. Applied Artificial Intelligence**, 17:5-6, 375-381, 2003.

ZHANG, Z.; **Introduction to machine learning: k-nearest neighbors.** Ann Transl Med, 2016

ZHENG, A.; *CASARI* A. **Feature Engineering for Machine Learning**. (O'Reilly). *Copyright* 2018 Alice and Amanda Casari, 978-1-491-95324-2.