UNIVERSIDADE TECNOLÓGICA FEDERAL DO PARANÁ
PROGRAMA DE PÓS-GRADUAÇÃO EM ENGENHARIA ELÉTRICA E INFORMÁTICA INDUSTRIAL

WILLIAN JEFERSON ANDRADE

DETECÇÃO DE ANOMALIAS DE POSICIONAMENTO EM ROBÔS INDUSTRIAIS UTILIZANDO APRENDIZADO DE MÁQUINA

DISSERTAÇÃO

CURITIBA
2024

WILLIAN JEFERSON ANDRADE

DETECÇÃO DE ANOMALIAS DE POSICIONAMENTO EM ROBÔS INDUSTRIAIS UTILIZANDO APRENDIZADO DE MÁQUINA

Detection of positioning anomalies in industrial robots using machine learning

Dissertação apresentado(a) como requisito parcial à obtenção do título de Mestre em Engenharia Elétrica e Informática Industrial, do Programa de Pós-Graduação em Engenharia Elétrica e Informática Industrial, da Universidade Tecnológica Federal do Paraná.

Orientador: Dr. André Eugenio Lazzaretti
Coorientador: Dr. Valmir de Oliveira

CURITIBA

2024

4.0 Internacional

Esta licença permite compartilhamento, remixe, adaptação e criação a partir do trabalho, mesmo para fins comerciais, desde que sejam atribuídos créditos ao(s) autor(es).
Conteúdos elaborados por terceiros, citados e referenciados nesta obra não são cobertos pela licença.

Ministério da Educação
Universidade Tecnológica Federal do Paraná
Campus Curitiba

WILLIAN JEFERSON ANDRADE

DETECÇÃO DE ANOMALIAS DE POSICIONAMENTO EM ROBÔS INDUSTRIAIS UTILIZANDO APRENDIZADO DE MÁQUINA

Trabalho de pesquisa de mestrado apresentado como requisito para obtenção do título de Mestre Em Ciências da Universidade Tecnológica Federal do Paraná (UTFPR). Área de concentração: Fotônica Em Engenharia.

Data de aprovação: 14 de Dezembro de 2023

Dr. Andre Eugenio Lazzaretti, Doutorado - Universidade Tecnológica Federal do Paraná

Dr. Gilberto Reynoso Meza, Doutorado - Pontifícia Universidade Católica do Paraná (Pucpr)

Dr. Marco Antonio Simoes Teixeira, Doutorado - Universidade Tecnológica Federal do Paraná (Utfpr)

Dr. Ronnier Frates Rohrich, Doutorado - Universidade Tecnológica Federal do Paraná

Documento gerado pelo Sistema Acadêmico da UTFPR a partir dos dados da Ata de Defesa em 14/12/2023.

AGRADECIMENTOS

À Deus, obrigado Senhor por mais uma das muitas oportunidade de progresso e evolução nesta vida. Gostaria de agradecer ao meu professor orientador André Eugênio Lazzaretti por toda paciência e dedicação para a realização desse trabalho, ao professor Valmir de Oliveira, meu coorientador por ter proporcionado minha entrada no programa de pós graduação, sem os quais eu não teria chego até aqui. Agradeço todo o apoio de minha liderança, em particular os senhores Zaqueu Chimicoviaki e Guillermo Meister, que me incentivaram e apoiaram desde o início do mestrado. Agradeço a participação dos colegas de trabalho Bruna Mulinari e Carlos Costa, que estiveram junto comigo durante todo o desenvolvimento desse trabalho, e sem ajuda e persistência deles não teria obtido tais resultados.

RESUMO

ANDRADE, Willian Jeferson. **Detecção de anomalias de posicionamento em robôs industriais utilizando aprendizado de máquina**. 2024. 74 f. Dissertação (Mestrado em Engenharia Elétrica e Informática Industrial) – Universidade Tecnológica Federal do Paraná. Curitiba, 2024.

Em razão da grande ascensão dos robôs no âmbito industrial mundial, tais equipamentos se tornaram fundamentais para o atingimento das metas diárias de produtividade e qualidade de uma planta fabril. Uma falha ou anomalia que por ventura venha ocorrendo com a máquina, mesmo que sútil, pode levar a uma grande parada de uma máquina ou até mesmo uma linha produtiva. Nesse âmbito, o estudo de detecção prévia de anomalias em robôs se torna apropriado para a manutenção preventiva planejada, a continuidade da produção e a longevidade do equipamento, sendo esse o principal objetivo deste trabalho. A metodologia utilizada compreendeu a construção de um *dataset* inicial com anomalias de posicionamento artificialmente geradas em um robô de uma linha de produção real. Através de uma análise inicial dos dados, algumas informações puderam ser filtradas logo no início do estudo, resultando na escolha das características de amplitude e desvio padrão de algumas das variáveis escolhidas para analise. A partir desses dados, o modelo *Isolation Forest* foi selecionado para operar como detector de anomalias. Foram feitas duas tratativas do dataset, devido ao desbalanceamento de classes e quantidades de amostras por produto, sendo gerados modelos por produtos e um modelo genérico tendo como característica o tipo de produto. Realizando um comparativo qualitativos das métricas entre os modelos individuais e o modelo genérico, percebeu-se que este último apresentou um desempenho superior a todos os modelos individuais em todas as métricas avaliadas, atingindo os resultados de *Precision* igual a 1, *Recall* igual a 0,952 e *F1-Score* igual a 0,975. Considerando o *dataset* com um total de 6516 amostras, dessas 274 com a presença de algum tipo de anomalia, teve-se como resultado apenas 13 casos de anomalias classificadas de forma errada. Este modelo também foi implementado no CLP da máquina, permitindo avaliação contínua das falhas do robô. Dessa forma, este trabalho demonstrou a viabilidade de detecção de anomalias em um cenário real de produção.

Palavras-chave: Plano ortogonal. Algoritmo. Robô industrial. Torques. Características.

ABSTRACT

ANDRADE, Willian Jeferson. **Detection of positioning anomalies in industrial robots using machine learning**. 2024. 74 p. Dissertation (Master's Degree in Electrical engineering) – Universidade Tecnológica Federal do Paraná. Curitiba, 2024.

Due to the great rise of robots in the global industrial sphere, such equipment has become fundamental for achieving the daily productivity and quality goals of a manufacturing plant. A failure or anomaly that may occur with a machine, even if useful, can lead to a major stoppage of a machine or even a production line. In this context, the study of prior detection of anomalies in robots becomes suitable for planned preventive maintenance, production continuity and equipment longevity, which is the main objective of this work. The methodology used comprises the construction of an initial data set with positioning anomalies artificially generated in a robot on a real production line. Through an initial analysis of the data, some information could be filtered right at the beginning of the study, resulting in the choice of amplitude and standard deviation variables of the variables X, Y and Z of the orthogonal plane of the robot and the calculated torques of the axes 2 and 3 From these data, the Isolation Forest model was selected to operate as an anomaly detector. Two treatments of the data set were carried out, due to the imbalance of classes and quantities of samples per product, with models being generated by products and a generic model having the type of product as its characteristic. Carrying out a qualitative comparison of the statistics between the individual models and the generic model, we see that the latter performed better than all the individual models in all evaluations evaluated, reaching the results of Precision equal to 1, Recall equal to 0.952 and F1 - Score equal to 0.975. Considering the data set with a total of 6516 samples, of these 274 with the presence of some type of anomaly, the result was only 13 cases of occasional anomalies in the wrong way. This model was also implemented in the machine's PLC, allowing continuous assessment of robot failures. Therefore, this work demonstrates the detection of anomalies in a real production scenario.

Keywords: Orthogonal Plan. Algorithm. Industrial robot. Torques. Features.

LISTA DE ILUSTRAÇÕES

Figura 1 – Exemplo de amplitudes do torque. 20
Figura 2 – Exemplo do desvio padrão do torque. 20
Figura 3 – Sequência de trabalho da estação 31
Figura 4 – Arquitetura de redes e comunicações 31
Figura 5 – Metodologia de projeto 32
Figura 6 – Sequencia de pontos 35
Figura 7 – Eixos do robô 37
Figura 8 – Eixos do robô 37
Figura 9 – Mesma posição final com eixos em posições diferentes. 38
Figura 10 – Curvas de temperatura dos servo motores. 43
Figura 11 – Curvas de posição cartesiana. 43
Figura 12 – Curvas de corrente. 44
Figura 13 – Curvas de torque. 45
Figura 14 – Curvas de torque eixos 1 a 3 um ciclo. 45
Figura 15 – Curvas de corrente eixos 1 a 3 um ciclo. 46
Figura 16 – Curvas de torque calculado. 46
Figura 17 – Características normalizadas sem a presença de anomalias. 48
Figura 18 – Curva de posição do eixo X durante um ciclo normal. 48
Figura 19 – Curva de posição do eixo X com anomalia. 49
Figura 20 – Curva de posição do eixo Y durante um ciclo normal. 49
Figura 21 – Curva de posição do eixo Y com anomalia. 50
Figura 22 – Curva de posição do eixo Z durante um ciclo normal 50
Figura 23 – Curva de posição do eixo Z com anomalia 51
Figura 24 – Curva de posição do *Torque Arm* Eixo 2 durante um ciclo normal. 51
Figura 25 – Curva de posição do *Torque Arm* Eixo 2 com anomalia. 52
Figura 26 – Curva de posição do *Torque Arm* Eixo 3 durante um ciclo normal. 52
Figura 27 – Curva de posição do *Torque Arm* Eixo 3 com anomalia. 53
Figura 28 – Detecção de anomalias através da variação de amplitude das posições. . . . 62
Figura 29 – Detecção de anomalias através do desvio padrão das posições. 63
Figura 30 – Detecção de anomalias através da variação de amplitude do *torque act*. . . . 64
Figura 31 – Detecção de anomalias através da variação do desvio padrão do *torque act*. . 64
Figura 32 – Detecção de anomalias através da variação de amplitude do *torque arm*. . . 65
Figura 33 – Detecção de anomalias através da variação do desvio padrão do *torque arm*. 65
Figura 34 – Modelo em operação na linha de produção. 66

LISTA DE TABELAS

Tabela 1 – Resumo dos trabalhos correlatos 28
Tabela 2 – Valores da variável T. 39
Tabela 3 – Resumo do *dataset*. 41
Tabela 4 – Comparativo amplitude e desvio padrão posição eixo X. 49
Tabela 5 – Comparativo amplitude e desvio padrão posição eixo Y 49
Tabela 6 – Comparativo amplitude e desvio padrão posição eixo Z 50
Tabela 7 – Comparativo amplitude e desvio padrão *Torque Arm* 2 52
Tabela 8 – Comparativo amplitude e desvio padrão *Torque Arm* 3. 52
Tabela 9 – Resultados por produto (modelo individual). 58
Tabela 10 – Matriz de confusão produto A. 58
Tabela 11 – Matriz de confusão produto B. 58
Tabela 12 – Matriz de confusão produto C. 59
Tabela 13 – Matriz de confusão produto D. 59
Tabela 14 – Matriz de confusão produto E. 59
Tabela 15 – Resultados modelo global 60
Tabela 16 – Matriz de confusão modelo global 60
Tabela 17 – Comparativo de performance entre os modelos. 61

SUMÁRIO

1 INTRODUÇÃO . . . 9
1.1 OBJETIVO GERAL . . . 12
1.1.1 Objetivos Específicos . . . 12
1.2 ESTRUTURA DO TRABALHO . . . 12

2 FUNDAMENTAÇÃO TEÓRICA . . . 14
2.1 ROBÓTICA INDUSTRIAL . . . 14
2.2 DETECÇÃO DE ANOMALIAS . . . 16
2.3 MÉTODOS UTILIZADOS . . . 18
2.3.1 Extração de Características . . . 19
2.3.1.1 Amplitude (Magnitude) . . . 19
2.3.1.2 Desvio padrão . . . 19
2.3.2 *Isolation Forest* . . . 20
2.4 TRABALHOS CORRELATOS . . . 23

3 METODOLOGIA . . . 30
3.1 DESCRITIVO DO PROCESSO . . . 30
3.2 ETAPAS DO DESENVOLVIMENTO . . . 32
3.3 REQUISITOS . . . 32
3.3.1 Entendimento do problema . . . 33
3.3.2 Expectativas . . . 33
3.3.3 Ganhos . . . 33
3.3.4 Desafios . . . 34
3.4 CONSTRUÇÃO DO *DATASET* . . . 34
3.4.1 Variáveis monitoradas . . . 36
3.5 ORGANIZAÇÃO DOS DADOS . . . 42
3.5.1 Análise das curvas e pré-seleção de variáveis . . . 42
3.5.2 Seleção de características . . . 46
3.5.3 Análise Qualitativa e Quantitativa das Características Selecionadas . . . 47
3.6 TREINAMENTO DOS MODELOS . . . 53
3.7 MÉTRICAS E AVALIAÇÃO DOS RESULTADOS . . . 54
3.8 IMPLEMENTAÇÃO PRÁTICA . . . 54
3.8.1 *Shadow Mode* . . . 55

4 RESULTADOS . . . 57
4.1 RESULTADOS COM UM MODELO POR PRODUTO . . . 57
4.2 RESULTADOS COM UM MODELO GLOBAL . . . 59
4.2.1 Comparativo entre os modelos . . . 60
4.3 ANÁLISE VISUAL . . . 61
4.4 RESULTADOS DO MODELO OPERANDO NA LINHA . . . 65

5 CONCLUSÕES E PERSPECTIVAS . . . 69

REFERÊNCIAS . . . 72

1 INTRODUÇÃO

No cenário atual da quarta revolução industrial, *Smart Factories* são plantas altamente automatizadas onde *Cyber-Physical Systems* (CPSs) conseguem gerenciar de forma automática os processos, tornando o ambiente mais confiável e eficiente (BONCI *et al.*, 2019). Há alguns anos, a utilização dos robôs industriais veem ocupando uma larga e importante faixa de operação nos diversos ramos de industrialização em virtude de sua versatilidade, alta precisão e velocidade de trabalho, aumentando significativamente os níveis de produtividade e de qualidade (CHEN *et al.*, 2020). De acordo com Marina Müller Cristopher e Sussane (2022), na apresentação de Outubro de 2022 realizada pela *International Federation of Robotics*, a instalação de robôs industriais teve o maior crescimento de todos os tempos, mais de 500 mil unidades foram vendidas durante o ano de 2021, o que representa um aumento de 31% em comparação com o ano de 2020.

Os robôs manipuladores são considerados um componente chave para o cumprimento das metas nos processos industriais. No entanto, uma falha inesperada leva ao aumento dos custos e na redução da produção, de forma que a detecção antecipada de defeitos é amplamente desejada, evitando assim, enormes perdas de produtividade. De acordo com Borgi *et al.* (2017), tomando como base de análise a mecânica padrão e a tecnologia elétrica empregada na construção do robô, existem diversas falhas que podem ocorrer com esse equipamento. Por exemplo, falhas no sistema de frenagem ocorrem em geral devido ao desgaste. Já nos motores elétricos, as falhas mais comuns são os curto-circuitos. Uma vez que a ocorrência dessas falhas pode variar no tempo e na forma dos dados, não é uma tarefa fácil combinar essas anomalias em uma estrutura padrão para uma simples detecção de falhas. Para uma análise de dados de anomalias, é necessária uma base de dados que contenha não somente os dados de operação normal, mas também vários dados de diferentes formas de anomalias, uma vez que não é recomendável a simulação de anomalias em um robô instalado em uma linha de produção, pois sempre exite o risco de causar algum dano ao equipamento. Nesse sentido, é necessário gerar uma base confiável de dados que contemple todas as situações possíveis, o que na prática dificilmente acontece em um curto período de avaliação.

Um dos grandes desafios para a manutenção de um robô é conseguir identificar as pequenas colisões que ocorrem com frequência durante o processo, devido a diversos fatores ligados ao desgaste mecânico da instalação, que podem causar danos severos às partes mecânicas

do robô e não são facilmente identificadas em uma manutenção preventiva de rotina feita de acordo com a especificação do fabricante. Cada uma das pequenas colisões que ocorrem durante o processo produtivo, geram um contra-torque no robô, o que reflete em um esforço adicional para garantir a posição programada ao custo da elevação das correntes do motor e do torque. O contra-torque percebido pelo robô pode levar a uma defasagem entre o conjunto mecânico e o *encoder* de posicionamento, o que pode fazer com que o robô passe a não mais atingir as posições programadas com precisão, o que por sua vez fará com que as pequenas colisões aumentem até o momento em que uma grande colisão cause uma falha. É sabido que desgaste, fadiga, sobrecarga, vibração, umidade e outros fatores eventualmente podem causar degradação no desempenho, o que pode levar a falhas inesperadas, causando assim, prejuízos financeiros significativos, bem como custos elevados com manutenção (AIVALIOTIS *et al.*, 2021). No contexto deste trabalho, o alvo do estudo é um robô manipulador com seis graus de liberdade, o qual realiza a tarefa cíclica de retirar peças de uma posição pré programada para depositar em outra. Ambas as posições – depósito e retirada – possuem uma fixação mecânica robusta e de precisão, pois o robô é programado para apanhar e depositar as peças nessas posições programadas. No entanto, devido ao desgaste mecânico natural que ocorre com o tempo de utilização, essas posições podem sofrer variações ao longo do funcionamento. Nesse caso haverá um deslocamento da posição programada conhecida pelo robô, o que fará com que no momento da retirada ou depósito de uma peça, ocorra uma pequena colisão quase imperceptível mas que pode, ao longo do tempo, causar a perda de referência de um ou mais eixos, ou até mesmo uma falha mais severa como o rompimento de uma correia ou a quebra de uma transmissão.

Até o momento, uma das alternativas mais usuais para mitigar os efeitos negativos da quebra inesperada é a manutenção preventiva, feita periodicamente de acordo com as especificações do fabricante. No entanto, esse tipo de manutenção tem o foco voltado para os itens relacionados em um *check-list* padrão sugerido no manual do fabricante, o que por vezes não é capaz de encontrar um defeito eminente, o qual pode levar o robô a uma falha logo após a realização da intervenção, gerando não somente o prejuízo para a produção como também o desperdício de recursos de manutenção. De acordo com (AIVALIOTIS *et al.*, 2021), recentes estudos mostram que uma manutenção preventiva mais eficaz e assertiva é embasada em dados históricos, os quais definem a melhor periodicidade para a intervenção. Em termos de coleta de dados de degradação de um robô, pode-se citar três métodos principais: (i) baseado no conhecimento de um especialista no assunto e uma base de dados histórica; (ii) modelagem física, a qual

utiliza modelo matemático para a determinação do processo de degradação; e, finalmente, (iii) o método de *data-driven*, o qual utiliza redes neurais, regressões, filtros e modelos estocásticos dos processos, sendo esse último, o mais recorrente e com resultados mais assertivos nos estudos de caso recentes (AIVALIOTIS *et al.*, 2021).

Outra forma de avaliar o estado de um robô e tomar ações preventivas são os chamados *Prognostics and Health Management Models* (PDM-models), os quais capturam o estado presente do robô em uma situação normal de operação e utilizam algoritmos que extrapolam padrões de operação futuros. De acordo com (NENTWICH; REINHART, 2021), esses modelos de regressão e classificação são embasados na física ou em dados, onde os dados precisam ser coletados em diferentes condições de operação do robô. Tais dados são então transformados em um indicador chamado de *Health Indicator* (IH), o qual irá representar o estado de saúde da máquina através de estatística ou análise do sinal. No trabalho de (BONCI *et al.*, 2019), por exemplo, foi proposto uma forma de detecção de falha em sistemas manipuladores cartesianos através do monitoramento das correias que fazem a interligação entre o eixo do motor e o eixo de deslocamento mecânico. Quando uma correia apresenta desgaste, ela perde a elasticidade original, o que se reflete na frequência de vibração, que por sua vez diminui. Ao identificar que a correia está solta, é possível gerar um alarme para verificação e manutenção preventiva. O método proposto analisou as correntes dos servo motores fazendo a decomposição da forma de onda para criar um índice com o objetivo de correlacionar a influência da correia solta com a corrente elétrica de operação do servomotor. De forma similar, o estudo de caso desenvolvido por (AIVALIOTIS *et al.*, 2021), foi a detecção de anomalias tomando como base um modelo físico e a coleta de dados de curvas de degradação de um robô utilizado para realizar a solda interna em tanques.

No caso particular do presente trabalho, a proposta é coletar dados de corrente elétrica, torque mecânico, temperatura dos motores e coordenadas de posição de todos os eixos de um robô industrial com seis graus de liberdade, que trabalha como manipulador em uma estação de uma linha de produção. Com base nesses dados, é proposta uma análise para o reconhecimento do padrão de comportamento das grandezas durante o ciclo considerado normal, bem como em eventos anômalos, que podem caracterizar falhas (suaves, moderadas ou mesmo severas). Após o entendimento, organização, concretização e análise dos dados obtidos, propõe-se então, utilizar de algoritmos de aprendizado de máquina para identificar a ocorrência de uma anomalia. O sucesso na implementação do algoritmo significa redução de falhas com consequente parada

de produção e aumento da vida útil do equipamento. Outro benefício da aplicação da abordagem aqui proposta é que o projeto possui grandes chances de escalabilidade, ou seja ter o mesmo conceito aplicado em robôs iguais ao modelo utilizado como referência ao estudo. Um dos fatores limitantes para a implementação do algoritmo de *machine learning* no controlador de estação são as questões de comprometimento do processamento e da utilização de memória, pois a principal tarefa do controlador é executar em tempo real as tarefas de automação da estação.

1.1 OBJETIVO GERAL

Desenvolver um sistema para detecção de anomalias em um robô industrial, utilizando dados de corrente elétrica, temperatura, torque mecânico e coordenadas de posição, permitindo realizar uma manutenção preventiva mais eficaz, evitando assim, paradas indesejadas da máquina ou mesmo a quebra indesejada de um componente.

1.1.1 OBJETIVOS ESPECÍFICOS

- Definir e coletar os dados de um robô industrial para análise;
- Realizar análise exploratória dos dados coletados;
- Avaliar os dados válidos e realizar a organização do conjunto de dados;
- Realizar teste com algoritmos existentes para identificação das anomalias;
- Avaliar o desempenho do algoritmo proposto neste conjunto de dados, apontando benefícios e eventuais limitações;
- Implementar o algoritmo em uma linha de produção real;
- Auxilio para planejamento de manutenção preditiva com base nos resultados da detecção de anomalias.

1.2 ESTRUTURA DO TRABALHO

O trabalho segue estruturado da seguinte forma. No capítulo 1, é realizada uma breve introdução sobre o tema e a abordagem dos objetivos geral e específicos do trabalho. O capítulo 2 apresenta uma fundamentação teórica e revisão da literatura referente ao tema da detecção de

anomalias em diversos setores incluindo os manipuladores industriais. O capítulo 3 demonstra a metodologia utilizada para o desenvolvimento e execução do trabalho. Na sequência, o capítulo 4 apresenta os principais resultados teóricos e práticos e finalmente, no capitulo 5, são discutidas as conclusões e trabalhos futuros.

2 FUNDAMENTAÇÃO TEÓRICA

Este capítulo apresenta os principais conceitos teóricos relacionados ao tema de pesquisa. Inicialmente, são apresentados conceitos gerais de robótica industrial. Em seguida, são apresentados os conceitos da detecção de anomalias e o algoritmo *Isolation Forest* que foi escolhido para a resolução do problema. Finalmente, são discutidos alguns trabalhos correlatos da área, bem como aspectos originais deste documento.

2.1 ROBÓTICA INDUSTRIAL

Um robô industrial, de acordo com a definição da ISO 10218 (STANDARDIZATION, 2011), é descrito como uma máquina manipuladora com vários graus de liberdade controlada automaticamente, reprogramável, multifuncional, que pode ter base fixa ou móvel para a utilização em aplicações de automação industrial.

Dentro desse contexto, a robótica industrial contempla um conjunto de mecanismos com inteligência e controle desenvolvidos para realizar tarefas consideradas repetitivas, pesadas ou que exijam alta precisão em um ambiente fabril (SUELL, 2020). Para tanto, foram criados os robôs industriais ou também conhecidos como braços robóticos. Os robôs industriais são constituídos de eixos e juntas, as quais proporcionam graus de liberdade e variam de acordo com a quantidade desses elementos. Toda a mecânica é construída com elementos de precisão garantindo ao robô repetibilidade e precisão nos movimentos. Além da mecânica elaborada, existe ainda todo um processo de controle em malha fechada para garantir o posicionamento de cada eixo através dos servo motores. Por último, um controlador realiza a monitoração da execução dos movimentos em sincronia com todos os eixos (CRAIG, 1989).

No caso do robô utilizado neste projeto, temos atuadores do tipo eletromagnéticos que têm a função de transformar a energia elétrica em energia mecânica. Os atuadores do robô são do tipo servomotores alimentados em corrente alternada trifásica e controlados por conversores de frequência com o estágio de potência comandado por IGBT (do inglês, *Insulated-Gate Bipolar Transistor*. A tecnologia é interna ao controlador do robô e foi desenvolvida pelo próprio fabricante. Os servomotores são de tamanho reduzido e torque elevado, o qual se mantém constante durante toda a faixa de operação. Para o controle de posição e velocidade cada servo motor possui um *resolver* acoplado que gera um sinal senoidal, o qual posteriormente

é convertido em sinal digital para a realização do controle preciso de malha fechada (SUELL, 2020).

Já com relação à cinemática, essa normalmente é composta por juntas e transmissões. As juntas compõem os pares cinemáticos que são interligados por elos adjacentes, podendo ser junta de rotação ou de translação. O uso de juntas visa tornar o processo de montagem mais simples necessitando de apensas uma variável para o controle de posição. O número de graus de liberdade de um robô é a quantidade de variáveis independentes da posição que precisam ser especificadas para se definir a localização de todas as partes do mecanismo. Os sistemas de transmissão são responsáveis pela transmissão da potência mecânica dos atuadores aos elos. Dentre os sistemas de transmissão mais utilizados encontram-se engrenagens, fusos de esfera, correias, polias, engrenagens planetárias e harmônicas. A escolha da transmissão depende dos parâmetros de projeto, tais como a potência transmitida, os tipos de movimentação desejada e a localização do atuador em relação a junta controlada (SUELL, 2020).

Finalmente, a unidade de comando, é responsável pelo controle e monitoração dos movimentos do robô. De acordo com Bilancia *et al.* (2023), adotando uma abordagem de controle padrão, o robô nomeia uma sequência de operações e movimentos a serem executados dentro do ciclo de trabalho programado, o qual é definido pelo programador através de um conjunto de instruções codificadas numa linguagem de programação específica do fabricante. Tais instruções são progressivamente lidas, interpretadas e passadas pelos módulos de planejamento de trajetória e geração de trajetória. O planejamento do caminho à ser executado calcula uma trajetória viável que conecta o ponto inicial ao ponto final no espaço de trabalho, enquanto o gerador de trajetória combina informações geométricas e de tempo e fornece como saída a cinemática inversa a lei do movimento no espaço articular. Em seguida, os pontos de ajuste de posição calculados são enviados ciclicamente aos servoacionamentos, que modulam e entregam a corrente elétrica aos servomotores por meio de um controle de malha fechada baseado no *feedback* de posição dos servomotores. Os comandos de movimentação enviados aos atuadores são originados de controladores externos, como por exemplo um CLP (Controlador Lógico Programável), o qual toma decisões tendo como base por exemplo o estado lógico de sensores (SUELL, 2020). As juntas do robô são guiadas pelo servomotor o qual é conectado ao *drive*. O *drive* envia ao controlador sinais de *feedback* de corrente. *Encoders* rotacionais são montados no eixo de saída dos motores para monitoração da posição. Essas informações em conjunto com o sinal de referência de movimentação são alimentadas à unidade de controle. Um sinal de controle então

é enviado de volta ao *drive* de controle de velocidade para controlar a posição do motor. Um sensor de corrente é utilizado para medir a corrente de fase entre o ajuste de velocidade do *drive* e o sistema do robô industrial (CHEN *et al.*, 2020).

Uma das ações mais importantes para o atingimento das velocidades, acelerações, controle do torque e o posicionamento corretos e de precisão, é a estratégia de controle do robô. De acordo com Ibrahim *et al.* (2016), o sistema de controle de posicionamento e torque de um robô é algo complexo, devido aos, atuadores dinâmicos, diversas incertezas do sistema e a flexibilidade das juntas. A dinâmica de funcionamento de um robô é considerada altamente não linear. Tomando como referência as variações de borda, os parâmetros de controle são determinados, o que confirma a forte estabilidade do sistema de controle de malha fechada.

Uma definição para o controle de malha fechada, descrito por (WANG; CHORTOS, 2022) é que essa técnica necessita e confia nos sinais de sensores para providenciar as informações a respeito da deformação dos atuadores e o respectivo estado de contato com a superfície do ambiente em que o robô se encontra inserido. o controle de malha fechada é necessário quando o ambiente ou a tarefa é variada ou incerta, como por exemplo um *gripper* que precisa apanhar diferentes tamanhos e formatos de objetos.

2.2 DETECÇÃO DE ANOMALIAS

Uma anomalia pode ser definida como um evento que desvia notadamente dos outros elementos de um determinado conjunto de dados (GOLDSTEIN; UCHIDA, 2016). As anomalias possuem duas importantes características: (i) são diferentes do normal em relação as suas características; e (ii) são raras em um *dataset* em comparação com as instâncias consideradas normais. A detecção de anomalias aplicada especificamente à indústria tem como foco identificar desvios de um processo, de uma máquina ou de um componente os quais apresentam na maior parte do tempo de funcionamento um comportamento normal de operação. No entanto, quando o desvio ou anomalia ocorre, pode se tratar de uma grave interferência levando até mesmo a parada e inutilização do equipamento, como é o caso de colisões de um robô (CHANDOLA *et al.*, 2009; CHALAPATHY; CHAWLA, 2019).

Ao contrário da maioria das tarefas de aprendizado de máquina, onde os padrões normalmente são conhecidos e regulares, a detecção de anomalias trata de um cenário completamente oposto, onde a incerteza e raros eventos são as características que se deseja descobrir para o tratamento do problema. Anomalias estão associadas com muitas incertezas como uma mudança

abrupta de comportamento, estrutura ou distribuição dos dados. Uma anomalia pode ter características completamente diferente da outra, como por exemplo variações abruptas de temperatura para mais ou para menos. Anomalias são difíceis de serem detectadas em larga escala dentro de um *dataset*, uma vez que seu evento não é esperado ou até mesmo desejado. Por outro lado, o comportamento de um grupo grande de dados dentro de um *dataset* pode ser considerado uma anomalia em grupo, uma vez que estes estejam todos fora do padrão (PANG *et al.*, 2021; CHANDOLA *et al.*, 2009).

De acordo com (PARK *et al.*, 2021), com base nos algoritmos de aprendizado, pode-se classificar os métodos de detecção em três tipos: aprendizado supervisionado, semi-supervisionado e não-supervisionado. No caso supervisionado, existem os rótulos de classes, sendo que um deles representa a anomalia. De acordo com (GOLDSTEIN; UCHIDA, 2016), esse cenário é bastante parecido com o reconhecimento de padrões tradicional, com a exceção de que as classes são tipicamente desbalanceadas. Nem todos os algoritmos de classificação tradicionais são indicados para essa tarefa, uma vez que alguns não são apropriados para casos severamente desbalanceados. Na maioria das aplicações, as anomalias não são conhecidas no primeiro momento de análise (treinamento) ou podem ocorrer espontaneamente durante a fase de teste. Sendo assim, nem sempre algoritmos clássicos de classificação são adequados para o problema.

O caso semi-supervisionado, também conhecido como classificação de uma classe, considera que todas as instâncias treinadas possuem apenas um rótulo. Sendo assim, o treinamento segue o princípio da detecção de bordas – contorno em torno das instâncias normais. A instância que não pertencer a maioria é marcada como anormalidade. Os algoritmos mais conhecidos para aplicação em métodos semi-supervisionados são: *One-clas Support Vector Machine*, *Isolation Forest* e os *Autoencoders* (GOLDSTEIN; UCHIDA, 2016).

Já o caso não-supervisionado, conforme (GOLDSTEIN; UCHIDA, 2016), é o método mais flexível, pois não exige nenhuma espécie de rótulo e não existe distinção entre dados de teste e treino. A ideia é que o algoritmo consiga ponderar os dados somente baseado em características intrínsecas do *dataset*.

De acordo com (ZOGHLAMI *et al.*, 2020), a detecção de anomalias tem se focado basicamente em aprendizado semi-supervisionado e não supervisionado, sendo utilizado em diferentes campos de aplicação e formato de dados. Tem sido utilizada para detecção de ataques cibernéticos que podem resultar em mau funcionamento ou tentativa de fraude. Outros exemplos

de aplicação são na detecção de anormalidades em um sistema de tratamento de água, falha em um isolamento elétrico em uma linha de trens de alta velocidade, utilidades médicas e localização de eventos anormais em sistemas de vigilância.

Uma característica chave da detecção de anomalias é a natureza dos dados de entrada, os quais podem incluir diferentes características. Os dados de entrada podem ser sequências, como textos e voz, ou não-sequenciais, como por exemplo imagens. Cada instância também pode ser definida como um atributo binário, categórico ou contínuo (CHANDOLA *et al.*, 2009). A disponibilidade dos dados para análise é obviamente importante para o levantamento das premissas iniciais e posteriormente para a definição do tipo de anomalia que se deseja encontrar. No caso de um robô industrial, o mais usual é o torque e a equação cinemática do robô.

As anomalias podem ser pontuais, contextuais ou em grupo. No caso pontual, foco da maioria dos trabalhos de literatura, a anomalia consiste em um desvio ou irregularidade que pode ocorrer de forma randômica e não possui uma interpretação em particular. De acordo com (CHANDOLA *et al.*, 2009), define-se como anomalia pontual uma instância individual que pode ser considerada anormal com relação aos demais dados. O caso contextual trata-se de um tipo de anomalia que é percebida em um contesto específico, como por exemplo uma elevação súbita de temperatura em um período de inverno. Para (CHANDOLA *et al.*, 2009), a noção de contexto é induzida pela estrutura do *dataset* e deve ser especificada como parte do problema. As anomalias coletivas são um grupo de características que se repetem em um período e que são diferentes dos padrões normais. O dado analisado individualmente em uma anomalia coletiva pode não ser considerado anormal, mas sim, na ocorrência coletiva (CHANDOLA *et al.*, 2009). Dentro desse contexto, pode-se considerar de acordo com (CHANDOLA *et al.*, 2009), que a detecção de anomalias compreende desvios de padrão da normalidade da massa de dados de um *dataset*. Trata-se da tarefa de encontrar padrões nos dados que não estão de acordo com o esperado. Também são conhecidos na literatura internacional como *abnormalities*, *deviants* ou *outliers*.

2.3 MÉTODOS UTILIZADOS

A metodologia utilizada se divide em duas frentes principais: extração de características e a detecção da anomalia. A seguir, serão descritos os fundamentos teóricos dos extratores de características e, em seguida, dos detectores de anomalia. Dentre as diversas possibilidades de métodos para a detecção de anomalias, neste trabalho optou-se pelo *Isolation Forest*. Portanto,

esse método será brevemente descrito aqui neste capítulo.

2.3.1 EXTRAÇÃO DE CARACTERÍSTICAS

O problema aqui proposto usa como base as variações de corrente, torque, temperatura e coordenadas de posição no plano cartesiano de todos os eixos do robô, os quais combinados podem revelar situações anormais, como indicado por Hornung *et al.* (2014) e descrito no próximo capítulo. Realizando a análise das variáveis coletadas, foram geradas algumas características que fossem relevantes a identificação de uma anomalia, as quais pudessem ser utilizadas com entrada para o treinamento do algoritmo. Foram extraídas as características relacionadas as medidas de dispersão, que são parâmetros estatísticos usados para determinar o grau de variabilidade dos dados de um conjunto de valores tais como média, desvio padrão, amplitude e variância. Após a geração das características, foram realizadas as verificações de utilização de cada uma e sua representabilidade em situações de anomalia, nesse sentido, as características que mais se destacaram foram a amplitude e o desvio padrão.

2.3.1.1 AMPLITUDE (MAGNITUDE)

É uma característica que determina a diferença entre o maior (X_{max}) e o menor (X_{min}) valor de um conjunto de dados de torque (COSTA, 2002), conforme descrito na Equação 1:

$$R = X_{max} - X_{min}. \tag{1}$$

A Figura 1 mostra a evolução temporal da característica de amplitude do torque que é uma das variáveis de avaliação.

2.3.1.2 DESVIO PADRÃO

O desvio padrão do torque (S) trata-se da raiz quadrada da variância (S_x^2) e seu calculo é feito através da Equação 2.

$$S_x = \sqrt{S_x^2}. \tag{2}$$

O desvio padrão se expressa na mesma unidade da variável, sendo por isso, de maior interesse que a variância nas aplicações práticas. Além disso, ele é mais realístico para efeito de comparação de dispersões (COSTA, 2002). A Figura 2 mostra um exemplo para um caso de análise deste trabalho.

Figura 1 – Exemplo de amplitudes do torque.

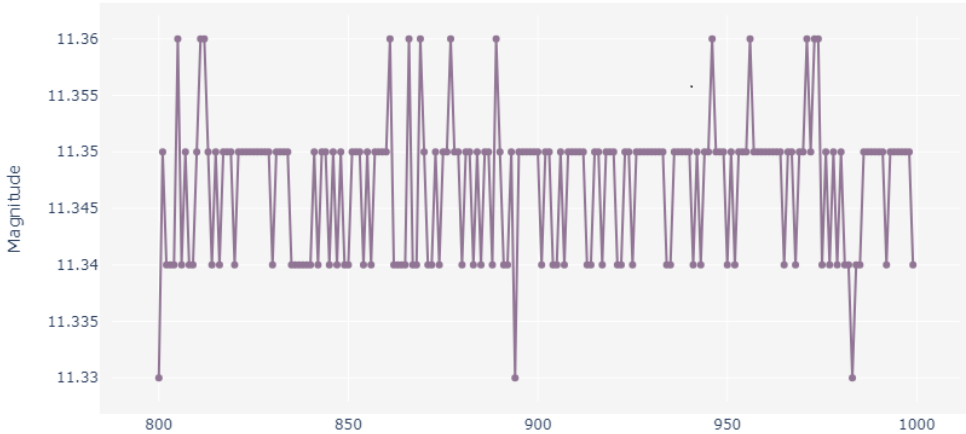

Fonte: Autoria própria.

Figura 2 – Exemplo do desvio padrão do torque.

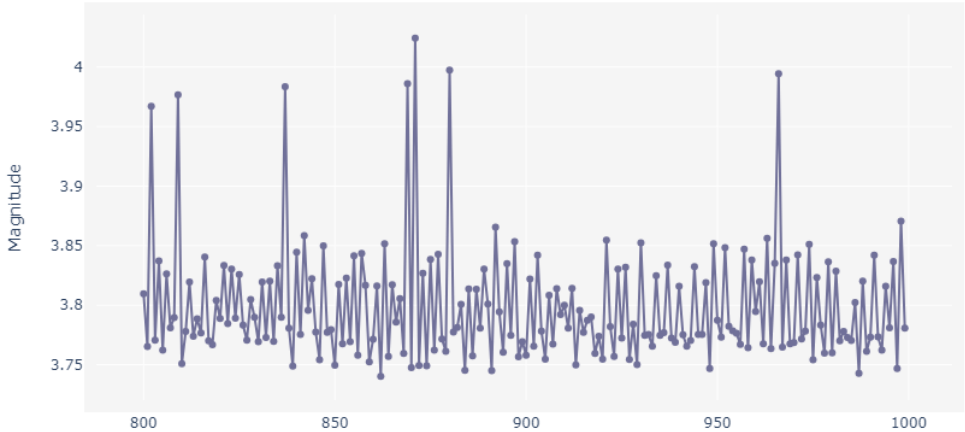

Fonte: Autoria própria

2.3.2 *ISOLATION FOREST*

A maioria dos algoritmos utilizados para a detecção de anomalias em um determinado *dataset* tem como principal objetivo a construção de um perfil das instâncias normais, para então identificar as instâncias que não pertencem ao padrão considerado normal, como uma anomalia. A detecção de anomalias tem sido alvo de estudo por vários grupos de pesquisa, por se tratar de um tema atual e de grande importância para diferentes áreas do conhecimento, de forma que diversos algorítimos foram desenvolvidos para a tratativa do tema. Dentre esses diversos algorítimos desenvolvidos nos últimos anos, um que se destaca, atingindo resultados do estado-da-arte para diferentes aplicações é o *Isolation Forest* (HARIRI *et al.*, 2021). O algoritmo chamado de *Isolation Forest* ou *iForest* foi desenvolvido em 2008 por Fei Tony Liu and Zhi-Hua

Zhou para a detecção de anomalias em um conjunto de dados. Esse algoritmo tem se provado muito eficaz na detecção de anomalias, sendo a principal vantagem de não construir um perfil como referência para encontrar amostras anômalas, mas sim, considerando que dados anormais são poucos e diferentes (HARIRI *et al.*, 2021). O algoritmo consiste em gerar árvores isoladas, onde as anomalias são consideradas aquelas que possuem o menor caminho na média. Existem apenas duas variáveis nesse método, o número de árvores e o tamanho da sub-amostra. O método converge rapidamente com um número pequeno de árvores e apenas com um pequeno tamanho de subamostras (LIU *et al.*, 2008). De acordo com (LIU *et al.*, 2008), algumas das vantagens da utilização do método *Isolation Forest* podem ser citadas abaixo:

- A característica da árvore isolada permite a construção de modelos parciais e a exploração de sub-amostras em extensão, o que não é possível em outros métodos;
- O *iForest* não se utiliza de distâncias ou densidade para a detecção, o que reduz o custo computacional;
- Possui uma complexidade linear no tempo com baixa utilização de memória, o que se mostra adequado para sistemas de baixa complexidade computacional – uma das frentes deste trabalho;
- Possui a capacidade de ser aplicado a grandes data sets e problemas de grandes dimensionalidades com um alto número de atributos irrelevantes.

O algoritmo *Isolation Forest* foi escolhido para a resolução do problema proposto no trabalho em função da sua simplicidade, baixa necessidade de recursos computacionais e fácil interpretabilidade, pois para a geração das arvores e sub-amostras basicamente é construída uma sequência de comparadores condicionais, as chamadas funções *IF/ELSE*.

Para seu detalhamento, pode-se considerar um conjunto de dados $X = \{x_1, \ldots, x_n\}$ com diversos pontos em n dimensões. O algoritmo irá criar uma árvore selecionando recursivamente uma dimensão randômica, comparando cada ponto a uma distância de corte para cada dimensão selecionada. Os pontos serão então enviados para a direita ou para a esquerda dos ramos da árvore de acordo com as regras do algoritmo. Com a geração de várias árvores, pode-se utilizar a profundidade dos ramos para determinar o *score* da anomalia. A equação que representa o score médio dos ramos está representada na equação 3:

$$s(x,n) = 2^{\frac{-E(h(x))}{c(n)}}, \tag{3}$$

sendo que $E(h(x))$ é o valor médio da profundidade de um dado simples, x é o alcance em todas as árvores, $c(n)$ é o fator de normalização definido como a profundidade média em uma busca binária sem sucesso, do inglês *Binary Search Tree* (BST), implementada no algoritmo.

O termo isolado significa separar uma instância das demais, uma vez que anomalias são poucas e diferentes, e nesse caso mais susceptíveis ao isolamento (LIU *et al.*, 2008). Através da análise das árvores geradas por uma *iForest*, pode-se perceber que um determinado ponto considerado normal necessita de mais partições para ser localizado, já uma anomalia é composta por apenas algumas partições. Uma partição pode ser representada por uma estrutura de árvore, o número de partições para isolar um ponto é equivalente ao comprimento do caminho desde a raiz até o final do nó. Diversas partições são geradas aleatoriamente, sendo que as árvores são geradas com diferentes conjuntos de partições, então através da média do comprimento de cada caminho é determinado o comprimento total (LIU *et al.*, 2008).

De acordo com (LESOUPLE *et al.*, 2021), o algoritmo sempre irá gerar árvores aleatórias para particionar os dados e calcular para cada uma das árvores e o número de nós necessários para isolar cada vetor de treino. Sendo assim, anomalias são aquelas cujos vetores possuem o menor comprimento médio, motivado pelo fato de que dados normais são muito mais concentrados e que esses necessitam de um caminho bem mais longo para serem isolados.

Seja *T* um nó da árvore isolada de forma externa sem ramos ou interna com um teste e até dois nós irmãos (T_l *e* T_r), um teste consiste em um atributo *q* e um valor de separação *p*, onde $q < p$, dividindo os pontos de dados entre T_l *e* T_r. Dado um grupo de dados $X = x_1,...,x_n$ com *n* instâncias de um distribuição *d*, para formar uma árvore isolada, divide-se repetidamente *X* por *q* e *p* de forma randômica até que:

- a árvore tenha atingido um limite de altura;
- quando o módulo de *X* for igual a 1;
- todos os dados de *X* tenham o mesmo valor.

Uma árvore isolada é uma árvore binária, onde cada nó tem exatamente zero ou dois nós filhos. Assumindo que todas as instancias são distintas, cada instância é isolada de um nó externo quando uma *iTree* atingiu tamanho máximo. Em cada caso o número de nós externos é *n* e o interno é $n - 1$. O número total de nós é $2n - 1$

A tarefa de detectar uma anomalia é determinar um *ranking*, o qual reflete o grau de anomalia. Uma forma é escolher pontos de acordo com o comprimento do caminho ou *score*,

então anomalias são consideradas os pontos no topo da lista. O comprimento do caminho *h(x)* de um ponto *x* é medido através do número de bordas *h(x)* transversas à *iTree*, desde a sua raiz até a transversal que termina em um nó externo. Um *score* é necessário para qualquer método de detecção de anomalias. Existe uma dificuldade em derivar um score de *h(x)*, porque enquanto o tamanho máximo de *iTree* cresce em função de *n*, a média cresce em função do $log(n)$. Utilizando por analogia a estimativa a da média do comprimento do método BST, tem-se a equação 4 para a busca sem sucesso:

$$c(n) = 2H(n-1) - \frac{2(n-1)}{n}, \tag{4}$$

sendo que *H(i)* é um valor harmônico e pode ser estimado por $ln(i) + \gamma$ (onde γ é a constante de Euler com valor 0.5772156649). A variável *c(n)* é a média de *h(x)* dado um certo *n* utilizado para normalizar *h(x)*. Portanto *score* de uma instância é definido como apresentado na Equação 3. Na Equação 3:

- quando *E(h(x))* $\rightarrow$ *c(n), s* $\rightarrow$ 0.5;
- quando *E(h(x))* $\rightarrow$ 0, *s* $\rightarrow$ 1;
- quando *E(h(x))* $\rightarrow$ *n*-1, *s* $\rightarrow$ 0.

De acordo com as relações acima, tem-se que:

- As instâncias que retornam *s* próximo de 1, serão consideradas anomalias;
- As instâncias que possuírem *s* muito menor que 0,5, então essas serão consideradas com seguranças instâncias normais;
- Se todas as instâncias retornarem um valor de *s* muito próximo de 0,5, então pode-se considerar que o *dataset* inteiro não possui anomalias.

2.4 TRABALHOS CORRELATOS

Diversos autores tem buscado soluções na área correlata deste trabalho, com objetivo de detectar mudança de comportamento de um robô. A seguir, é apresentado um breve descritivo dos trabalhos mais similares à abordagem aqui proposta, bem como os diferenciais da presente pesquisa.

O trabalho de pesquisa desenvolvido por (ZHANG *et al.*, 2021) teve seu foco no estudo de identificação online de colisões de um robô colaborativo Kuka LWR4+ com sete graus de liberdade, o qual estava montado em uma plataforma fixa. Diversos tipos de interações físicas foram exercidas intencionalmente ao robô, tais como um martelo macio, a própria mão com luva e uma esfera plástica durante sua trajetória para a geração do dados. A monitoração do torque mostra que existem desvios e ruídos no sinal causados pela movimentação das juntas, os quais são afetados pela direção do movimento. Por esse motivo, os pesquisadores traçaram diferentes trajetórias com o mesmo ponto de início porém com o ponto final diferente. Os pesquisadores iniciaram o estudo pela determinação da coleta dos dados, sendo escolhida a variável torque. Para a coleta dos dados, foi utilizado um *software* para coletar toda a curva de torque de cada um dos sete eixos com uma amostragem de 1ms. Após a coleta dos dados, uma análise foi feita no *dataset* para identificar e separar o tipo de evento entre colisões e contatos. No total, foram considerados 13633 exemplos de diferentes posições, mantendo uma escala de 1:1:2 entre os sinais de colisão, contato e livre. As curvas que apresentaram grandes desvios dos valores esperados ou ruídos foram desconsideradas. As variáveis de torque são então usadas como entrada de um classificador o qual resulta em uma predição entre colisão, contato e livre. As *features* escolhidas para análise foram aquelas que apresentaram mudanças em amplitude do sinal. As características analisadas nessa ordem foram média, variância, *skweness* e *Kurtosis*. Ao realizar a análise das curvas de torque no domínio da frequência, foi constatado que havia uma diferença clara entre colisão e contato os quais ocorriam em 10 e 20 Hz respectivamente. Para finalmente selecionar as *features* relevantes para o classificador, foram utilizados a correlação de Spearman e o Algoritmo de Relieff. O primeiro analisa a correlação entre duas *features* e o segundo calcula os pesos de cada *feature* de acordo com a sua importância para o classificador. A próxima etapa do estudo foi a escolha do melhor classificador para análise dos dados da série temporal, logo foram escolhidos os modelos mais popularmente utilizados, os quais são: *Linear Discriminant Analisys* (LDA), o *k-nearest neighbors* (kNN), a *Support Vector Machine* (SVM) e a *Feedforward Neural Network* (FNN). Foram feitas varias configurações automáticas para encontrar os melhores hiperparâmetros de validação e logo após os melhores scores de acordo com os melhores parâmetros escolhidos na etapa anterior. Todos os quatro modelos apresentaram scores satisfatórios sendo que o melhor resultado apresentado foi a rede neural com 96,6%. O maior trabalho foi conseguir identificar as diferenças entre os sinais de torque do robô para a geração de cada uma das classes. O trabalho poderia ter explorados alguns métodos para a

detecção de anomalias além do classificador, tratando apenas os sinais de colisão como sendo um desvio da normalidade do padrão de operação. Essa dissertação irá mostrar que não há a necessidade de criação de classes de colisões, mas sim estudar o comportamento de uma curva normal de torque dentro de um ciclo de funcionamento do robô, treinando o algoritmo para detectar uma situação fora da normalidade.

No trabalho publicado por (PARK *et al.*, 2021), a grande preocupação é detectar um evento de colisão visando a segurança do operador e a manutenção do robô. Como variáveis de análise, os autores escolheram o modelo matemático do robô e um *momentum observer-based*, o que na prática significa um sensor de detecção de picos de corrente, os quais monitoram a relação Força e Torque em cada uma das juntas do robô. Esse método utilizado, apesar de compensar as incertezas do modelo tais como variação do *payload* ou fricção e não requerer experimentos extensivos para identificação do modelo, ainda requer uma sintonia do processos com uma quantidade bastante elevada de parâmetros. Os autores propõem um método para detecção de anomalias em robôs manipuladores utilizando algoritmos não supervisionados em busca da resolução do problema em identificar o momento exato em que o ocorre uma colisão. Os algorítimos utilizados para a detecção de anomalias foram o *One-Class Support Vector Machine* (OC-SVM) que é um classificador bastante conhecido e um *autoencoder* que é uma rede neural, ambos amplamente aplicados e difundidos para a tarefa de reconhecimento de anomalias. No trabalho os autores dão maior ênfase em separar as *soft colisions*, as quais podem ocorrer a qualquer momento em virtude das alterações mecânicas da estação, e as *hard colision*, que de acordo com o trabalho, são as consideradas anomalias pois podem danificar o equipamento. Ainda uma terceira classe de dados foi gerada, as quais foram consideradas normais ou *colision-free*. Para a geração dos dados de colisão foram utilizados ferramentas de colisão desenvolvidas pelos autores, que é um resistor sensível à força coberto por uma placa de deformação. Os dados gerados pelo sensor foram considerados na escala de tempo, ou seja um evento considerado *hard-colision* levou até 100ms de duração, já o *soft-colision* levou entre 100 e 700ms de duração. Outro ponto importante a ser observado na coleta de dados é que existe uma sobreposição de valores de torque entre as classes de colisão, ou seja, em um caso prático onde não há um observador, as classes poderiam ser misturadas causando erros de classificação. No caso do experimento dos autores, todos os dados foram gerados em laboratório e contabilizados individualmente o lhes deu a certeza de separação dos eventos para a geração das classes. Ao final das análises e dos testes dos dois algoritmos, chegou-se a conclusão que ambos funcionaram

adequadamente na tarefa de identificação e separação dos tipos de colisão, com uma leve melhora em termos de performance da rede neural. Um complicador na utilização do método em larga escala é a utilização do modelo matemático na geração dos dados para análise e treinamento do modelo, pois nem todos os fabricantes de robô fornecem a equação. Outro ponto importante a ser observado no trabalho dos autores é que a curva de dados de torque ou de corrente não foi levada em consideração no estudo, somente os dados do sensor foram considerados para a geração e treino do algoritmo. Esta dissertação pretende mostrar que somente com as variáveis obtidas diretamente do robô em tempo real é possível fazer a detecção de um estado anômalo, como por exemplo uma colisão, sem a necessidade de utilização do modelo matemático ou de qualquer sensor adicional para tal finalidade.

Detecção antecipada de falhas é crucial para garantir segurança e alto desempenho de sistemas de acordo com (HORNUNG *et al.*, 2014). O foco daquele trabalho é desenvolver um algoritmo capaz de detectar os mais diversos tipos de anomalia em um robô. Para isso, o foco do estudo é a utilização da metodologia de *data-driven*. O maior desafio, segundo o autor, é a impraticabilidade em gerar e gravar dados reais de falhas, pois tais eventos são causados não apenas por problemas de *hardware*, como por exemplo desgaste mecânico, mas por uma combinação de fatores os quais não podem ser exaustivamente simulados. Pensando nesse aspecto os autores propõem a utilização de um método semi-supervisionado chamado de RADS - *Robot Anomaly Detection System*, o qual tem a capacidade de aprender continuamente os dados validos durante uma operação normal, criando uma representação compacta de tais estados, depois passando de treinamento para aplicação essas anormalidades são detectadas e correspondentemente identificadas. O método foi validado utilizando um robô Kuka *Light Weight Robot* (LWR). O método inicia com o cálculo dos mapas de dados de estados válidos e inválidos, entre eles torques das juntas e dos motores, correntes, temperaturas das juntas e carga aplicada. Os mapas servem então para gerar duas classes distintas, as quais são separadas por uma SVM, garantindo uma decisão rápida. Quando uma nova condição de operação é exigida, como a troca de uma ferramenta ou a operação do robô em uma nova área e trabalho, o sistema pode ser corrigido se necessidade dos dados de treinamento antigos. Os testes com o robô foram simulados em um ambiente de teste, fazendo com que o mesmo se move-se em diferentes trajetórias e causando distúrbios durante o percurso, mantendo o robô no ponto final por 5 segundos. A partir da base de dados concretizada, partiu-se para a definição dos métodos a serem testados. Os métodos escolhidos para analise do dados foram o *Support Vector Machine*

(SVM), *Robot Anomaly Detection System* (RADS), *Principal Component Analisys* (PCA) e *High-Dimensional Robot Anomaly Detection System*(HDRADS). O método RADS consegue trabalhar bem com dados positivos e negativos, incrementando a robustez e generalização do modelo, o problema da generalização pode ser resolvido com a utilização do PCA, porém a projeção e reprojeção somente aplicadas não são seguras na diferenciação das anomalias. O autor destaca as dificuldades computacionais e a limitações de cada método isolado e as vantagens na detecção da anomalia quando combinados, porém ao mostrar o resultado prático da detecção de colisões, de acordo com o texto, forçadas de forma artificial, o gráfico apresentado mostra apenas o torque no eixo 1. Essa dissertação pretende mostrar que é possível identificar anomalias em qualquer eixo do robô, inclusive quando a anomalia ocorre simultaneamente em mais de um eixo.

Em um outro trabalho realizado por (KAYAN *et al.*, 2023), um *dataset* com os dados de um braço robótico real foram analisados através de uma *Convolutional Neural Network* (1D-CNN). A CNN tem a capacidade de extrair características de uma série temporal, logo o modelo gera predições com base nas entradas da janela de dados permitindo assim, o desenvolvimento desse sistema proporciona não somente a detecção de anomalias, mas também *forecasting* e manutenção preventiva. Através do *dataset* inicial foram gerados outros quatro arquivos, sendo que o utilizado para a analise foi o que contem os dados de unidade de medida inercial. Com as variáveis de entrada acelerômetro, giroscópio e magnetômetro, sendo 3 por eixo realizou-se a conversão para janelas de entrada do modelo de *machine learning*. Através da predição de cada entrada foi calculado o residual, Se o valor do residual estiver acima de um determinado *threshold* a entrada é considerada uma anomalia. Um dos limitantes desse método é a complexidade computacional para uso em dispositivos *edge*, como proposto aqui neste trabalho.

Uma outra referência seguindo a linha de detecção de anomalias em robôs industriais é o trabalho desenvolvido por (CHEN *et al.*, 2020), o qual afirma que a monitoração de forma *online* de robôs industriais é fundamental para o perfeito funcionamento das linhas de produção, evitando assim quebras indesejadas e perdas econômicas. Os autores propõe um método não supervisionado para a detecção de anomalias de robôs utilizando o *Sliding-window convolutional variational autoencoder* (SWCVAE) o qual é capaz de realizar a detecção em tempo real. O modelo foi testado em um robô Kuka KR6R900. O modelo realiza a analise de dados espaciais e temporais se utilizando apenas do dados gerados pelo robô, sem a necessidade de instalação de qualquer sensor adicional. Para expressar as características da série de dados multi variado é

aplicado aos dados de entrada o *autoencoder* variacional convolucional baseado em janelas, para capturar dentro de uma longa janela, a dependência temporal da série de dados periódicos. O robô realiza a tarefa de *pick and place* tendo como garra uma ventosa. Uma câmera posicionada na área de trabalho realiza o envio das coordenadas para o robô realizar a pega do objeto. A comunicação entre o robô e controlador, um S7-1200 da Siemens se da via rede Profinet, o CLP realiza a coleta dos dados para análise. Para o treino e teste foram utilizados os dados de ângulo e corrente das juntas dos seis eixos com uma taxa de amostragem de 33.3Hz. A análise dos dados dos ângulos das juntas são importantes para extrair do robô as características dinâmicas, enquanto que as correntes são mais susceptíveis aos distúrbios externos. Utilizando o método proposto e tomando como referência os indicadores F1 *Score* e *Precision Recall Curve* foram obtidos os valores de 88,71 e 90,93% respectivamente, indicando resultados satisfatórios para a detecção de anomalias. A complexidade computacional do método proposto também pode ser apontada como um limitador para dispositivos *edge*.

A Tabela 1 apresenta um resumo das principais diferenças entre os trabalhos correlacionados que foram pesquisados como referencia para o trabalho.

Tabela 1 – Resumo dos trabalhos correlatos

Autor	Tema	Modelos	Variáveis	Anomalias	Método
Hornung (2014)	Segurança e alto desempenho do robô	SVM, PCA, RDAS e HDRADS	Torques das juntas e motores, temperaturas, correntes e cargas	Colisões artificiais geradas durante a trajetória	Data-driven (duas classes)
Chen (2020)	Monitoramento online KR6R900	SWCVAE	Angulos e correntes	Somente dados normais	Slide Window (dinâmica e estática)
Zhang (2021)	Colisões online robô colaborativo LWR4+ 7 graus liberdade	LDA, kNN, SVM e FNN	Sensores de torque dos 7 eixos	Martelo macio, luva e esfera plástica	3 labels (amplitude)
Park (2021)	Segurança do operador e manutenção do robô	OC-SVM e rede neural	Modelo matemático e sensor picos de corrente	Resistência sensível a força coberto por uma placa de deformação	2 labels (duração evento)
Kayan (2023)	Modelo matemático de um braço robótico	1D-CNN	Acelerômetro, giroscópio e magnetômetro	Sem geração de colisões	predição do threshold (residual inercia)

Fonte: Autoria própria

A contribuição desse trabalho de pesquisa é utilizar uma estação automática com robô industrial de uma planta fabril para o desenvolvimento de um algoritmo de *machine learning* capaz de detectar anomalias de posicionamento. Diferente dos trabalhos correlatos utilizados como base para a pesquisa, os quais foram todos desenvolvidos em ambiente de laboratório sob condições controladas e conhecidas, este trabalho irá mostrar que é possível aplicar toda a teoria de desenvolvimento e implementação de um algoritmo de *machine learning* desde a

fase inicial que é a coleta dos dados até sua implementação prática na máquina e colocação em funcionamento.

3 METODOLOGIA

Este capítulo apresenta, inicialmente, um descritivo do processo industrial analisado. Em seguida, são detalhadas as etapas da metodologia e requisitos do projeto como um todo. Posteriormente, o *dataset* construído é apresentado, incluindo a organização adotada para os dados, pré-seleção e seleção das variáveis. Finalmente, o treinamento dos modelos é apresentado em conjunto com as métricas e avaliação dos resultados, além dos detalhes de implementação prática da solução proposta.

3.1 DESCRITIVO DO PROCESSO

O robô alvo do estudo desse trabalho é parte integrante de uma estação automática pertencente a uma linha de produção que realiza a montagem de um produto. Cada uma das estações da linha de produção é responsável por uma parte da montagem do produto final. Ou seja, cada processo agrega valor ao produto realizando a montagem de componentes. Devido ao termo de sigilosidade de produto, chamaremos apenas *produto* como sendo a parte a qual recebe os componentes, e *componente* aqueles que são montados no produto em cada etapa. Na estação de trabalho o produto e o componente chegam em um palete em posições mecânicas definidas através de um sistema de transportador de correias. Ao chegar o palete à estação, o robô realiza a retirada de uma máscara que garante a posição mecânica do componente o qual já está pré-montado no produto. Em seguida, o robô realiza a retirada do produto do palete e deposita na estação de medição, onde existe um equipamento de medição pneumática que fará a medição de diâmetro de um furo através da injeção de ar comprimido. Após o resultado dessa medição o robô realiza a retirada de um componente na medida de acordo com o resultado da medição do produto, de um dos paletes que se encontram indexado em uma calha de alimentação. A peça também precisa ser medida para garantir o perfeito *match* entre ambas. A medição também é feita com um dispositivo pneumático, o qual faz a leitura do diâmetro do componente. Caso a medida esteja aceitável dentro dos limites previstos de tolerâncias o robô realiza a montagem do componente dentro do produto e devolve o conjunto ao palete. A Figura 3 mostra a sequência de passos do processo da estação em modo automático.

A estação é composta por um controlador industrial CX5140 da Beckhoff, dispositivos de medição analógicos, sistemas de segurança e o robô Kuka KR6R900. A Figura 4, mostra a

Figura 3 – Sequência de trabalho da estação

Fonte: Autoria própria

configuração das redes e comunicações entre os dispositivos.

Figura 4 – Arquitetura de redes e comunicações

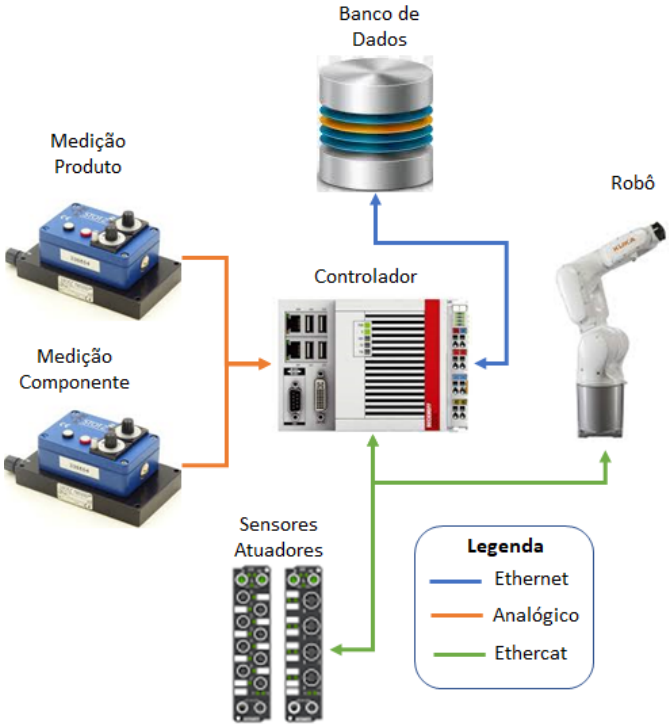

Fonte: Autoria própria

O controlador industrial realiza todo o comando da estação. A cada chegada de produto, o controlador realiza a consulta ao banco de dados para garantir que o produto já tenha sido processado na estação anterior e possui um resultado aprovado. Logo após, os parâmetros de montagem do produto são carregados. O controlador comanda o robô para realizar a manipulação do produto e componente dentro da estação, faz a aquisição dos dados das medições analógicas

e, ao final, reporta os dados do processo e os dados do robô para o banco de dados.

O objetivo de reportar os dados de produção para o banco de dados é ter a rastreabilidade do processo de montagem para todos os produtos produzidos. Já o armazenamento dos dados do robô, que é o objeto de estudo desse trabalho, é a análise do funcionamento. De posse dos dados do robô, é possível a realização de diversas linhas de estudos e pesquisa, tais como, determinação de falhas, manutenção preditiva e detecção de anomalias – foco deste trabalho.

3.2 ETAPAS DO DESENVOLVIMENTO

O objetivo principal do trabalho é entregar como resultado para a linha de produção na qual o robô está instalado, uma abordagem de detecção prematura de desvios do robô, tomando como referência algumas variáveis inicialmente consideradas importantes para os estudos e análises iniciais. A escolha das variáveis iniciais teve como base a literatura publicada em alguns artigos relacionados com o tema do trabalho. Em seguida, o trabalho seguiu a metodologia de desenvolvimento mostrado na Figura 5 e detalhados conforme segue.

Figura 5 – Metodologia de projeto

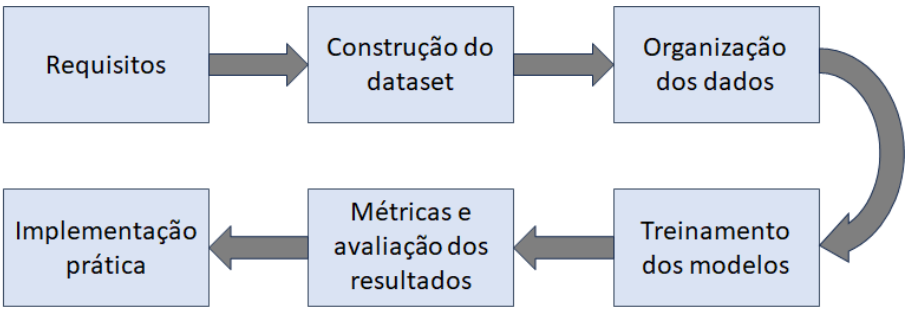

Fonte: Autoria Própria

3.3 REQUISITOS

A definição clara e objetiva dos requisitos iniciais de um projeto é fundamental para o planejamento correto das fases e atividades ao longo de todo o desenvolvimento do trabalho. No âmbito industrial, levando em consideração a aplicação de projetos que envolvem a utilização de algoritmos de aprendizado de máquina, é necessário seguir os passos da metodologia de implementação em máquinas, a qual determina as etapas de evolução iniciando pelo levantamento dos requisitos, até a manutenção e melhorias do modelo já em funcionamento.

3.3.1 ENTENDIMENTO DO PROBLEMA

A necessidade de detecção de anomalias em robôs industriais surge através de duas demandas: necessidade de planejamento de uma manutenção preventiva mais assertiva e da necessidade de manter o equipamento em operação o maior tempo possível sem apresentar falhas. Um robô manipulador depende diretamente da confiabilidade da estrutura mecânica de posicionamento das partes a serem manipuladas para o sucesso da operação. Componentes mecânicos estão sujeitos a desgastes em função do tempo de utilização. Esses desgastes muitas vezes podem ser pequenos e imperceptíveis aos olhos humanos, porém para tarefas de precisão, como é o exemplo da manipulação feita pelo robô que é utilizado neste trabalho que é de 0,02 milímetros, esse desgaste pode se tornar um erro de posição gerando um contra-torque no braço robótico que pode levá-lo a parada de operação. Quando o robô não consegue retirar ou depositar a peça manipulada na posição exata que foi ensinada – ponto de trabalho – pode ocorrer um esforço adicional nos eixos o que pode levar a diversos tipos de problemas, desde a perda de sincronismo entre a transmissão mecânica e a monitoração de posição como uma quebra de um componente mecânico como por exemplo, uma correia de transmissão.

Falhas podem estar relacionadas não somente ao *hardware* como citado anteriormente, mas também ao *software* e podem incluir problemas com comunicação, desgastes e quebra de sensores, especialmente nos primeiros estágios do distúrbio. Essas falhas não necessariamente resultam em uma parada, uma vez que algoritmos de controle presentes no *software* de controle do robô podem atuar modificando valores de medição e controle (HORNUNG *et al.*, 2014).

3.3.2 EXPECTATIVAS

A expectativa inicial do projeto é ter um algoritmo sendo executado em tempo real no controlador, com a capacidade de interpretação dos dados e consequente tomada de decisão em virtude do cenário apresentado.

3.3.3 GANHOS

Entre os ganhos do projeto pode-se listar:

- Aumento do tempo de produção através da redução de paradas não planejadas;

- Aumento da vida útil do equipamento;
- Melhoria nos indicadores de performance de produção: Eficácia Geral do Equipamento (do inglês, *Overall Equipment Effectiveness* – OEE) e Taxa de Produtividade (do inglês, *First Pass Yield* – FPY).

3.3.4 DESAFIOS

Os desafios são:

- Coleta de dados totalmente desconhecida inicialmente. Não era possível determinar quais dados seriam úteis para o projeto e se todos poderiam ser disponibilizados;
- Taxa de amostragem. Inicialmente o projeto focou na maior taxa de amostragem possível com o objetivo de estudar e interpretar os dados;
- Poucas amostras com anomalias em comparação com as amostras normais;
- Realizar alterações de programação de CLP e robô em uma linhas de produção sem causar distúrbios;
- Geração de dados de anomalia durante o processo produtivo sem interrupção.

3.4 CONSTRUÇÃO DO *DATASET*

Inicialmente, a coleta dos dados foi idealizada para obtenção da maior quantidade de informações possíveis, uma vez que não era conhecido o momento ou os momentos dentro do ciclo da estação onde poderiam ocorrer as anomalias. Como já comentado anteriormente, um programa de robô normalmente é bastante curto, pois o equipamento é um escravo da estação, executando os programas de acordo com as definições de um controlador. Um programa comum de robô começa em geral com uma posição inicial chamada *Home Position*. Logo após, move para um ponto de segurança onde não há risco de colisão, em seguida, para uma posição de aproximação do ponto de interesse, normalmente logo acima o qual seguirá para a posição de pega/depósito da peça, retornando para uma posição que pode ou não ser a mesma de aproximação e, finalmente, para uma posição de segurança seguida da *Home Position*. Todo esse ciclo representado na figura 6, não costuma levar mais que dois segundos para ser completamente executado.

Figura 6 – Sequencia de pontos

Fonte: Autoria Própria

Para fazer a aquisição de todos os dados de um programa, um arquivo em formato de texto é gerado a cada chegada de um novo produto à estação contendo o código do produto. Ao se iniciar a chamada dos programas do robô iniciam-se as capturas dos valores das variáveis selecionadas, as quais serão detalhadas na subseção 3.4.1. A aquisição dos dados se inicia com os valores iniciais das variáveis, a cada mudança de valor de uma das variáveis, uma nova linha de armazenamento é gerada com todos os valores atuais e assim por diante, até o final do ciclo da máquina. Dessa forma um arquivo pode conter tantas amostras quantas forem as mudanças de valor das variáveis durante a execução do processo.

Considerando a coleta de dados e escrita dos mesmos em arquivo, foram obtidas inicialmente, algo entre 1500 a 2000 linhas dados para um processo considerado como ciclo normal. Em apenas um dia de produção são produzidas em torno de 3000 peças, ou seja, considerando um valor médio de 1750 amostras por ciclo, tem-se aproximadamente 5.250.000 amostras em apenas um dia, com 34 atributos os quais estão descritos em detalhes na Subseção 3.4.1. A primeira tentativa de processamento dos dados de um mês de produção se mostrou inviável devido à grandeza da matriz de entrada. Para prosseguir com a análise, o foco foi realizar a análise por produto e por programa do robô, reduzindo assim a quantidade de dados a serem

processados pelo método de detecção de anomalia.

A estabilização e entendimento dos dados coletados foi mais um desafio do trabalho, pois houveram alguns problemas com a geração, coleta e armazenamento dos dados. A geração dos dados do lado do robô precisou levar um fator de multiplicação dos valores das variáveis a serem transmitidas, pois o formato da variável de saída era uma *double word* com 32 bits, variável essa que não consegue passar valores decimais, logo os valores foram multiplicados por um indexador variando de 10 a 1000 a depender do range de variação de cada variável, passando pela divisão do mesmo fator do lado do CLP. Outro problema encontrado foi a ausência de um padrão de forma de onda para qualquer uma das variáveis. Percebeu-se então que havia um erro de coleta causado pelo *software* de escrita dos dados no arquivo. Resolvido o problema anterior, descobriu-se uma mistura de dados entre dois arquivos consecutivos, ou seja, existiam arquivos que divergiam da média de amostras contidas. Alguns arquivos possuíam muitas amostras acima da média e outros muito abaixo da média. Notou-se então, que esse fato ocorria sempre em dois arquivos em sequência. Como a estação pode trabalhar com o processamento de até duas peças por vez, executando tarefas distintas para cada peça, percebeu-se que havia a ocorrência de parte do ciclo de aquisição de um ciclo ser armazenado em outro arquivo. Esse problema foi resolvido fazendo a implementação de um *index* de separação das duas peças, tornando o sistema de coleta apto para armazenar os dados necessários.

3.4.1 VARIÁVEIS MONITORADAS

Antes de entrar no detalhamento das possíveis variáveis coletadas do robô para análise, é propício explicar sobre a composição dos eixos e das bases existentes em um robô. O robô utilizado para o estudo possui seis graus de liberdade, ou seja, seis eixos com acionamento e controle individuais interligados através de elos e juntas mecânicas individuais. A Figura 7 mostra a nomenclatura que normalmente é atribuída aos robôs industriais, começando no eixo A1, que é a base para todos os outros, e terminando no eixo A6, o qual possui uma flange mecânica onde se encontra a montagem da ferramenta de trabalho, ou também chamada de garra.

Outro conceito fundamental para o entendimento da arquitetura de um robô é a definição das bases. Todo robô industrial é orientado através das chamadas bases, que são as referências para a determinação dos movimentos de um ponto ao outro. De forma geral, todos os robôs possuem no mínimo duas bases criadas, as quais fazem parte dos dados de máquina, que são a base de coordenadas *WORLD* que está localizada entre o pedestal de sustentação do robô e o

Figura 7 – Eixos do robô

Fonte: (KUKA, 2019)

início do eixo A1 e a base da ferramenta que está localizada na flange do eixo A6, conforme mostrado na Figura 8.

Figura 8 – Eixos do robô

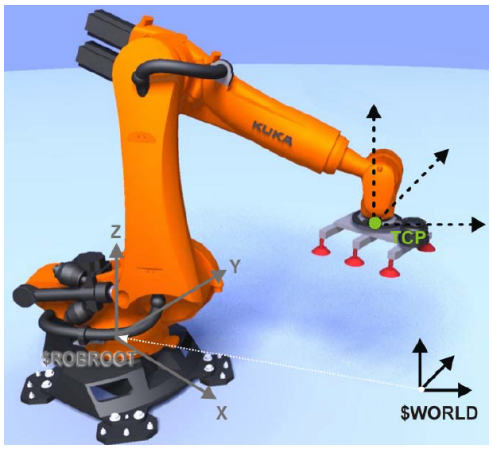

Fonte: (KUKA, 2019)

Um robô industrial, como qualquer outra máquina, possui diversas variáveis de trabalho. Essas variáveis podem ser lidas e armazenadas para posterior estudo e análise. Algumas delas são temperatura, torque e corrente dos servomotores e posicionamento cartesiano. Cada movimento do robô no espaço é uma trajetória entre dois pontos de coordenadas cartesianas tridimensional, ou seja, existem valores nos eixos lineares X, Y e Z, nos eixos rotacionais A, B e C. Porém, somente essas informações não são suficientes para definição de posição no espaço sem que ocorra o fenômeno da ambiguidade. A Figura 9 mostra um exemplo do que pode ocorrer na prática. A mesma posição é atingida com eixos em posições diferentes.

Logo, variáveis adicionais para orientação mecânica também fazem parte do vetor posição de um robô. Essas variáveis são *Status* (S) e *Turn* (T). Um vetor de posição de um robô é

Figura 9 – Mesma posição final com eixos em posições diferentes.

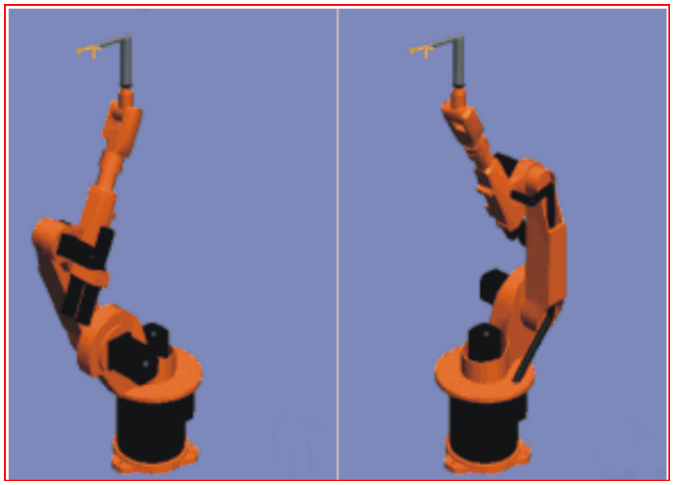

Fonte: (KUKA, 2019)

representado no seguinte formato: $Pos = \{X, Y, Z, A, B, C, S, T\}$.

A variável *Status* é uma composição de 3 bits que indicam em qual área os eixos do robô se encontram. Como por exemplo, se o mesmo está operando abaixo ou acima da linha de centro, se o eixo A3 está operando no quadrante positivo ou negativo, etc. O bit 0 é utilizado para especificar a posição de interseção dos eixos que fazem a formação do punho que são os eixos A4, A5 e A6:

- Se bit 0 = 1, então significa que o robô se encontra na posição chamada de *overhead*, ou seja, o valor da coordenada X que forma a interseção dos eixos A4, A5 e A6 em relação as coordenadas do eixo A1 é negativo;

- Se bit 1 = 1, então o robô está na *basic area*, ou seja, o valor da coordenada X que forma a interseção dos eixos A4, A5 e A6 em relação as coordenadas do eixo A1 é positivo.

O bit 1 da variável *Status* indica a posição do chamado "cotovelo", que é o eixo A3. Se o valor do ângulo do eixo A3 for maior ou igual a zero, o bit 1 assume o valor 1, caso contrário o valor é 0. O bit 2 é utilizado para determinação da posição do eixo A5, tomado como base a relação com a posição 0 do eixo A4. Se o eixo cinco for igual a zero ou estiver inclinado para cima o valor do bit 2 será igual a 1; caso contrário, o valor assumido será igual a 0.

A variável *Turn* indica exatamente a orientação do ângulo de cada eixo. A Tabela 2 mostra os valores dos bits para cada combinação de T para cada eixo. Essa variável é apresentada no formato de *struct* do tipo Real, sua sintaxe na linguagem de programação do robô é E6POS. Por se tratar de uma estrutura de dados, cada variável que compõe o vetor pode ser acessada

individualmente, por exemplo adotando-se o nome da variável como *Pos*, o valor do eixo Z pode ser lido através da sintaxe *Pos.Z*, assim com todos os demais valores.

Tabela 2 – Valores da variável T.

$Valor$	$Bit5$	$Bit4$	$Bit3$	$Bit2$	$Bit1$	$Bit0$
0	A6≥0°	A5≥0°	A4≥0°	A3≥0°	A2≥0°	A1≥0°
1	A6<0°	A5<0°	A4<0°	A3<0°	A2<0°	1<0°

Fonte: (KUKA, 2019)

Para o estudo desse trabalho, algumas variáveis foram escolhidas para armazenamento e posterior análise:

Posição: Qualquer posição do robô pode ser lida em qualquer momento, esteja ele executando um programa ou não. Como um movimento do robô pode gerar uma infinidade de pontos no espaço, é necessário que um ou mais pontos específicos sejam indicados para a coleta de interesse. No caso deste projeto, optou-se por coletar somente o ponto em que o robô toca no produto ou nos componentes, por entender que esse é o momento no qual se deseja realizar a análise. O formato dessa variável é o E6POS, já detalhado anteriormente.

Torque atual: O torque atual de um robô é o valor que está sendo exercido pelos eixos ao longo de uma trajetória. Esse valor é a interpretação das leituras das variáveis dos servomotores. O valor de cada torque está disponível através da variável de sistema do tipo *struct*, chamada `$TORQUE_AXIS_ACT`, a qual é valida para leitura sempre que o freio do motor estiver liberado. Se o freio estiver atuado, o valor lido é igual a zero. O valor é atualizado na variável do início ao final de um movimento ou um programa, sendo possível aquisição do dado tão rápido quanto for a leitura do controlador ou da rede. Para acessar cada uma das variáveis dos eixos de forma individual, é necessário indicar o eixo correspondente da seguinte forma: `$TORQUE_AXIS_ACT[eixo]`, onde o valor de eixo pode variar entre 1 e 6.

Temperatura: Um dado importante para a monitoração e manutenção de um robô é a temperatura de trabalho dos eixos. Esse valor é disponibilizado para leitura em tempo real através da variável `$MOT_TEMP`.

***Holding* Torque:** Trata-se de um valor calculado a partir do modelo dinâmico do robô. Diferente do torque atual, o *Holding* torque leva em consideração a carga e a posição especifica em que o robô se encontra. Essa variável assim como as demais também *struct* e pode ser acessada através da variável de sistema chamada `$HOLDING_TORQUE`.

Corrente: Uma variável muito importante no contexto de análise preditiva e de falhas é a corrente de um motor. No caso do robô, todas as correntes dos servo motores são monitoradas

durante todos os momentos, mesmo que esteja o robô parado e com os freios atuados. A variável que monitora esses valores é a `$CURR_ACT`.

Sendo assim, o total de variáveis coletadas é de 34, sendo: uma variável de tipo do produto, uma variável de programa do robô executado, oito variáveis de posição, seis varáveis de temperatura, seis varáveis de corrente, seis varáveis de torque atual e seis varáveis de torque calculado.

No programa do robô, também foram criadas variáveis que adicionam um valor às coordenadas cartesianas (X, Y e Z) no momento de pega ou depósito do produto, o que conduz o robô ao ponto incorreto, simulando uma alteração de posição mecânica do dispositivo de suporte do produto.

O dataset mostrado na Tabela 3 apresenta a divisão de amostras e as classes por produto, totalizando de 6516 amostras, sendo 6242 consideradas normais e as demais 274 são as anomalias, o que caracteriza um dataset desbalanceado, como geralmente observado em casos de detecção de anomalias. Para a geração dessa quantidade de anomalias foi necessário um grande esforço e coordenação em conjunto com o pessoal de produção, pois como trata-se de uma máquina real que está em operação não se pode interferir a qualquer momento e também não se pode causar paradas, sendo essa tarefa uma das mais complicadas de ser realizada, uma vez que para a geração de anomalias é fundamental que o robô esteja em funcionamento, para que as situações detectadas e registradas para posterior estudo, sejam as mais condizentes com a realidade da máquina. Cada um dos valores de *target* possui uma variação de anomalia gerada de forma sintética. Ou seja, o robô foi induzido ao erro propositalmente para o levantamento de dados artificiais de anomalias para possibilitar o treinamento do modelo. O significado de cada valor de *target* é o seguinte:

- 0: dado sem anomalia;
- 1: anomalia gerada somente no eixo X;
- 2: anomalia gerada somente no eixo Y;
- 3: anomalia gerada somente no eixo Z;
- 4: anomalia gerada nos eixos X e Y;
- 5: anomalia gerada nos eixos X e Z;
- 6: anomalia gerada nos eixos Y e Z;

- 7: anomalia gerada nos eixos X, Y e Z.

Tabela 3 – Resumo do *dataset*.

Produto	Target	Amostras
A	0	939
	3	8
	4	4
	5	16
	6	10
	7	18
B	0	3454
	1	13
	2	20
	3	20
	4	11
	5	11
	6	33
	7	20
C	0	370
	5	7
	6	3
D	0	976
	4	28
	6	27
	7	18
E	0	503
	5	7

Fonte: Autoria própria

A geração de um *dataset* desbalanceado, como foi o caso mostrado na tabela 3, já era algo esperado. Na literatura utilizada como referencia para o trabalho, já havia a indicação de que as anomalias são poucas e restritas dentro de um conjunto de dados. Devido a todas as dificuldades para gerar os dados de anomalia, conforme mencionados anteriormente, esse foi o conjunto de dados escolhido para análise, com vários desbalanceamentos, tanto em relação a quantidade de amostras por produto, o que depende diretamente das ordens de produção, quanto da quantidade de anomalias em relação as amostras normais.

Um dos problemas que pode ocorrer quando se modificam as coordenadas cartesianas do robô visando a simulação de anomalias é que podem existir diferenças prévias entre o valor lido pelo resolver do servo motor e as juntas mecânicas, algo passível de ocorrer em uma máquina com servo acionamentos. Afim de garantir que não existam erros dessa magnitude, é realizado antes de iniciar o processo de geração de anomalias, o processo chamado de masterização dos eixos do robô, que é fazer com que a posição mecânica das juntas seja reconhecida e sincronizada com o valor do resolver. Esse procedimento consiste em levar todos os eixos do robô a uma posição conhecida e através de um dispositivo externo, fornecido pelo fabricante do robô, realizar

o ajuste de correção das relações entre resolver e juntas mecânicas. Fazendo isso antes de iniciar a coleta de dados de anomalias, é possível garantir que o robô se encontra sincronizado e que não haverão erros de odometria inseridos na coleta.

3.5 ORGANIZAÇÃO DOS DADOS

Uma vez definida a coleta dos dados, passou-se então, para a fase de análise da relevância das variáveis para o estudo, o que significa realizar uma interpretação preliminar do formato das curvas das variáveis para determinação do padrão normal e da anomalia, bem como a importância de cada variável no processo como um todo.

3.5.1 ANÁLISE DAS CURVAS E PRÉ-SELEÇÃO DE VARIÁVEIS

Dentre as 34 variáveis selecionadas para coleta, quase todas podem ser avaliadas na forma gráfica, com exceção do número de programa e do tipo de produto. A seguir, estão detalhadas as análises realizadas por grupo de variáveis.

Curvas de temperatura dos servo motores: Analisando as curvas de temperatura de cada eixo, pode-se perceber que não existem variações consideráveis durante a operação, seja ela normal ou em casos anômalos. Dessa forma, para a finalidade de encontrar desvios do padrão normal, essa variável não pode ser utilizada e foi descartada já inicialmente. A Figura 10 apresenta a estabilidade da temperatura ao longo de alguns ciclos de operação normal e anômalo. Entre as amostras 44 e 48 do gráfico 10, ocorrem anomalias, não havendo qualquer mudança no valor da temperatura dos servomotores, confirmando assim a exclusão dessa variável para a geração de um modelo.

Curvas de posição: Como já mencionado anteriormente, o motivador do estudo do trabalho era monitorar o posicionamento do robô no momento da retirada ou depósito da peça, pois devido aos desgastes mecânicos da estação ao longo da sua operação, poderiam induzir o robô ao erro, e assim seria possível notar essa diferença através do posicionamento. A Figura 11 mostra alguns ciclos considerados normais com a estabilidade dos valores coletados e a mudança dos mesmos para outro produto – amostra 38 – , que posteriormente permanecem estáveis. A variável de posição será mantida para análise na próxima etapa de seleção, dada a sua sensibilidade em mudanças de operação, conforme será detalhada na próxima Seção.

Curvas de corrente: Como citado por (CHEN *et al.*, 2020), a leitura direta das correntes

Figura 10 – Curvas de temperatura dos servo motores.

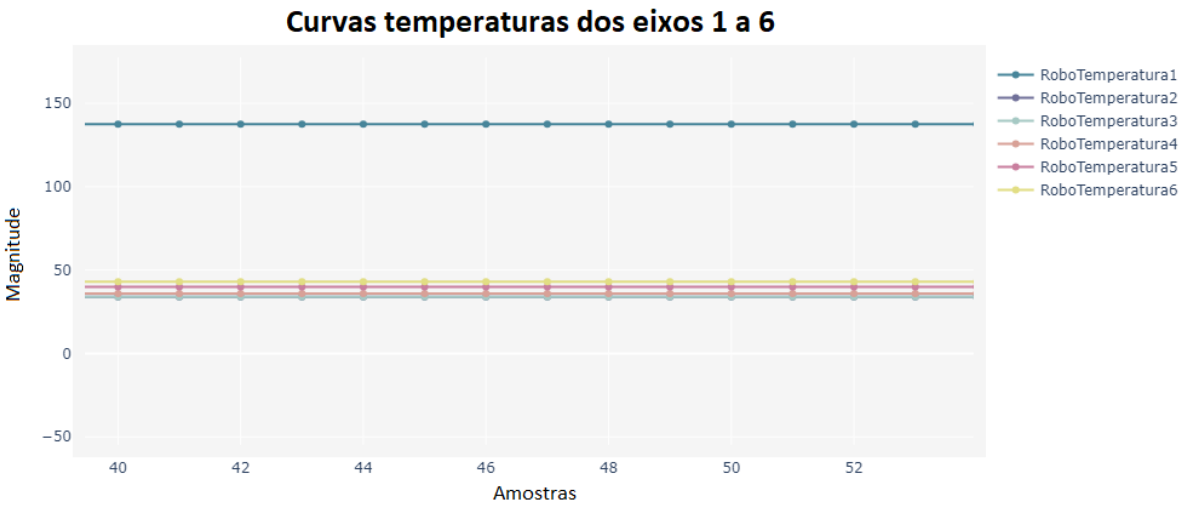

Fonte: Autoria própria

Figura 11 – Curvas de posição cartesiana.

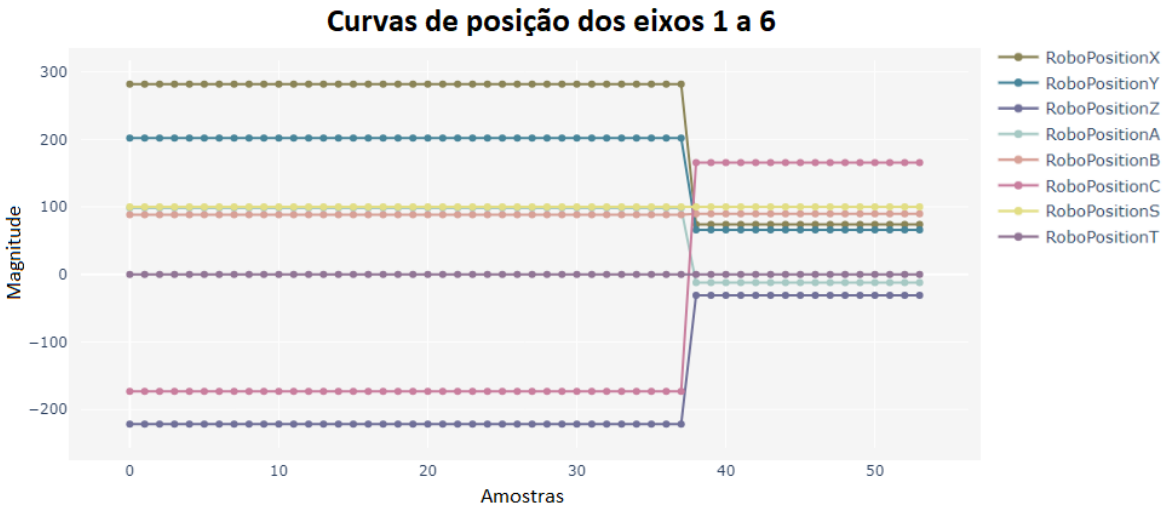

Fonte: Autoria própria

dos servomotores se mostram susceptíveis à distúrbios externos. Seguindo esse conceito, essas variáveis podem indicar mudanças abruptas no comportamento quando em situações de colisão. Neste trabalho, as curvas de corrente foram armazenadas à uma taxa de amostragem de 30ms, tempo esse suficiente para determinar o padrão de curva por eixo do robô. As correntes variam entre valores positivos e negativos de acordo com o movimento do robô e sentido de acionamento do servo motor. A Figura 12 mostra o perfil de corrente considerado normal para os seis eixos

do robô. A variabilidade nos diferentes ciclos de operação de um produto também indicam que, inicialmente, esta variável pode ser relevante para a análise.

Figura 12 – Curvas de corrente.

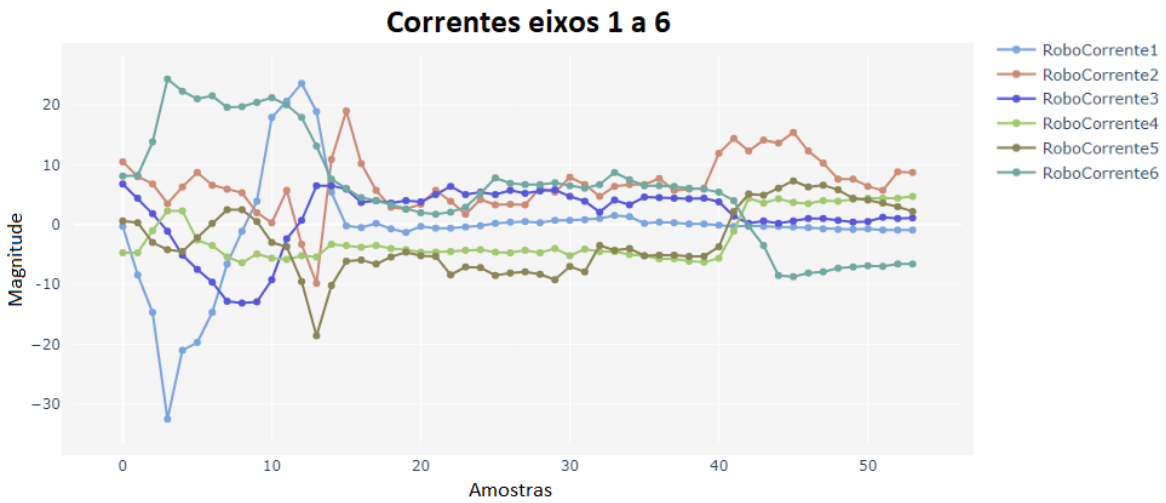

Fonte: Autoria própria

Curvas de torque: As curvas de torque do robô são os esforços aos quais as juntas mecânicas são submetidas, sendo essas, medidas através das correntes que são monitoradas por meio dos sistemas de controle dos servomotores. Como mostra a Figura 13, os torques nos eixos 1, 2 e 3 apresentam alterações significativas ao longo dos ciclos de operação do robô, enquanto os 4, 5 e 6 são estáveis e pouco afetados pela mudança de tarefas da máquina. De qualquer forma, todas essas variáveis são mantidas para a próxima etapa da análise.

Um detalhe importante é que corrente e torque apresentam informações muito similares para o servo motor deste robô. As Figuras 15 e 14 mostram o comportamento inverso das curvas dos eixos 1 a 3 para as variáveis torque e corrente. Dessa forma, chega-se à conclusão que a utilização de apenas uma das duas variáveis, corrente ou torque, já é suficiente para a análise – elimina-se redundância de informações. Portanto, o conjunto de variáveis escolhido foram os torques instantâneos (Torque Act) dos eixos 1 a 6, excluindo-se os sinais de corrente.

Curvas de torque calculado: As curvas de torque calculadas são definidas, conforme literatura do fabricante do robô, como *Torque Arm*. A variável *Torque Arm* de um eixo é um cálculo realizado a partir do modelo dinâmico, com referência à corrente atual e à corrente de carga (KUKA, 2019). Esse cálculo, realizado em tempo real pelo controlador, leva em consideração não somente o modelo matemático do robô mas também as correntes, a interferência das

Figura 13 – Curvas de torque.

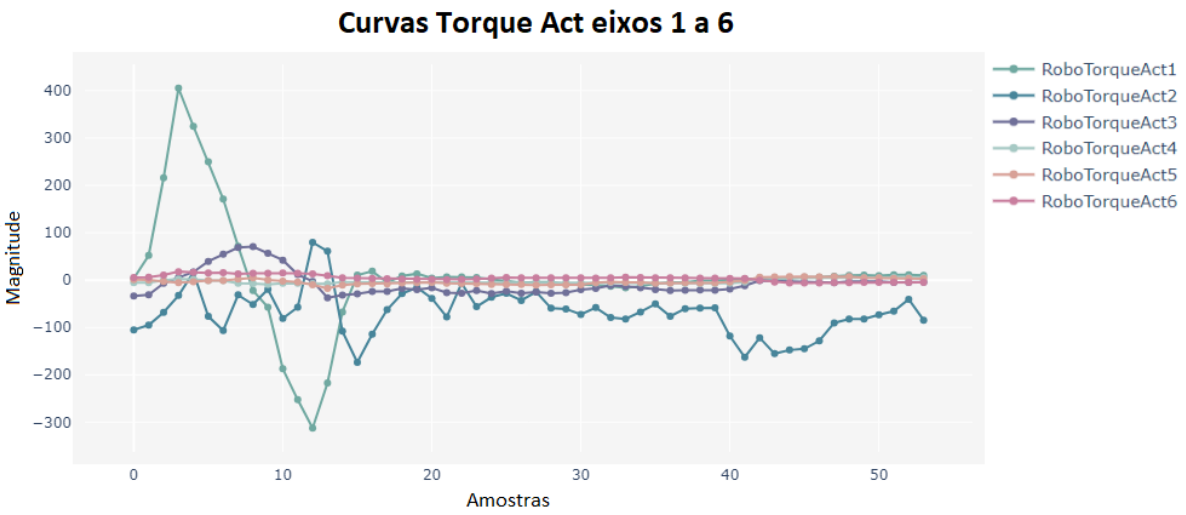

Fonte: Autoria própria

Figura 14 – Curvas de torque eixos 1 a 3 um ciclo.

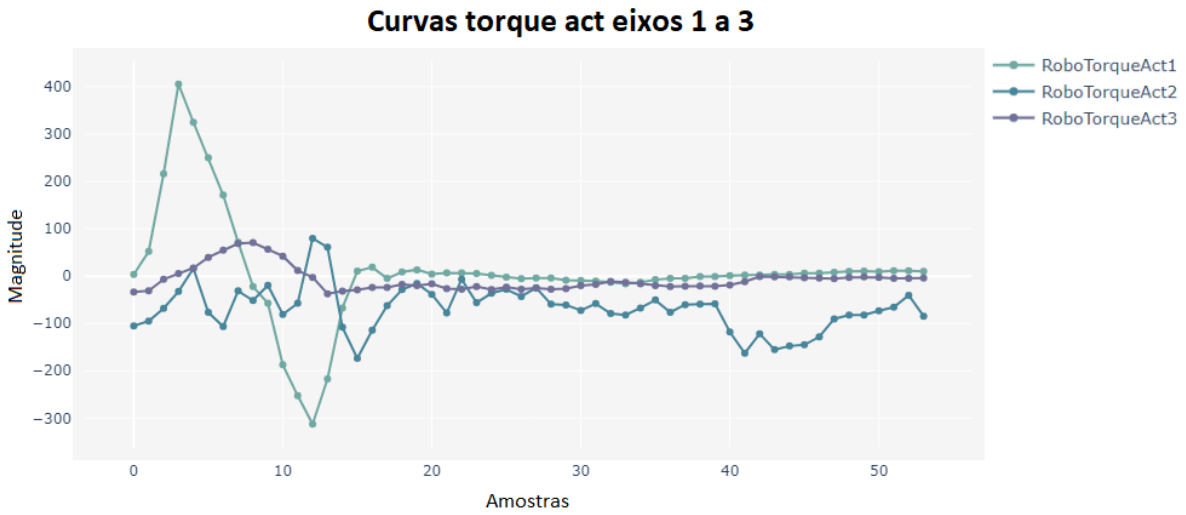

Fonte: Autoria própria

juntas, o atrito mecânico, a carga e os momentos de inércia. Essas variáveis são constantemente monitoradas durante o ciclo de operação para garantir a integridade da máquina. A Figura 16 mostra o perfil do torque de todos os eixos em situação considerada normal.

Percebe-se pelo formato gráfico que essas variáveis apresentam comportamentos bastante diferente da leitura direta das correntes ou mesmo do torque direto (Torque Act), como mostrado anteriormente, pois são torques calculados que dependem de outras variáveis do

Figura 15 – Curvas de corrente eixos 1 a 3 um ciclo.

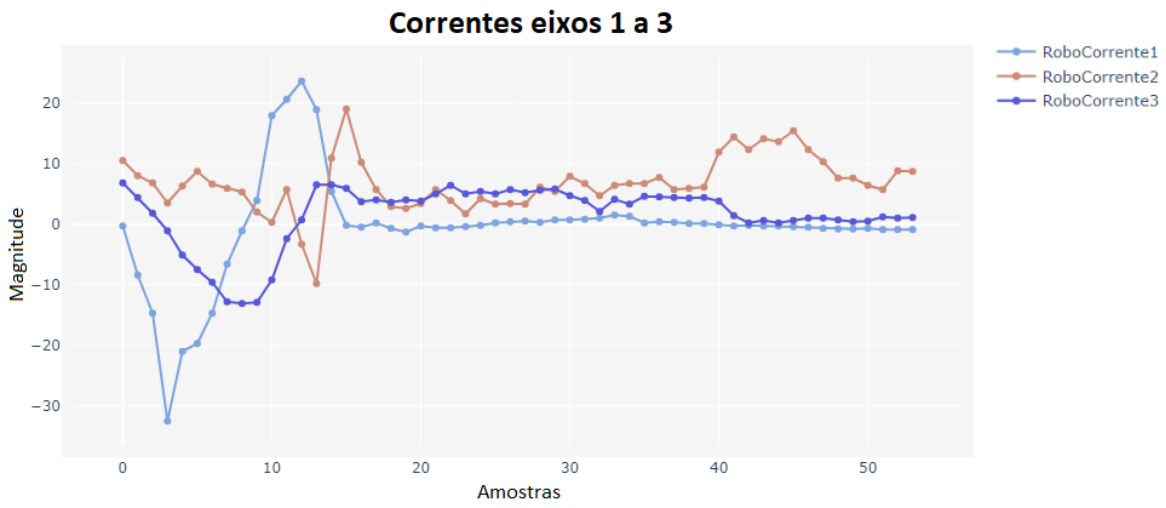

Fonte: Autoria própria

Figura 16 – Curvas de torque calculado.

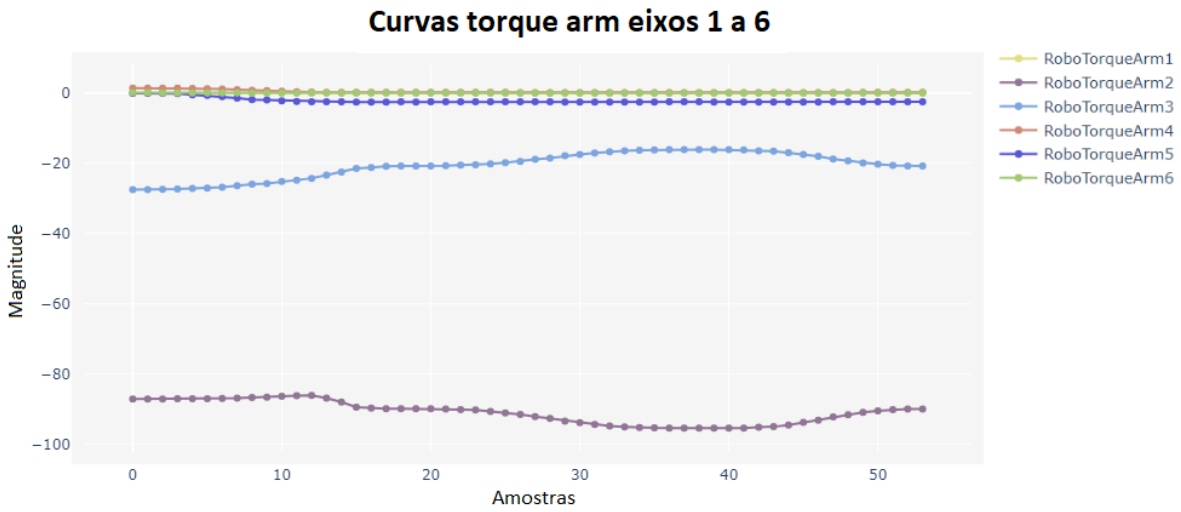

Fonte: Autoria própria

robô. Para o estudo das anomalias, essas variáveis serão mantidas para a fase de seleção de características, detalhada conforme segue.

3.5.2 SELEÇÃO DE CARACTERÍSTICAS

Com o intuito de fornecer uma redução ainda mais significativa no número de variáveis, mantendo somente as variáveis relevantes para a detecção proposta, utilizou-se o método de

seleção de características sequencial do tipo *Backward* (RASCHKA; MIRJALILI, 2019). Este procedimento inicia com todas as características, removendo aquelas que levam a um desempenho de detecção inferior a cada etapa do processo, que se repete iterativamente até que um número mínimo de características seja atingido. As características procuradas nos sinais foram: média, valor eficaz, amplitude, variância, desvio padrão, número de passagens por zero e conteúdo harmônico do sinal. Além disso, como classificador base durante a iteração, utilizou-se o *Isolation Forest*. Após essa etapa, as características selecionadas foram:

- a amplitude dos torques calculados do eixo 2 e 3;
- as amplitudes das posições X, Y e Z do eixo cartesiano;
- o desvio padrão do torque calculado do eixo 3.

É importante salientar que essa escolha das características não é o resultado de uma busca global de todas as combinações, já que o método de seleção de características utilizado não garante tal resultado. Outros subconjuntos de características apresentaram similares aos das características acima listadas. Porém, em função da simplicidade para implementação prática no CLP e por apresentarem resultados adequados numa análise preliminar, optou-se por manter somente amplitude/magnitude e desvio padrão.

As demais características avaliadas não foram utilizadas pois ou não traziam informações relevantes durante um evento de anomalia ou não eram tão expressivas quanto a amplitude e o desvio padrão.

3.5.3 ANÁLISE QUALITATIVA E QUANTITATIVA DAS CARACTERÍSTICAS SELECIONADAS

A Figura 17 mostra uma visão normalizada de todas as características selecionadas para o treinamento do modelo, onde não ocorrem anomalias. Inicialmente, a análise de detecção da anomalia através das posições X, Y e Z do plano cartesiano do robô são identificadas pelo atraso que ocorre na passagem de posição quando em situação anômala, conforme mostrado nas Figuras 18 e 19. É perceptível pela Figura 18, por exemplo, que ocorre a transição do valor de posição muito próximo da amostra de número 120. Já em condição de anomalia, essa mesma transição ocorre mais próxima da amostra 130, de acordo com a Figura 19. Deve-se considerar que as amostras são incrementais e que representam um ciclo de operação. Essa mesma condição

se repete para as demais variáveis de posição Y e Z. O mesmo padrão é percebido para os dois outros eixos (Y e Z), conforme mostrado nas Figuras 20, 21, 22 e 23

Figura 17 – Características normalizadas sem a presença de anomalias.

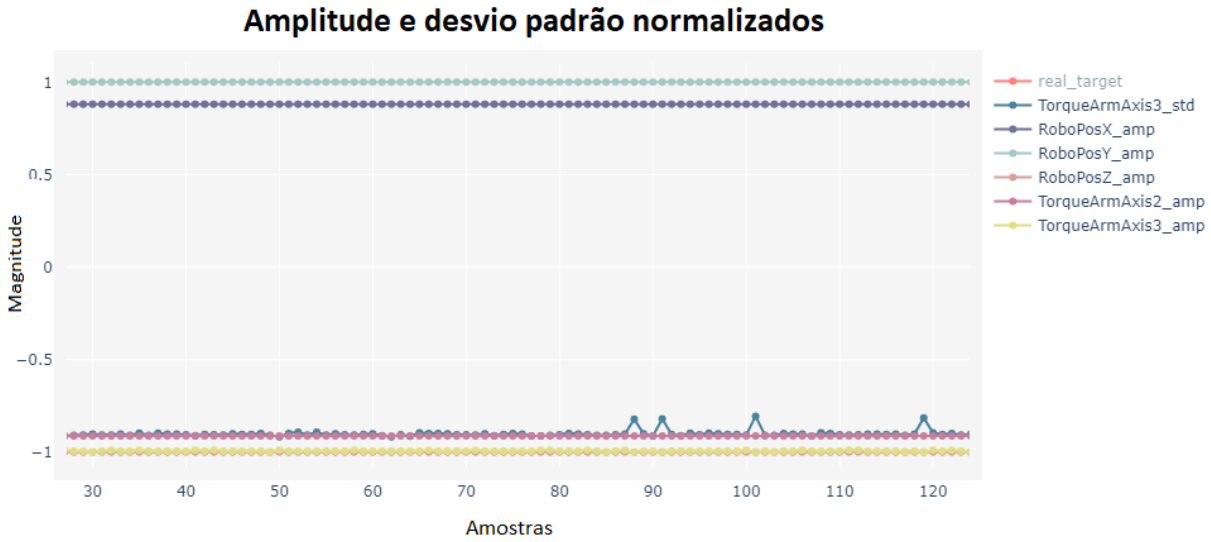

Fonte: Autoria própria

Figura 18 – Curva de posição do eixo X durante um ciclo normal.

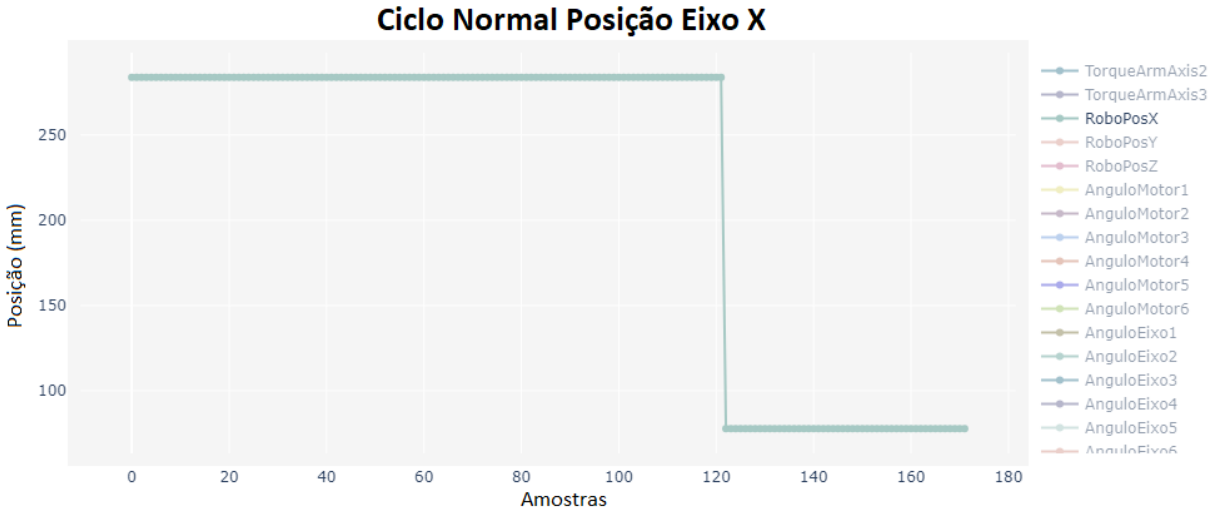

Fonte: Autoria própria

A Tabela 4 mostra as diferenças de valores de amplitude e desvio padrão entre um ciclo normal e um ciclo com anomalia para a variável posição do eixo X. Importante salientar que a detecção de uma anomalia leva em conta a combinação de alteração das variáveis monitoradas, de forma que a avaliação isolada de uma variável ou a aplicação de um *threshold* procurando identificar os desvios de amplitude ou desvio padrão não seria eficaz para o processo, exigindo o treinamento de um modelo de detecção de anomalia, descrito na próxima seção.

Figura 19 – Curva de posição do eixo X com anomalia.

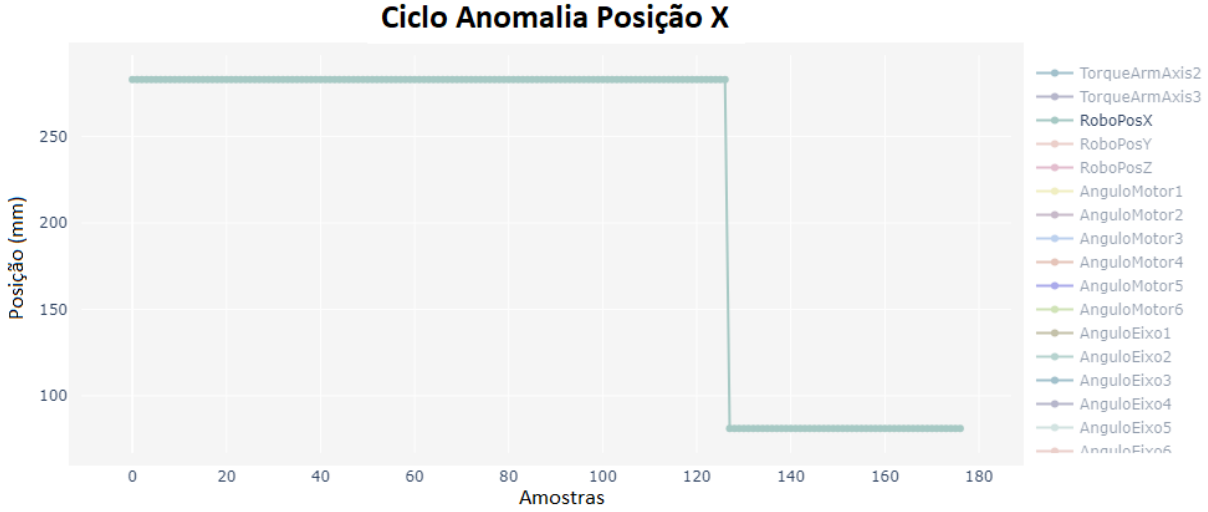

Fonte: Autoria própria

Figura 20 – Curva de posição do eixo Y durante um ciclo normal.

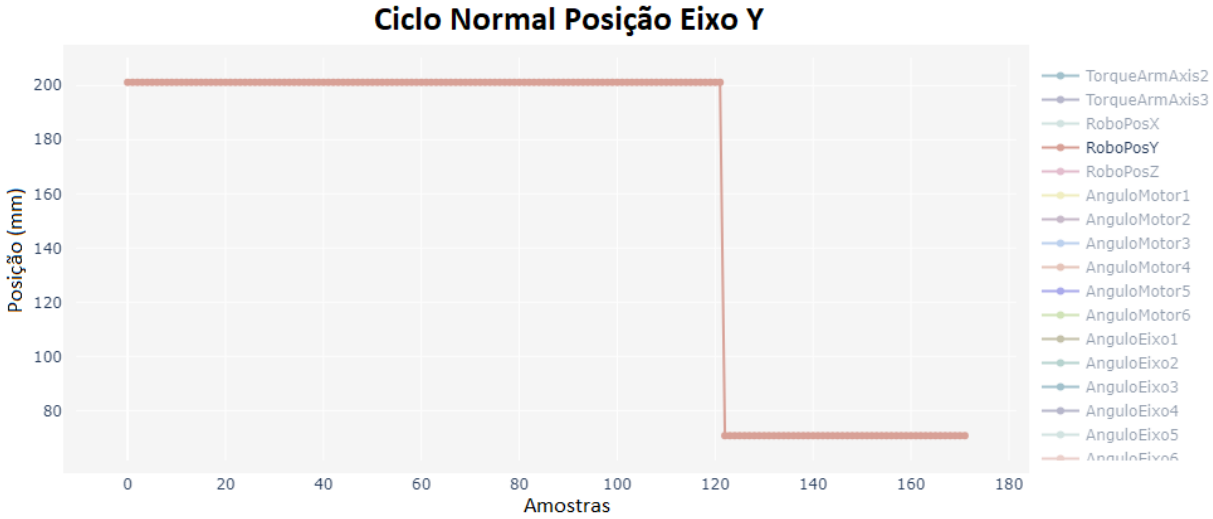

Fonte: Autoria própria

Tabela 4 – Comparativo amplitude e desvio padrão posição eixo X.

	Amplitude	Desvio padrão
Ciclo Normal	206,08	93,85
Ciclo Anomalia	201,90	91,15

Fonte: Autoria própria

A Tabela 5 mostra as diferenças de valores de amplitude e desvio padrão entre um ciclo normal e uma ciclo com anomalia para a variável posição do eixo Y.

Tabela 5 – Comparativo amplitude e desvio padrão posição eixo Y

	Amplitude	Desvio padrão
Ciclo Normal	130,44	59,40
Ciclo Anomalia	133,72	60,37

Fonte: Autoria própria

Figura 21 – Curva de posição do eixo Y com anomalia.

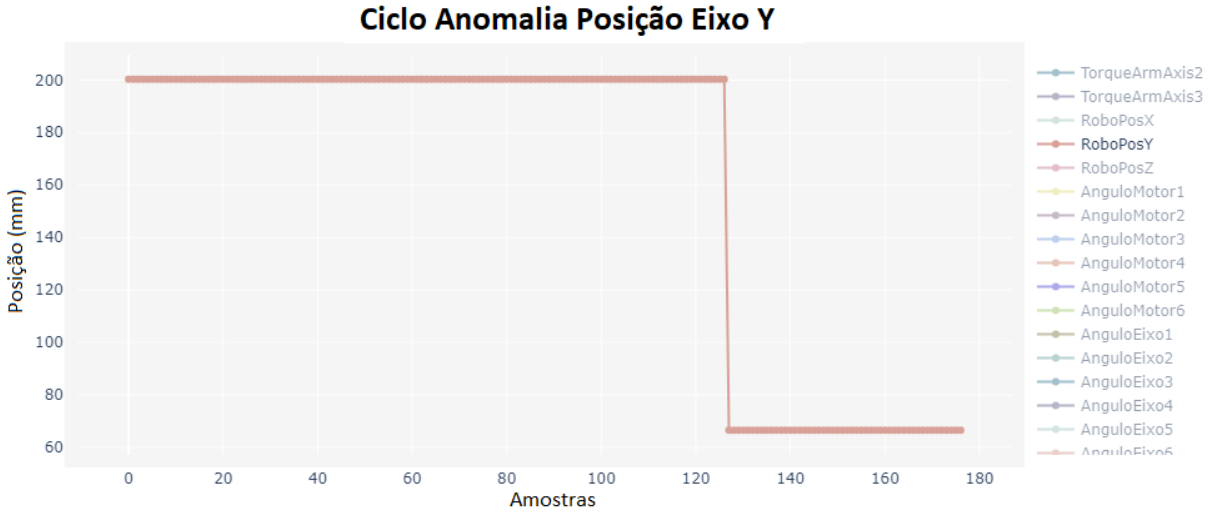

Fonte: Autoria própria

Figura 22 – Curva de posição do eixo Z durante um ciclo normal

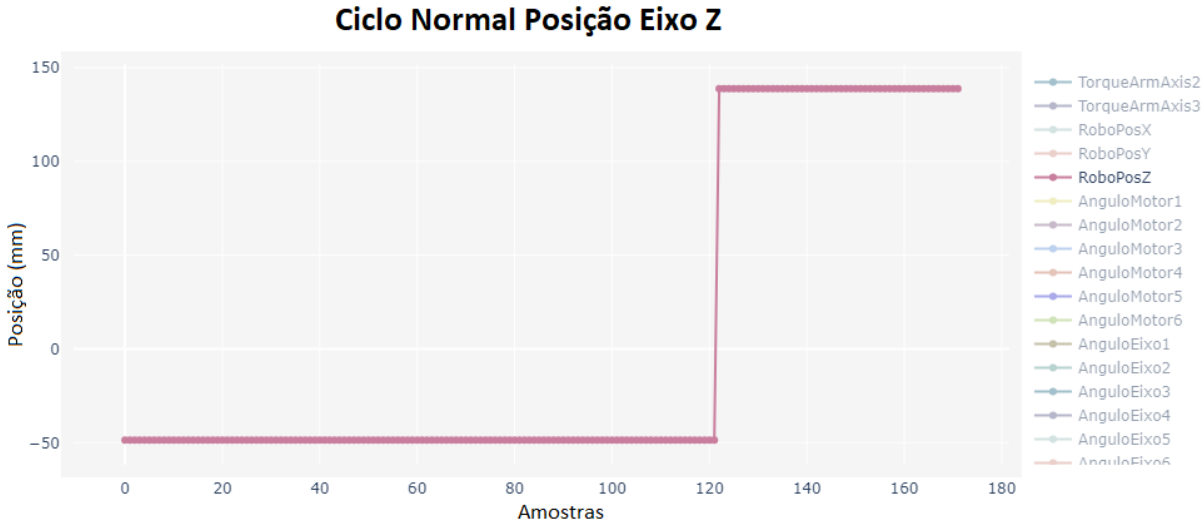

Fonte: Autoria própria

A Tabela 6 mostra as diferenças de valores de amplitude e desvio padrão entre um ciclo normal e uma ciclo com anomalia para a variável posição do eixo Z.

Tabela 6 – Comparativo amplitude e desvio padrão posição eixo Z

	Amplitude	Desvio padrão
Ciclo Normal	187,41	85,35
Ciclo Anomalia	183,36	82,78

Fonte: Autoria própria

Com relação a análise das curvas de *Torque Arm*, o que se pode perceber para os eixos 2 e 3, é uma alteração na amplitude das curvas, uma vez que a forma permanece praticamente inalterada. A figura 24 mostra o perfil da curva do torque calculado para o eixo 2, já a figura 25

Figura 23 – Curva de posição do eixo Z com anomalia

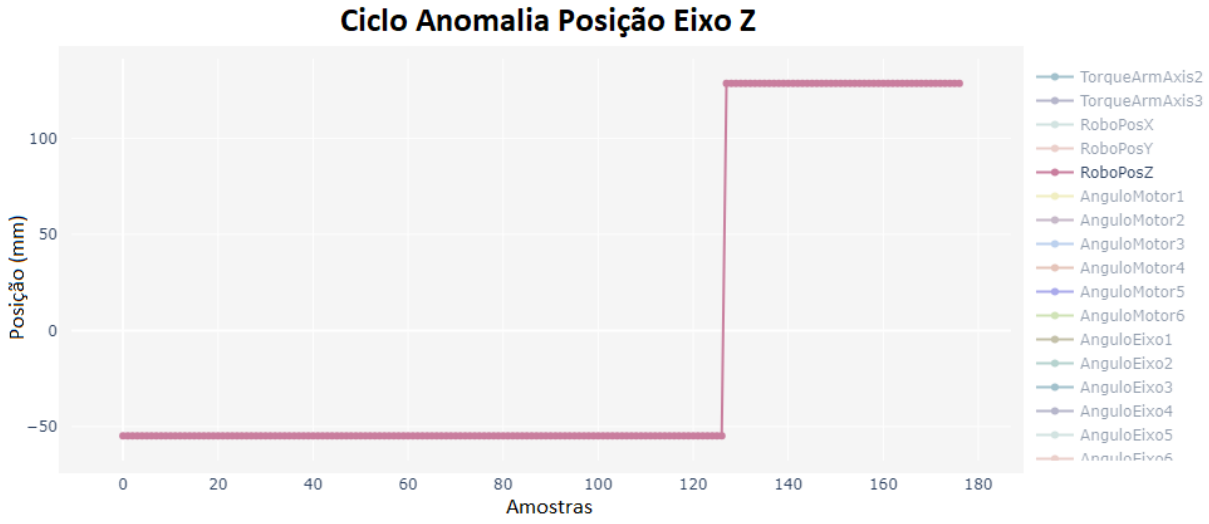

Fonte: Autoria própria

apresenta um ciclo com anomalia detectada no eixo 2. A figura 26 possui a representação da curva do torque calculado do eixo 3 para um ciclo normal, já a figura 27, mostra a curva do torque calculado do eixo 3 em situação de anomalia.

Figura 24 – Curva de posição do *Torque Arm* Eixo 2 durante um ciclo normal.

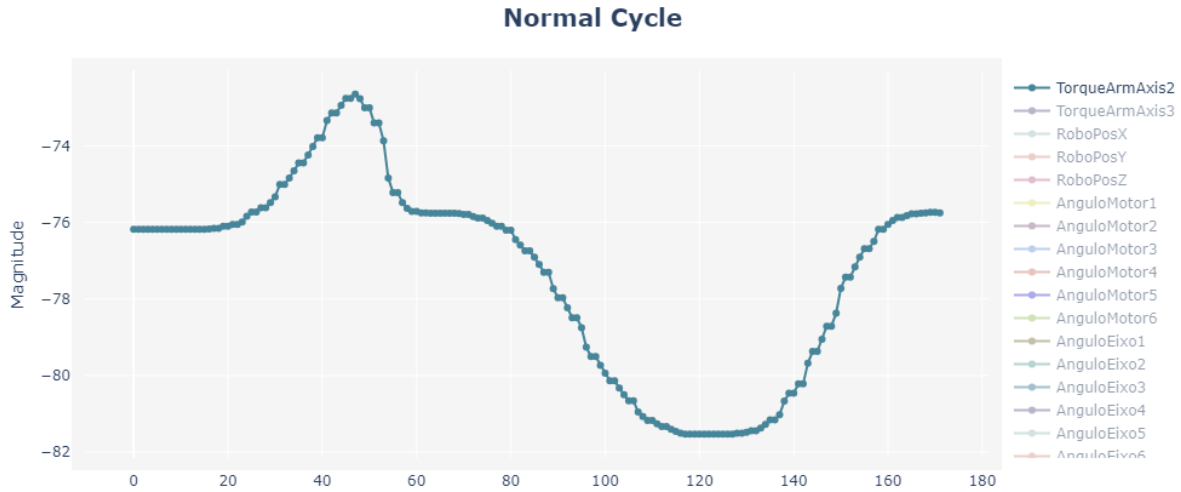

Fonte: Autoria própria

A Tabela 7 mostra as diferenças de valores de amplitude e desvio padrão entre um ciclo normal e uma ciclo com anomalia para a variável *Torque Arm 2*, já a tabela 8 mostra as diferenças de valores de amplitude e desvio padrão entre um ciclo normal e uma ciclo com anomalia para a variável *Torque Arm 3*.

Figura 25 – Curva de posição do *Torque Arm* Eixo 2 com anomalia.

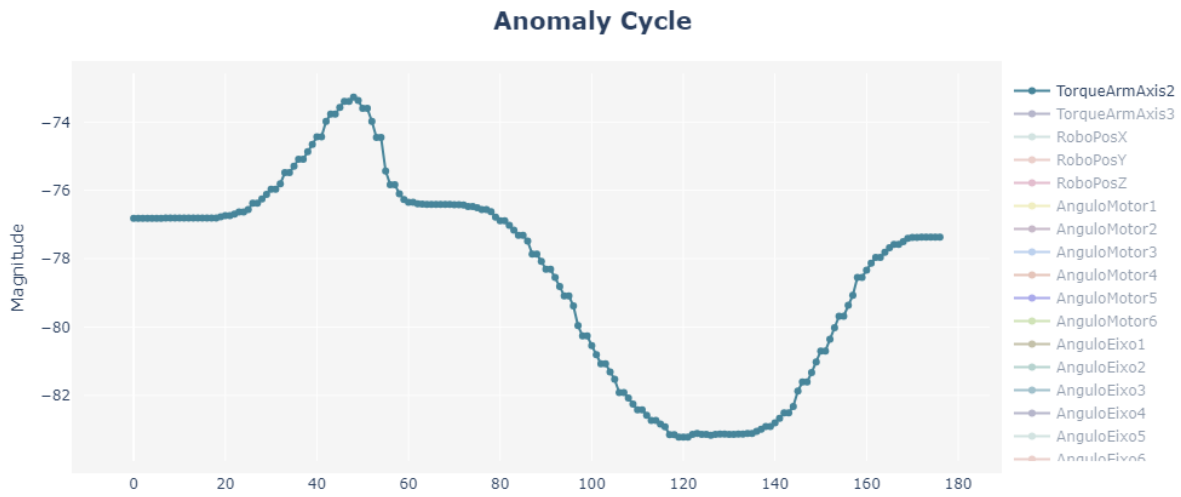

Fonte: Autoria própria

Figura 26 – Curva de posição do *Torque Arm* Eixo 3 durante um ciclo normal.

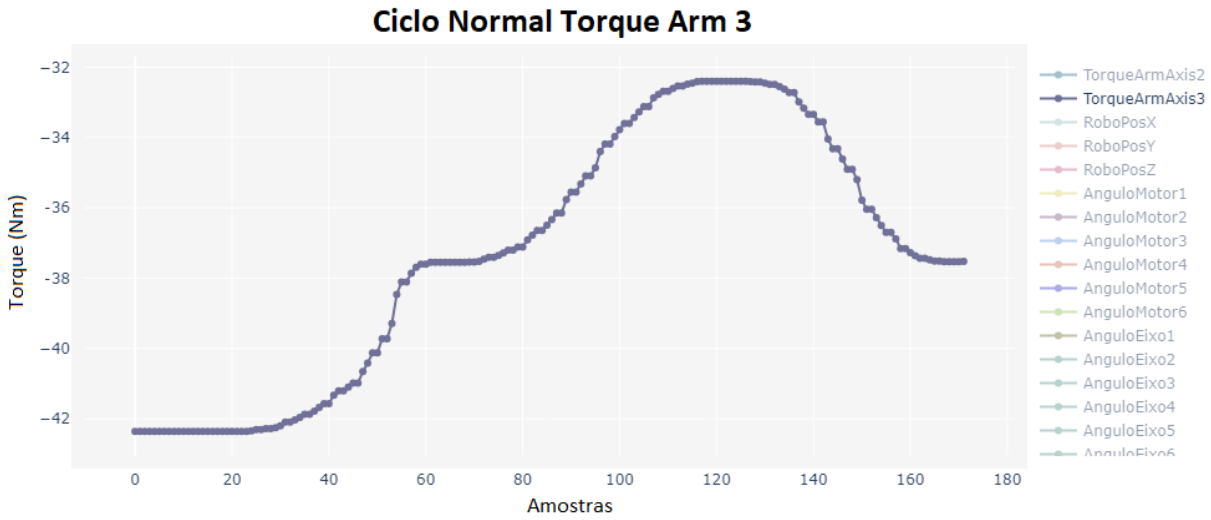

Fonte: Autoria própria

Tabela 7 – Comparativo amplitude e desvio padrão *Torque Arm* 2

	Amplitude	Desvio padrão
Ciclo Normal	8,87	2,58
Ciclo Anomalia	9,95	2,94

Fonte: Autoria própria

Tabela 8 – Comparativo amplitude e desvio padrão *Torque Arm* 3.

	Amplitude	Desvio padrão
Ciclo Normal	9,95	3,55
Ciclo Anomalia	10,54	3,70

Fonte: Autoria própria

Figura 27 – Curva de posição do *Torque Arm* Eixo 3 com anomalia.

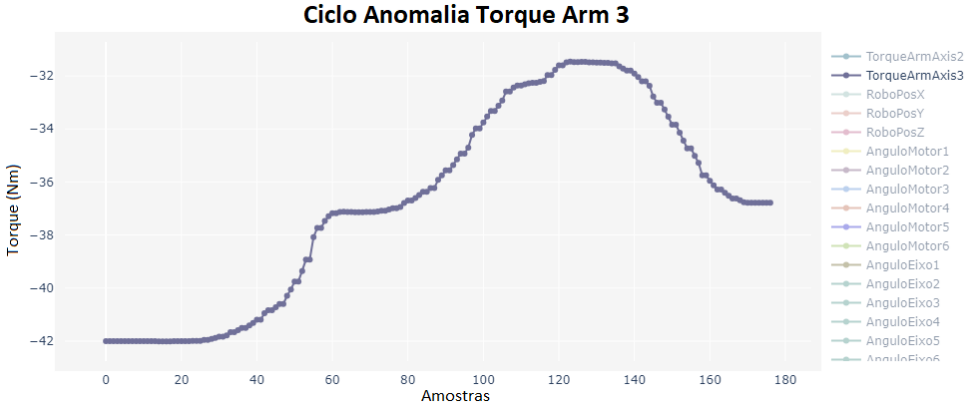

Fonte: Autoria própria

Essas foram as variáveis que apresentaram algum tipo de alteração na presença de anomalias. As demais variáveis, não apresentaram variações significativas entre um ciclo normal e um ciclo anômalo, sendo excluídas pelo processo de seleção de atributos e, portanto, excluídas no próximo passo que é o treinamento do modelo para identificação das anomalias.

3.6 TREINAMENTO DOS MODELOS

Tomando como referência a literatura com foco na detecção de anomalias, o *Isolation Forest* foi o escolhido por apresentar os melhores resultados em termos de acerto de detecção em diferentes abordagens da literatura e também um bom desempenho computacional, em virtude da implementação baseada em árvore, o que torna a implementação no CLP mais vantajosa. Na fase de treinamento do modelo, todos os hiper parâmetros foram otimizados usando *grid-search*, que é um processo de procurar exaustiva dentro de sub conjunto especificado de forma manual (CHAN; TRELEAVEN, 2015) e validação cruzada com cinco *folds*, o que representa a quantidade em que o dataset foi particionado para facilitar o processamento. A otimização dos hiper parâmetros foi feita devido ao conhecimento prévio das anomalias, as quais foram geradas de forma artificial, conforme já explicado anteriormente. Para obtenção dos resultados foram utilizados os seguintes espaços de busca para otimização dos hiper parâmetros:

- $n_{estimators}$: é a quantidade de estimadores de base (árvores), o qual foi variado entre os valores de 50 até 250, com passo de 5.

- *contamination*: determina a quantidade de contaminação provável do *dataset*, por exemplo, por possíveis *outliers*. O valor foi variado entre o *auto*, o qual mantém os valores originais

do *dataset* e *float* que variou entre $[0.005, 0.01, 0.02, 0.03, 0.04, 0.05, 0.06, 0.07]$;

- $max_{samples}$: É o número de amostras a serem extraídas dos dados de entrada para treinar cada estimador base (árvore). Este valor foi variado entre 10 a 100, com passo de 10.

Sobre a divisão do conjunto de treino e de teste, ela foi realizada deixando 80% dos dados normais e anômalos para treinamento e 20% para teste. Foi utilizado um Hardware de *Workstation* com a seguinte configuração para treinar o modelo: processador Intel i7, 128GB de memória RAM e uma placa de video 2080TI. O tempo total para o treinamento do modelo utilizando o algoritmo *Isolation Forest* com pouco mais de 6000 dados foi de aproximadamente 2 horas.

3.7 MÉTRICAS E AVALIAÇÃO DOS RESULTADOS

Dentre as diversas possibilidades de avaliação de resultados de modelos matemáticos com a finalidade de detectar uma anomalia, o indicador que se demonstrou mais recomendado para mostrar a eficácia do modelo é o F1-score micro (RASCHKA; MIRJALILI, 2019), por ter influência reduzida em relação ao desbalanceamento. O cálculo do F1-score micro é representado na equação 5:

$$F1 - score_{micro} = \frac{TP}{TP + \frac{1}{2} \times (FP + FN)}, \tag{5}$$

sendo:

- TP - *True Positives* - Amostras positivas (normais) que foram classificadas corretamente;
- FP - *False Positives* - Amostras que foram de classificadas como positivas (normais) mas eram negativas (anômalas);
- FN - *False Negatives* - Amostras que foram classificadas como positivas (normais) mas eram negativas (anômalas).

3.8 IMPLEMENTAÇÃO PRÁTICA

Os resultados quantitativos da avaliação do indicador F1-score do modelo geral apresentaram uma melhor performance o que leva o trabalho para a próxima etapa que é a implementação prática. Durante a fase de colocação em funcionamento de um modelo de *machine learning* em uma máquina de produção, alguns cuidados que precisam ser seguidos na íntegra em respeito

às características produtivas e as normas internas do fabricante. Não é prudente a instalação de qualquer tipo de software ou aplicativo rodando diretamente no processador do controlador, sem antes realizar testes de performance, ou seja, o programa, *software* ou aplicativo a ser instalado não deve consumir memória e capacidade de processamento de forma elevada, o que poderia comprometer o funcionamento das tarefas realizadas pelo CLP, as quais são de total prioridade de execução. A forma mais próxima da realidade de uma máquina que se pode chegar para a realização do teste de performance é fazer o *download* do programa da máquina em um *hardware* igual ao da estação em um ambiente de teste e colocar o programa que contém o executável do modelo para ser executado em paralelo. Todas as comunicações possíveis também devem ser estabelecidas, como por exemplo a troca de informações entre máquina e banco de dados. Caso haja a ocorrência de algum problema no ambiente criado para a emulação, o programa executável deverá ser revisto e se necessário retrabalhado, para que um novo teste possa ser realizado. O aplicativo deve sempre ser tratado como secundário – este não deve interromper o ciclo de trabalho da máquina e nem causar distúrbios em situações de pane ou mal funcionamento. Para tanto, estratégias de contorno devem ser previstas caso o *software* pare de funcionar, como por exemplo a criação de sinais de vida, os quais indicam que ambos lados permanecem operando e comunicando, tempos limite para tentativa de troca de dados também são uma prática comum para detectar falhas de envio e recebimento, comumente chamados de *time-out*, e assim por diante. Caso alguma falha inesperada ocorra no lado no executável do modelo, a máquina deve operar no modo anterior, ou seja sem a interferência do modelo. Caso o CLP através das estratégias de contingência perceba que o modelo parou de responder aos comandos ou que apresenta falha, deverá interromper a comunicação e informar através de alarme que o modelo parou de funcionar para que providências sejam tomadas.

3.8.1 *SHADOW MODE*

Apesar de toda a fase de testes primários em ambiente simulado, conforme comentado na seção anterior, ainda existe mais um estágio de validação do funcionamento do modelo em ambiente real. Para garantir que o modelo testado apresente resultados satisfatórios e que de fato será efetivo e não conterá erros, uma prática muito comum para máquinas de produção é o trabalho por um período determinado no chamado *Shadow Mode*, que corresponde a colocar o aplicativo em funcionamento total dentro do processador e arquivar os resultados tanto da máquina no processo atual e do modelo. Nessa etapa, o modelo não toma a decisão e não interfere

em nada no funcionamento da máquina, somente gera dados para arquivamento para que após um período de coleta, estes sejam analisados e confrontados com os resultados da máquina. Dessa forma é possível verificar após uma simples análise se o modelo conseguiria ser mais assertivo que o processo atual. Concluída a fase de coleta dos dados, é possível ter a garantia de que o modelo encontra-se em estágio funcional. No caso do modelo de detecção de anomalias, não se pretende tomar decisões sobre a máquina num primeiro momento, porque não existem dados anteriores de anomalias e os dados existentes foram gerados de forma sintética. A primeira fase dessa etapa de *deployment* do modelo, tem o objetivo de deixa-lo coletando informações e detectando anomalias, para que posteriormente, seja possível a tomada de decisões.

4 RESULTADOS

O objetivo deste capítulo é mostrar os resultados obtidos na execução do modelo *Isolation Forest* para detecção de anomalias do robô industrial manipulador. Primeiramente, pretende-se mostrar os resultados obtidos para um modelo individual por produto e para um modelo único global para todos os produtos. Além disso, os resultados encontrados para cada situação serão detalhados, incluindo as matrizes de confusão de cada abordagem, destacando os melhores e piores resultados. Finalmente, serão apresentados os gráficos das variáveis, mostrando a eficácia do modelo em detectar as anomalias – análise visual, bem como a implementação em *shadow mode*.

4.1 RESULTADOS COM UM MODELO POR PRODUTO

Para avaliar se o produto que é manufaturado na linha não possui interferência direta com a detecção de uma anomalia, foram criados, inicialmente, modelos específicos para cada um dos produtos. Em uma primeira abordagem do problema levando em consideração a variação dos produtos e o desbalanceamento dos *datasets*, optou-se por tratar de forma isolada o problema. Os resultados obtidos com essa metodologia são apresentados na Tabela 9, onde:

- *Precision*: indicador da quantidade de predições positivas (normal) classificadas corretamente ($TP/(TP + FP)$);
- *Recall*: Também chamado de sensibilidade, é o indicador que relaciona a quantidade de predições classificadas como positivas e todas as amostras positivas ($TP/(TP + FN)$);
- *F1-Score*: Medida que combina *Precision* e *Recall*, geralmente chamada de média harmônica de ambos;
- *Macro AVG*: média onde todas as classes (normal e anomalia) contribuem igualmente para a métrica média final;
- *Weighted AVG*: média onde a contribuição de cada classe para a média é ponderada pelo seu número de amostras correspondente.

Pela análise da Tabela 9, observa-se que os produtos D e E possuem uma acerto inferior para as anomalias, sendo o produto D o mais crítico. Os demais produtos apresentam um *F1-*

Score acima de 95%, sendo que a detecção de anomalias é, em geral, a causa dos erros mais impactantes no desempenho final de cada produto.

Tabela 9 – Resultados por produto (modelo individual).

	Precision	*Recall*	*F1-Score*	***Produto***
Anomaly	0,916	0,982	0,948	A
Normal	0,998	0,994	0,996	
Macro AVG	0,957	0,988	0,972	
Weighted AVG	0,994	0,993	0,994	
Anomaly	1	0,843	0,915	B
Normal	0,994	1	0,997	
Macro AVG	0,997	0,921	0,956	
Weighted AVG	0,994	0,994	0,994	
Anomaly	1	0,800	0,888	C
Normal	0,994	1	0,997	
Macro AVG	0,997	0,901	0,943	
Weighted AVG	0,994	0,994	0,994	
Anomaly	0,167	0,164	0,165	D
Normal	0,937	0,938	0,938	
Macro AVG	0,552	0,551	0,551	
Weighted AVG	0,883	0,884	0,884	
Anomaly	1	0,428	0,600	E
Normal	0,992	1	0,996	
Macro AVG	0,996	0,714	0,798	
Weighted AVG	0,992	0,992	0,990	

Fonte: Autoria própria

Com o intuito de analisar com mais detalhes os problemas de cada caso, optou-se por avaliar a matriz de confusão de cada modelo em cada produto. As Tabelas 10, 11, 12, 13 e 14 abaixo mostram os resultados das matrizes de confusão para os produtos A, B, C, D e E, respectivamente.

Tabela 10 – Matriz de confusão produto A.

Real	-1	1	***Todos***
-1	55	1	56
1	5	934	939
Todos	60	935	995

Fonte: Autoria própria

Tabela 11 – Matriz de confusão produto B.

Real	-1	1	***Todos***
-1	108	20	128
1	0	3454	3454
Todos	108	3474	3582

Fonte: Autoria própria

Pode-se perceber pelos resultados das tabelas das matrizes de confusão que o melhor desempenho de modelo foi com o produto A, o qual possui apenas um erro para a detecção

Tabela 12 – Matriz de confusão produto C.

$Real$	-1	1	$Todos$
-1	8	2	10
1	0	370	370
Todos	8	372	380

Fonte: Autoria própria

Tabela 13 – Matriz de confusão produto D.

$Real$	-1	1	$Todos$
-1	12	61	73
1	60	916	976
Todos	72	977	1049

Fonte: Autoria própria

Tabela 14 – Matriz de confusão produto E.

$Real$	-1	1	$Todos$
-1	3	4	7
1	0	503	503
Todos	3	507	510

Fonte: Autoria própria

de uma anomalia e 5 erros para a detecção de normalidade. O provável motivo da melhor performance desse modelo é que o número de amostras anômalas é maior em proporções que os demais produtos, já o modelo que gerou mais erros de classificação foi o produto E, que por sua vez, teve o menor índice proporcional de amostras anômalas entre os cinco produtos. Essa diferença ou desbalanceamento de amostras entre os diferentes produtos ocorre porque as anomalias foram geradas de forma programada, de acordo com a disponibilidade da produção, não havendo possibilidade de escolher o produto e a quantidade de amostras durante o período de coleta.

4.2 RESULTADOS COM UM MODELO GLOBAL

Como o *dataset* possui diferentes produtos, optou-se por realizar testes com um modelo que podemos chamar de global ou único, o qual visa o processamento de todos os dados do *dataset* sem levar em conta as diferenças de produto. Para essa abordagem, o tipo do produto é inserido como característica para o modelo. A Tabela 15 mostra os resultados dos indicadores para o modelo único. Esse modelo apresentou resultados com desempenho superior em relação a um modelo por produto. Considerando o indicador *F1-Score*, na detecção de anomalia temos uma melhoria de 2,85%, passando de 0,948 para 0,975 quando comparado ao melhor resultado dos modelos por produto. Todos os demais indicadores mostrados tiveram alguma melhora em

relação quando comparado ao melhor resultado do modelo por produto.

Tabela 15 – Resultados modelo global

	Precision	*Recall*	*F1-Score*
Anomaly	1	0,952	0,975
Normal	0,997	1	0,998
Macro AVG	0,998	0,976	0,987
Weighted AVG	0,998	0,998	0,997

Fonte: Autoria própria

A Tabela 16 mostra a matriz de confusão para este modelo global. Observa-se que os erros para as anomalias diminui significativamente e os padrões normais são todos corretamente classificados.

Tabela 16 – Matriz de confusão modelo global

$\boldsymbol{Real}$	$\boldsymbol{-1}$	$\boldsymbol{1}$	$\boldsymbol{Todos}$
-1	261	13	274
1	0	6242	6242
Todos	261	6255	6516

Fonte: Autoria própria

4.2.1 COMPARATIVO ENTRE OS MODELOS

De modo a fornecer um comparativo mais detalhado das melhorias que o modelo global fornece, optou-se por apresentar um resultado por produto, comparando ambos os modelos, conforme mostra a Tabela 17. Nessa tabela é possível notar que os maiores erros do modelo único acontecem para a anomalia do tipo 2, que são as anomalias geradas inserindo apenas um erro no eixo Y do robô, para o produto B. Esses erros podem ter sidos gerados dado os valores próximos das características nessa anomalia, em relação aos valores das características no padrão normal de funcionamento. Ainda, a anomalia do tipo 1 e do tipo 2 só foram geradas para o produto N9, contendo somente 33 amostras no total com anomalias desses tipos, de modo que pode ser difícil para o modelo entender as diferenças entre os padrões de comportamento dessas anomalias em relação ao padrão normal.

Já o melhor caso do modelo único pode ser observado com o produto A, que melhorou consideravelmente os acertos para esse produto quando incluído na modelagem única. Para esse produto, quando avaliado em um modelo individual, nota-se um alto valor de falsos positivos e falsos negativos, comparado até mesmo a outros modelos individuais. Quando considerado no modelo único, ele elimina esses erros. Esse resultado pode ter sido obtido visto que o modelo

Tabela 17 – Comparativo de performance entre os modelos.

Target	Erro modelo individual	Erro modelo global	Amostras totais	Produto
0	5	0	939	
3	0	0	8	
4	0	1	4	A
5	1	4	16	
6	0	0	10	
7	0	0	18	
0	0	0	3454	
1	1	1	13	
2	15	6	20	
3	0	0	20	B
4	1	0	11	
5	2	1	11	
6	0	0	33	
7	1	0	20	
0	0	0	370	C
5	2	0	7	
6	0	0	3	
0	60	0	976	
4	28	0	28	D
6	25	0	27	
7	8	0	18	
0	0	0	503	E
5	4	0	7	

Fonte: Autoria própria

único apresenta mais amostras das anomalias 4, 6 e 7, de modo que essa quantidade maior de amostras podem colaborar para que o modelo encontre diferenças entre o padrão normal das características e o padrão das anomalias. Além disso, esse produto pode ter semelhanças construtivas a outros produtos considerados no modelo único, o que resulta em características parecidas entre os produtos.

Em resumo, todos os resultados atingidos pelos modelos individuais não conseguiram superar a performance do modelo único. Mesmo para os produtos com poucas amostras como o caso dos produtos C e E, o modelo único se mostrou mais eficaz na detecção de anomalias. A única diferença entre as duas tratativas é que o modelo genérico considera o produto como uma característica.

4.3 ANÁLISE VISUAL

Para verificar a eficácia do modelo global ao realizar a detecção das anomalias das características treinadas, foram gerados gráficos mostrando essa funcionalidade. A pena na cor vermelha que representa o *target* conforme mostrado na figura 28 sinaliza a presença de uma anomalia. A linha de detecção de anomalias funciona da seguinte forma. O padrão de um ciclo

normal é mostrado graficamente pelo valor 0 enquanto que a anomalia é identificada com o valor -1. Todos os gráficos foram gerados a partir do mesmo conjunto e quantidade de amostras. Os gráficos possuem 200 amostras, sendo que as primeiras 75 são consideradas ciclos normais e as outras 125 possuem algum tipo de anomalia gerada de forma sintética.

A Figura 28 tem por finalidade mostrar como o modelo está identificando as anomalias geradas nos eixos X, Y e Z do plano cartesiano de orientação do robô. O eixo X é onde estão as amostras em ordem sequencial e o eixo Y é o valor da numérico da posição normalizada entre os valores -1 e 1. Os valores foram normalizados para facilitar a interpretação do gráfico. Valores contínuos significam que trata-se de um ciclo normal. Por exemplo, a variável RoboPositionX_-amp possui o valor zero para representar a normalidade de um ciclo – valores fora do padrão são anomalias. O gráfico inicia com amostras normais, ou seja, sem a presença de anomalias. Até próximo da amostra de número 1100 se inicia a detecção das anomalias, que é o momento no gráfico onde os valores dos eixos X, Y e Z de forma individual ou combinada começam a apresentar valores diferenciados. Essa variação nos valores são entendidas pelo modelo como as anomalias que foram geradas.

Figura 28 – Detecção de anomalias através da variação de amplitude das posições.

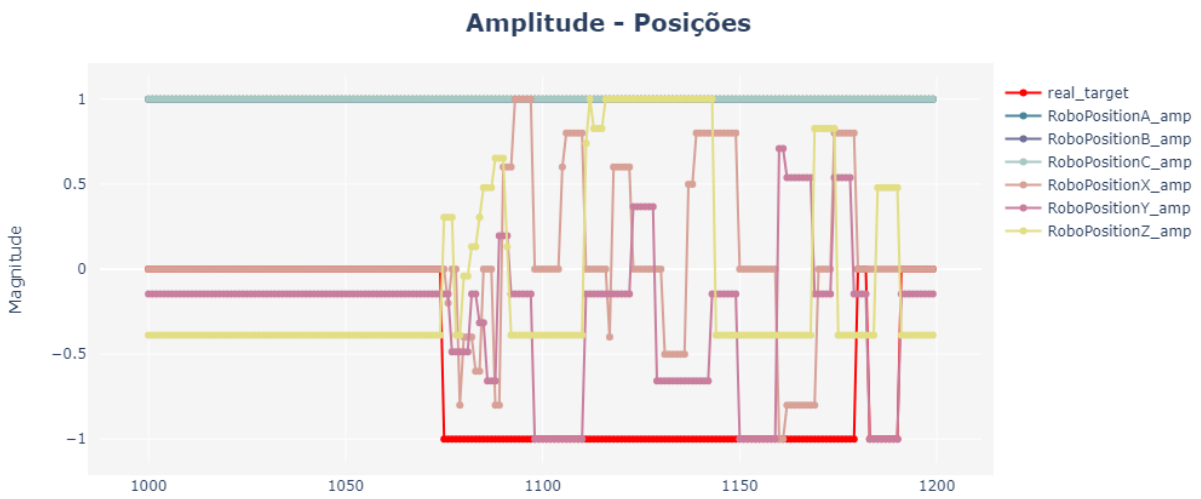

Fonte: Autoria própria.

Outra variável analisada pelo modelo foi o desvio padrão das posições X, Y e Z do plano cartesiano do robô. Na Figura 29 são mostradas todas as variáveis cartesianas novamente, normalizadas entre os valores -1 e 1 para facilitar a interpretação da ocorrência de anomalias. Inicialmente, os valores do desvio padrão de cada uma das variáveis vem se repetindo de forma

cíclica, no entanto a partir da amostra 1075 os valores passam a sofrer alterações o que demonstra que existem anomalias, as quais são detectadas pelo modelo, o que pode ser interpretado pela curva vermelha atingindo o valor 0.

Figura 29 – Detecção de anomalias através do desvio padrão das posições.

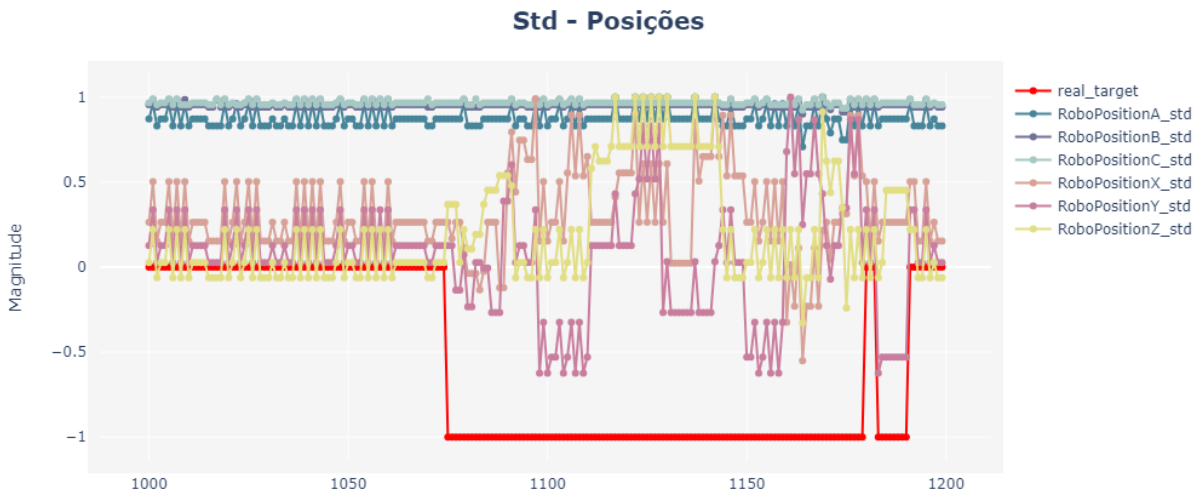

Fonte: Autoria própria.

Da mesma forma que o ocorrido nos gráficos apresentados anteriormente com as posições cartesianas, a Figura 30 mostra a detecção de anomalias ocorrendo na mesma faixa de amostras, porém através da monitoração da amplitude dos *torques act* dos eixos 2 e 3. O modelo realiza a detecção das mesmas anomalias detectadas na variação do desvio padrão das variáveis cartesianas.

A Figura 31 demonstra as mesmas detecções de amostras com anomalias através do desvio padrão dos *torques act* dos eixos 2 e 3. Novamente foram utilizadas a mesma sequência de amostras começando com ciclos normais e depois as anomalias, a percepção de detecção do modelo se manteve igual à analise das variáveis anteriores.

No gráfico das variáveis *Torque Arm*, que são os torques calculados do robô, torna-se mais fácil o entendimento e a visualização das curvas de ciclos normais e ciclos anômalos, pois os valores dos demais torques dos eixos 1, 4, 5 e 6 além de permanecerem praticamente inalterados durante todo o período de amostras, ainda se afastam em valores das variáveis de interesse. As variações de amplitudes dos *Torque Arm* dos eixos 2 e 3 também são detectados pelo modelo, como mostrado na Figura 32.

Analisando o gráfico dos desvios padrões do *Torque Arm* dos eixos 2 e 3, é possível

Figura 30 – Detecção de anomalias através da variação de amplitude do *torque act*.

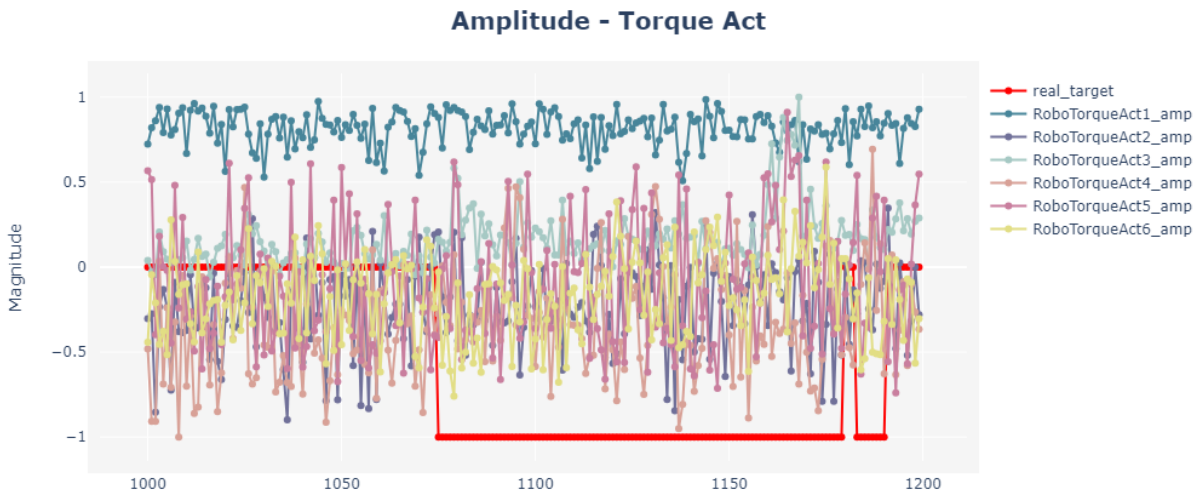

Fonte: Autoria própria.

Figura 31 – Detecção de anomalias através da variação do desvio padrão do *torque act*.

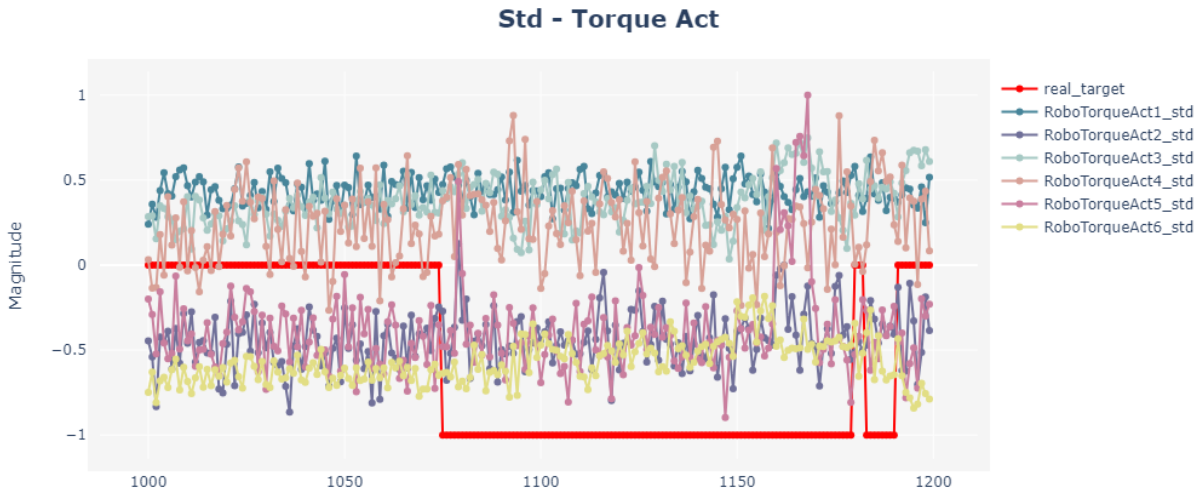

Fonte: Autoria própria.

perceber que assim como na característica de amplitude, as demais variáveis permanecem praticamente inalteradas durante todo o período de amostras, e que novamente as variações de desvio padrão dos torques calculados (*torque arm*) dos eixos 2 e 3 são detectados pelo modelo, como mostrado na Figura 33.

Figura 32 – Detecção de anomalias através da variação de amplitude do *torque arm*.

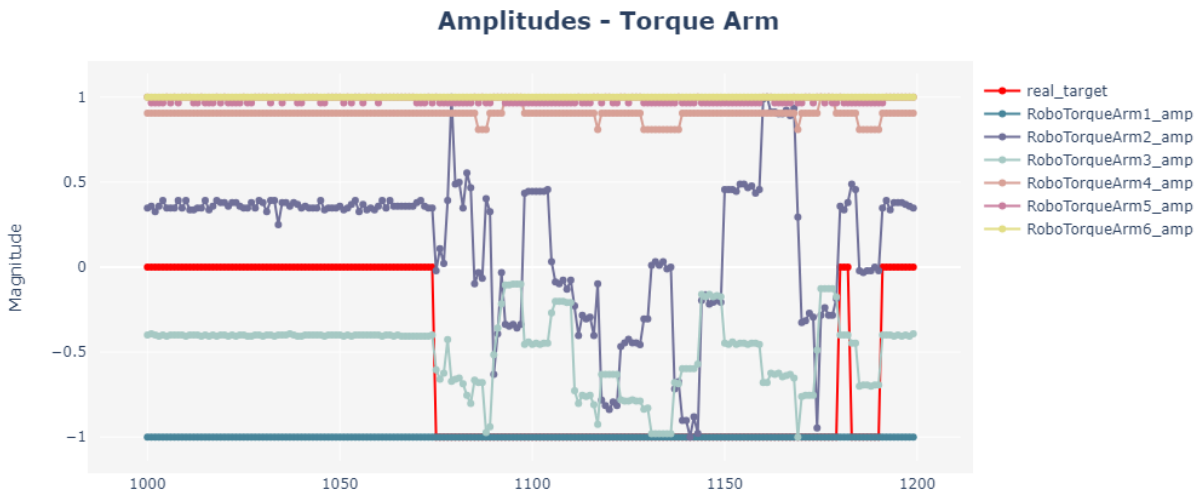

Fonte: Autoria própria.

Figura 33 – Detecção de anomalias através da variação do desvio padrão do *torque arm*.

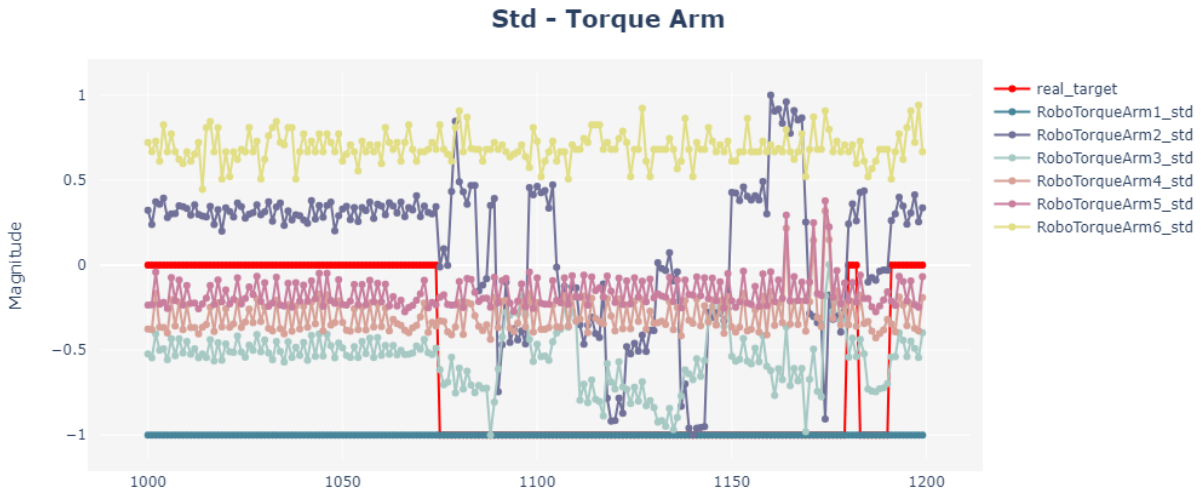

Fonte: Autoria própria.

4.4 RESULTADOS DO MODELO OPERANDO NA LINHA

Uma das etapas propostas por este trabalho e considerada de grande importância para a fábrica é a implementação do modelo na linha de produção. Para satisfazer esse requisito, é necessário colocar o modelo de *machine learning* desenvolvido, o qual apresentou resultados promissores, conforme explicados ao longo deste capítulo, funcionando de alguma forma, seja ela local ou em nuvem, realizando a detecção das anomalias reais que ocorrem durante a

produção. Após a criação do modelo é necessário encontrar uma forma segura de implementá-lo em uma linha de produção sem comprometer a robustez e confiabilidade dos equipamentos. Logo, o *software* para tal finalidade não deve comprometer as capacidades de processamento e memória caso este seja instalado diretamente na linha de produção. A opção escolhida para atender ao requisito foi a instalação local no PC de automação da estação de trabalho que possui sistema operacional Windows 10 IoT. O PC já possui a comunicação com o robô que é necessária para a coleta de dados e análise *on-line*, o que facilita a integração do modelo com a máquina. Para colocar o modelo em funcionamento na linha de produção foi escolhido gerar um programa executável a partir do Python. Esse programa executável possui somente as bibliotecas necessárias para o funcionamento do modelo e um *plug-in* para a troca de dados via I/O com o programa do CLP, ou seja, trata-se de um programa operacional, não requer grande espaço em disco e nem alta utilização de memória e processamento. A Figura 34 mostra uma imagem da tela de comando da estação com o modelo em funcionamento.

Figura 34 – Modelo em operação na linha de produção.

```
---------- :: Starting application :: ----------
 ------------------------------------------------
 => Loading Plugins...
 IA_ST60 - Run
 Read JSON
 Libraries Imported
 [OK] Beckhoff AMS port router connection
 [redacted]
 Imported external variables
 Get Values...
Valores Iniciais:
[RoboTorqueArm3_std],  [RoboPositionX_amp],  [RoboPositionY_amp], [RoboPositionZ_amp], [RoboTorqueArm2_amp], [RoboTorqueArm3_amp], [Produto]
[[ 3.55415132  206.08000946  130.44998932  187.41999435  8.889999939  9.97999953  5 ]]


Valores Normalizados:
[RoboTorqueArm3_std],  [RoboPositionX_amp],  [RoboPositionY_amp], [RoboPositionZ_amp], [RoboTorqueArm2_amp], [RoboTorqueArm3_amp], [Produto]
[[ -0.86928001 -0.52923167 -1.14017277 -0.75882419 -0.26723  -1.28242101  1.5  ]]


Resposta IA:
[[ -1 ]]


Tempo de execução:
0.56500148777 ms
 Plugin executed successfully!
```

Fonte: Autoria própria.

As matrizes que contém os valores inicias e normalizados que aparecem na Figura 34 são as variáveis de entrada do modelo na seguinte ordem: Desvio padrão do Torque Arm eixo 3, amplitude da posição X, amplitude da posição Y, amplitude da posição Z, amplitude do torque Arm do eixo 2, amplitude do torque Arm do eixo 3 e tipo de produto. O valor -1 para a resposta do modelo de detecção de anomalia significa que o resultado da avaliação é uma anomalia. Se o resultado fosse 1 seria um ciclo normal.

Além das considerações iniciais com relação ao consumo de memória e a capacidade de processamento da CPU com a instalação do software executável do modelo, outro ponto

importante a ser analisado é o tempo de análise e resposta do modelo. Para determinar com a maior exatidão possível esse tempo de execução, foi implementado dentro do programa do CLP, um temporizador para medir o tempo entre o envio dos dados para o modelo e o retorno do resultado (ciclo normal ou ciclo anômalo) para o programa do CLP. Nessa primeira fase de colocação em funcionamento não importa o tipo de anomalia e sim a capacidade de detecção. O tempo de resposta de execução do modelo, tomando como referência o valor apresentado na Figura 34, foi de 565ms. Pode ocorrer uma pequena oscilação no tempo de resposta em razão da prioridade para a CPU ser o processamento das tarefas de comando e controle da estação. No entanto, essa pequena diferença que possa acontecer no tempo de execução do modelo não implica em um problema para a linha de produção, uma vez que a intenção em detectar anomalias num primeiro momento é apenas informativa e não corretiva. Ou seja, o modelo não toma decisões e portanto, o programa do CLP não precisa ficar no aguardo de uma resposta para prosseguir com as próximas tarefas.

O modelo permaneceu em operação em *shadow mode* na linha de produção por alguns dias sem causar distúrbios para a produção, cumprindo assim mais uma etapa importante no ciclo de implementação de aprendizado de máquina em linhas de produção, que é não causar impactos negativos no ciclo produtivo. No entanto, ao resgatar os dados de resultado gerados pelo modelo durante o período de atividade, percebeu-se que os dados dos primeiros dias de produção apresentavam resultados normais. Porém, após esse período, todos os demais ciclos estavam sendo detectados como anomalias. Foram avaliadas então as curvas das características para entender o motivo do resultado. Realizando a comparação das curvas atuais com o conjunto de dados com os quais o modelo foi treinado, percebeu-se que haviam diferenças em termos de amplitude e desvio padrão em todas as variáveis, o que para o modelo estava sendo considerado algo fora do ciclo normal, ou seja, anomalia. O que foi constatado em contato com a área produtiva é que houve a troca do robô devido a um problema de manutenção e também a troca da base de fixação por uma de menor comprimento, alterando assim a altura do robô. Essas alterações influenciaram diretamente na dinâmica de funcionamento da máquina, refletindo diretamente nos dados coletados. Em razão dessa mudança de comportamento dinâmico do robô, foi necessário voltar a etapa de coleta de dados e geração de novas anomalias para o treinamento do modelo e geração de um novo executável. Com a geração do novo modelo, foram avaliadas novamente as métricas, as quais apresentaram resultados muito próximos da versão prévia com diferenças de valores quantitativos na casa de décimos de diferença. Sendo assim, o novo modelo

executável foi gerado e mais uma vez realizado o *deployment* na CPU de comando da estação. Nesse momento o modelo se encontra novamente na fase de *shadow mode* coletando os dados para posterior análise de desempenho.

5 CONCLUSÕES E PERSPECTIVAS

Grande parte dos robôs industriais tem aplicação em ambientes nocivos tais como óleos, sujeiras, partículas em suspensão, calor ou frio excessivo, além de serem submetidos aos próprios desgastes mecânicos citados por vezes neste trabalho, o que pode levar a máquina a um estado de anomalia prematura e indesejado. Estas anomalias além de comprometer a vida útil de um robô, ainda podem causar grandes prejuízos para a empresa, uma vez que estes componentes estão diretamente ligados ao atingimento das metas diárias de produção. Com isto, torna-se cada vez mais importante a detecção prematura de desgastes e desvios no comportamento normal de um robô, no intuito de prolongar a vida útil do equipamento, planejar uma manutenção e reduzir as chances de quebra súbita.

Os objetivos definidos no início do trabalho foram integralmente atingidos. Levando em consideração a literatura utilizada para o desenvolvimento do trabalho, foram definidos os dados necessários para iniciar os estudos conforme explicados na Seção 3.4.1. Com relação a coleta dos dados, ocorreram alguns desafios durante a execução, tais como a disparidade da quantidade de amostras nos arquivos de dados e o tempo de aquisição das amostras, os quais foram solucionados. Os dados de anomalia foram gerados de forma artificial para que se pudesse comparar e entender o que era uma curva de operação normal das variáveis e o que ocorria durante uma anomalia. Forma gerados diferentes modos de falha, inserindo pequenos desvios nas componentes X, Y e Z das coordenadas cartesianos do robô, fazendo com que ocorresse um erro de posicionamento o qual simula uma falha.

Através de uma análise inicial dos dados em formato de gráfico, algumas informações puderam ser filtradas logo no início do estudo, como por exemplo a exclusão das variáveis de temperatura que não se alteravam mesmo em condições de anomalia. No entanto, os dados mais significativos para o estudo foram escolhidos através da análise visual em combinação com uma metodologia de seleção de atributos. Essa diferenciação entre as curvas dos dois modos (normal e anômalo) só foi possível devido à geração dos dados de anomalia. Toda essa tratativa foi explicada na Seção 3.5.

Logo após a escolha das variáveis relevantes para o estudo, todas as informações desnecessárias foram retiradas do *dataset*, restando apenas os dados que deveriam ser utilizados para a próxima etapa. A seleção das variáveis relevantes para o treinamento do modelo foram detalhadas na Seção 3.5.2, que forma os valores de amplitude e desvio padrão das variáveis X, Y

e Z do plano ortogonal do robô as os torques calculados (Torque Arm) dos eixos 2 e 3.

Com os dados preparados para a fase de treino, iniciou-se a definição dos possíveis algoritmos capazes de solucionar o problema. Considerando a literatura e alguns testes iniciais, bem como a viabilidade de implementação prática em um CLP, o modelo escolhido foi o *Isolation Forest* por ter apresentado qualitativamente os melhores resultados das métricas. Os detalhes de desenvolvimento e aplicação desse algorítimo foram explicados na seção 3.6.

O que se percebeu com relação aos dados analisados é que os *datasets* possuíam grandes dimensões de dados, variação de produtos, desbalanceamento com relação as quantidades de amostras normais e amostras anômalas e desbalanceamento em quantidades totais entre os produtos, conforme foi mostrado na Tabela 3. Dessa forma, os testes foram iniciados gerando um modelo específico para cada produto, para garantir e eliminar as possíveis interferências dessa variável. Logo após, o algoritmo foi aplicado para o treinamento do *dataset* inteiro tendo como característica o produto – este modelo foi chamado de global. No comparativo em termos de resultados de métricas entre os modelos individuais e o modelo global, percebeu-se que este último apresentou um desempenho superior a todos os modelos individuais em todas as métricas avaliadas, que foram *precision*, *recall* e *F1-score*, os quais foram mostrados na seção 4.2.1. A matriz de confusão de cada modelo também foi utilizada para verificar a performance do classificador ao identificar o tipo correto de anomalia gerada e mais uma vez o modelo global se mostrou mais assertivo na classificação.

Com o desenvolvimento do trabalho e em paralelo o estudo das variáveis e o comportamento do robô em ambas situações de ciclo normal e anômalo, pode-se perceber que os sensores (*resolver*, corrente elétrica e posições cartesianas) são capazes de perceber a ocorrência de desvios, sendo esses verificados através das curvas das variáveis analisadas. Como resultados atingidos, pode-se destacar a viabilidade de um modelo de *Machine Learning* (detecção de anomalia) para a monitoração de anomalias de um robô industrial, confirmados através das métricas geradas pelo modelo genérico, o qual apresentou a melhor performance, atingindo os resultados de *Precision* igual a 1, o que significa que todas as amostras consideradas normais foram classificadas e detectadas corretamente, *Recall* igual a 0,952 e *F1-Score* igual a 0,975. Considerando o *dataset* com um total de 6516 amostras, dessas 274 com a presença de algum tipo de anomalia, teve-se como resultado apenas 13 casos de anomalias classificadas de forma errada, em função da semelhança de padrão de curva com o padrão normal – resultado considerado satisfatório para este trabalho.

Uma das fases mais desafiadoras foi a implementação prática do arquivo executável que continha o modelo de *machine learning* na CPU de comando da estação. Conforme explicado no seção 4.4, essa etapa foi cumprida com sucesso, atendendo os requisitos de performance da CPU após o *deployment*. Ocorreu um problema na avaliação de desempenho do modelo devido a uma substituição do conjunto robô e base de fixação que atrasaram a etapa de confirmação da performance do modelo. O arquivo executável encontra-se em operação na máquina coletando dados para avaliação.

Dessa forma, os principais requisitos inicialmente foram atendidos com o desenvolvimento do trabalho:

- Coleta de dados de um robô industrial de forma organizada, estruturada e periódica;
- Análise e entendimento dos valores reportados pelos sensores disponibilizados pelo robô sem a necessidade de sensoriamento externo;
- Definição de um algoritmo de *machine learning* capaz de realizar a detecção das variações dos sensores em presença de anomalias;
- Apresentação de resultados quantitativos através das métricas validando a utilização do modelo.

Em linhas gerais, o requisito maior que era conseguir monitorar pequenas variações de ciclo (anomalias) em um robô industrial manipulador em uma linha de produção real foi atingido com sucesso. No início do estudo não havia qualquer forma de detectar essas falhas, ou erros de posicionamento com comentado no início do trabalho. Esse era o objetivo mais importante, o qual motivou todo o desenvolvimento desse estudo que, por sua vez, demonstrou tal viabilidade.

Como sugestão para trabalhos futuros, ainda existem mais dados do robô que podem ser explorados, como por exemplo os ângulos dos servomotores e o ângulo de giro de cada um dos seis eixos, pois existem referências na literatura de trabalhos que utilizam essas variáveis como entrada de treinamento do modelo, uma vez que elas podem auxiliar ainda mais na detecção de distúrbios. Outra frente de estudos é implementar o modelo na linha e coletar os resultados das anomalias encontradas, para a construção de um *Dashboard* com informações relevantes a cada robô mostrando diversas *features* que podem ajudar não somente a manutenção no entendimento do funcionamento e planejamento das atividades de manutenção preventiva, como também o pessoal de produção na tomada de decisões tendo em vista as perspectivas de operação do robô e os impactos que uma parada poderia causar.

REFERÊNCIAS

AIVALIOTIS, P.; ARKOULI, Z.; GEORGOULIAS, K.; MAKRIS, S. Degradation curves integration in physics-based models: Towards the predictive maintenance of industrial robots. **Robotics and Computer-Integrated Manufacturing**, v. 71, p. 102177, 2021. ISSN 0736-5845. Disponível em: https://www.sciencedirect.com/science/article/pii/S0736584521000600.

BILANCIA, Pietro; SCHMIDT, Juliana; RAFFAELI, Roberto; PERUZZINI, Margherita; PELLICCIARI, Marcello. An overview of industrial robots control and programming approaches. **Applied Sciences**, v. 13, n. 4, 2023. ISSN 2076-3417. Disponível em: https://www.mdpi.com/2076-3417/13/4/2582.

BONCI, Andrea; LONGHI, Sauro; NABISSI, Giacomo; VERDINI, Federica. Predictive maintenance system using motor current signal analysis for industrial robot. *In*: **2019 24th IEEE International Conference on Emerging Technologies and Factory Automation (ETFA)**. *[S.l.: s.n.]*, 2019. p. 1453–1456.

BORGI, Tawfik; HIDRI, Adel; NEEF, Benjamin; NACEUR, Mohamed Saber. Data analytics for predictive maintenance of industrial robots. *In*: **International Conference on Advanced Systems and Electric Technologies**. *[S.l.: s.n.]*, 2017. p. 412–417.

CHALAPATHY, Raghavendra; CHAWLA, Sanjay. Deep learning for anomaly detection: A survey. **CoRR**, abs/1901.03407, 2019. Disponível em: http://arxiv.org/abs/1901.03407.

CHAN, Simon; TRELEAVEN, Philip. Chapter 5 - continuous model selection for large-scale recommender systems. *In*: GOVINDARAJU, Venu; RAGHAVAN, Vijay V.; RAO, C.R. (Ed.). **Big Data Analytics**. Elsevier, 2015, (Handbook of Statistics, v. 33). p. 107–124. Disponível em: https://www.sciencedirect.com/science/article/pii/B9780444634924000058.

CHANDOLA, Varun; BANERJEE, Arindam; KUMAR, Vipin. Anomaly detection: A survey. **ACM Comput. Surv.**, Association for Computing Machinery, New York, NY, USA, v. 41, n. 3, jul 2009. ISSN 0360-0300. Disponível em: https://doi.org/10.1145/1541880.1541882.

CHEN, Tingting; LIU, Xueping; XIA, Bizhong; WANG, Wei; LAI, Yongzhi. Unsupervised anomaly detection of industrial robots using sliding-window convolutional variational autoencoder. **IEEE Access**, v. 8, p. 47072–47081, 2020.

COSTA, Neto Pedro Luiz de Oliveira. **Estatística, 2.a edição revista e atualizada**. *[S.l.]*: Editora Edgarda Blücher Ltda, 2002.

CRAIG, John J. **Introduction to Robotics: Mechanics and Control**. 2nd. ed. USA: Addison-Wesley Longman Publishing Co., Inc., 1989. ISBN 0201095289.

GOLDSTEIN, Markus; UCHIDA, Seiichi. A comparative evaluation of unsupervised anomaly detection algorithms for multivariate data. **PLOS ONE**, Public Library of Science, v. 11, p. 1–31, 04 2016. Disponível em: https://doi.org/10.1371/journal.pone.0152173.

HARIRI, Sahand; KIND, Matias Carrasco; BRUNNER, Robert J. Extended isolation forest. **IEEE Transactions on Knowledge and Data Engineering**, v. 33, n. 4, p. 1479–1489, 2021.

HORNUNG, Rachel; URBANEK, Holger; KLODMANN, Julian; OSENDORFER, Christian; SMAGT, Patrick van der. Model-free robot anomaly detection. *In*: **2014 IEEE/RSJ International Conference on Intelligent Robots and Systems**. *[S.l.: s.n.]*, 2014. p. 3676–3683.

IBRAHIM, Anood; ALEXANDER, Reba Rachel; SANGHAR, MS Umar; D'SOUZA, Royson Donate. Control systems in robotics: A review. **International Journal of Engineering Inventions**, v. 5, n. 5, p. 29–38, 2016.

KAYAN, Hakan; RANA, Omer; BURNAP, Pete; PERERA, Charith. Artifact: Casper: Context-aware anomaly detection system for industrial robotic arms. *In*: **2023 IEEE International Conference on Pervasive Computing and Communications Workshops and other Affiliated Events (PerCom Workshops)**. *[S.l.: s.n.]*, 2023. p. 3–4.

KUKA, Deustchland GmbH. Kuka system software 8.5, operating and programimg instructions for system integrators. **IEEE Transactions on Smart Grid**, KSS 8.5 SI V7, n. 3, p. 2378–2388, 2019.

LESOUPLE, Julien; BAUDOIN, Cédric; SPIGAI, Marc; TOURNERET, Jean-Yves. Generalized isolation forest for anomaly detection. **Pattern Recognition Letters**, v. 149, p. 109–119, 2021. ISSN 0167-8655. Disponível em: https://www.sciencedirect.com/science/article/pii/S0167865521002063.

LIU, Fei Tony; TING, Kai Ming; ZHOU, Zhi-Hua. Isolation forest. *In*: **2008 Eighth IEEE International Conference on Data Mining**. *[S.l.: s.n.]*, 2008. p. 413–422.

MARINA MüLLER CRISTOPHER, Kraus Werner Bill; SUSSANE, Bieler. **World Robotics 2022**. Lyoner Str. 18 DE-60528 Frankfurt am Main, 2022. Disponível em: https://ifr.org/downloads/press2018/2022_WR_extended_version.pdf.

NENTWICH, Corbinian; REINHART, Gunther. Towards data acquisition for predictive maintenance of industrial robots. **Procedia CIRP**, v. 104, p. 62–67, 2021. ISSN 2212-8271. 54th CIRP CMS 2021 - Towards Digitalized Manufacturing 4.0. Disponível em: https://www.sciencedirect.com/science/article/pii/S2212827121009094.

PANG, Guansong; SHEN, Chunhua; CAO, Longbing; HENGEL, Anton Van Den. Deep learning for anomaly detection: A review. **ACM Comput. Surv.**, Association for Computing Machinery, New York, NY, USA, v. 54, n. 2, mar 2021. ISSN 0360-0300. Disponível em: https://doi.org/10.1145/3439950.

PARK, Kyu Min; PARK, Younghyo; YOON, Sangwoong; PARK, Frank C. Collision detection for robot manipulators using unsupervised anomaly detection algorithms. **IEEE/ASME Transactions on Mechatronics**, p. 1–11, 2021.

RASCHKA, Sebastian; MIRJALILI, Vahid. **Python Machine Learning, 3rd Ed.** Birmingham, UK: Packt Publishing, 2019. 748 p. ISBN 978-1789955750.

STANDARDIZATION, International Organization for. **ISO 10218: Robots and Robotic Devices : Safety Requirements for Industrial Robots**. *[S.l.]*: ISO, 2011. (ISO 10218: Robots and Robotic Devices : Safety Requirements for Industrial Robots, pt. 1).

SUELL, Romano Vitor Ferreira e Dutra Max. **Introdução à robótica industrial - Capítulo 1**. *[S.l.]*: xxx, 2020.

WANG, Jue; CHORTOS, Alex. Control strategies for soft robot systems. **Advanced Intelligent Systems**, v. 4, n. 5, p. 2100165, 2022. Disponível em: https://onlinelibrary.wiley.com/doi/abs/10.1002/aisy.202100165.

ZHANG, Zengjie; QIAN, Kun; SCHULLER, BjÃ¶rn W.; WOLLHERR, Dirk. An online robot collision detection and identification scheme by supervised learning and bayesian decision theory. **IEEE Transactions on Automation Science and Engineering**, v. 18, n. 3, p. 1144–1156, 2021.

ZOGHLAMI, Firas; KURREK, Philip; JOCAS, Mark; MASALA, Giovanni; SALEHI, Vahid. Unsupervised pose anomaly detection for dynamic robotic environments. *In*: **2020 IEEE Conference on Industrial Cyberphysical Systems (ICPS)**. *[S.l.: s.n.]*, 2020. v. 1, p. 338–343.